

分类号 TP302

学号 23023014

UDC 004.8

密级 公开

工学硕士学位论文

面向异构 GPU 集群的多模态大语言模型
并行训练策略研究

硕士生姓名 范锦山

学科专业 计算机技术

研究方向 分布式训练与优化

指导教师 李东升 研究员

协助指导教师 赖志权 副研究员

国防科技大学研究生院

二〇二六年三月

Parallel Training Strategy for Training Multimodal Large Language Models on Heterogeneous GPU Clusters

Candidate: Jinshan Fan

Supervisor: Prof. Dongsheng Li

Associate Supervisor: Prof. Zhiquan Lai

A dissertation

Submitted in partial fulfillment of the requirements

for the degree of Master of Engineering

in Computer Technology

Graduate School of National University of Defense Technology

Changsha, Hunan, P. R. China

March, 2026

独 创 性 声 明

本人声明所呈交的学位论文是我本人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表和撰写过的研究成果，也不包含为获得国防科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文题目：面向异构 GPU 集群的多模态大语言模型并行训练策略研究

学位论文作者签名：_____ 日期：_____ 年 _____ 月 _____ 日

学位论文版权使用授权书

本人完全了解国防科技大学有关保留、使用学位论文的规定。本人授权国防科技大学可以保留并向国家有关部门或机构送交论文的复印件和电子文档，允许论文被查阅和借阅；可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

（保密学位论文在解密后适用本授权书。）

学位论文题目：面向异构 GPU 集群的多模态大语言模型并行训练策略研究

学位论文作者签名：_____ 日期：_____ 年 _____ 月 _____ 日

作者指导教师签名：_____ 日期：_____ 年 _____ 月 _____ 日

目 录

摘 要	i
Abstract	ii
第一章 绪论	1
1.1 研究背景	1
1.1.1 训练多模态大语言模型面临的挑战	1
1.1.2 异构 GPU 集群的并行训练策略	4
1.2 国内外研究现状	7
1.2.1 多模态大语言模型并行训练策略研究现状	7
1.2.2 异构 GPU 集群并行训练策略研究现状	8
1.3 研究内容与贡献	10
1.3.1 MMoH: 多模态大语言模型在异构 GPU 集群上的混合并行	10
1.3.2 HR-MMoH: 多模态大语言模型在异构 GPU 集群上的重计算 .	11
1.4 论文组织结构	11
第二章 相关工作	13
2.1 多模态大语言模型	14
2.1.1 多模态大语言模型的异构架构	14
2.1.2 多模态大语言模型训练数据	15
2.1.3 多模态大语言模型训练过程	16
2.2 并行与分布式训练基础	17
2.2.1 数据并行与模型并行	17
2.2.2 零冗余优化器 (ZeRO)	20
2.3 异构 GPU 集群并行训练策略	21
2.4 重计算显存优化技术	23
2.5 本章小结	26
第三章 MMoH: 多模态大语言模型在异构 GPU 集群上的高效混合并行	27
3.1 引言	27
3.1.1 问题与动机	27
3.1.2 MMoH 框架概览	30
3.2 异构设备映射与复合粒度模型划分	32
3.2.1 需求驱动的设备拓扑识别	33

3.2.2	复合粒度抽象	34
3.2.3	冻结感知的模型划分	36
3.3	提前终止流水线调度策略	37
3.3.1	冗余识别与剪枝规则	38
3.3.2	调度流程与实现细节	39
3.3.3	对成本模型与划分策略的影响	40
3.3.4	实现要点	41
3.4	实验验证	42
3.4.1	实验设置	42
3.4.2	实验结果	43
3.4.3	实验分析	45
3.5	本章小结	47
第四章	HR-MMoH: 多模态大语言模型在异构 GPU 集群上的重计算策略	49
4.1	引言	49
4.2	异构重计算	50
4.2.1	现有的重计算策略与定量分析	50
4.2.2	异构重计算策略设计	56
4.3	实验验证	57
4.3.1	实验设置	57
4.3.2	实验结果	58
4.3.3	实验分析	58
4.4	本章小结	58
第五章	总结与展望	61
5.1	全文工作总结	61
5.1.1	主要创新点	61
5.1.2	研究的局限性	62
5.2	未来工作展望	62
5.2.1	理论深化	63
5.2.2	应用拓展	63
致谢		65
参考文献		67
作者在学期间取得的学术成果		77
公开评阅信息		79

附录 A 模板提供的希腊字母命令列表	81
--------------------------	----

表 目 录

表 2.1	多模态大语言模型训练中常用的部分数据集规模示意	16
表 3.1	实验用异构 GPU 集群配置	42
表 3.2	实验用 MLLM 模块配置（模型参数）	43
表 3.3	不同冻结场景下的模型划分对比。A、B、C 分别表示 NVIDIA RTX 3090、2080 Ti 与 2080 GPU。	45
表 4.1	Megatron-LM 重计算相关配置参数	51
表 4.2	Megatron selective 粒度下可配置的子模块	52
表 4.3	4.2.2 节主要符号说明	53
表 4.4	单层 Transformer 中间激活量	55

图 目 录

图 1.1 多模态大语言模型的核心组成部分	3
图 1.2 NVIDIA GPU 架构与代表性产品演进	5
图 1.3 使用 Megatron 训练多模态大语言模型	9
图 2.1 MLLM 多阶段训练中典型模块冻结与更新关系示意	17
图 2.2 数据并行示意	18
图 2.3 张量并行示意	18
图 2.4 流水线并行示意	19
图 2.5 专家并行 (EP) 中门控路由与专家分布示意	20
图 2.6 零冗余优化器 ZeRO 示意	21
图 2.7 重计算 (激活检查点) 示意	24
图 3.1 主流 MLLMs 的编码器—投影层—LLM 结构及冻结方式。	28
图 3.2 LLM 与 MLLM-3B 各层计算开销与显存占用的变化趋势 (NF 为不冻结, FB 为 freeze-both)。	29
图 3.3 不同并行策略在两种冻结场景下训练 MLLM-3B 的迭代时间, MMoH1/MMoH2 为 MMoH 规划器针对各场景得到的策略。	30
图 3.4 MMoH 框架总览。MMoH 包含并行策略规划器与提前终止调度器: 规划器根据 MLLMs 配置与异构集群规格生成最优并行策略; 调度器在训练中利用冻结技术减少不必要的计算与通信。	31
图 3.5 复合粒度抽象示意。(a) 编码器: 将连续多层层合并为编码器层块; (b) LLM Backbone: 将单层拆分为注意力块与 FFN 块, 不增加流水级间通信量。	35
图 3.6 提前终止调度器效果示意。4 流水级流水线、4 个 micro-batch, 前两流水级为冻结流水级。(a) 标准 1F1B; (b) 考虑冻结后反向时间变化; (c) 提前终止调度器: 跳过前两流水级对输入的梯度计算及相应 P2P 通信与张量存储。	40
图 3.7 提前终止在其它流水线调度机制上的适用性。左: Chimera; 右: Hanayo。前向时间假设各流水级一致, 反向时间差异来自冻结流水级; 提前终止可同样应用于连续冻结前缀。	41
图 3.8 四种冻结场景下 MMoH 与基线在两种异构集群上的训练吞吐对比。柱越长表示吞吐越高, OOM 表示显存溢出。	44
图 3.9 MMoH 与 Whale、Espresso 在 MLLM-12B 上、两种冻结设置下的负载均衡对比。分布越集中表示划分越均衡, 柱高越低表示迭代时间越短。	46

图 3.10 提前终止调度器消融。Espresso+ 为接入该调度器的 Espresso, MMoH- 为去掉该调度器的 MMoH。	46
图 4.1 注意力子层中间激活示意	53
图 4.2 MLP 子层中间激活示意	54

摘 要

多模态大语言模型（MLLM）融合视觉、语言等模态的感知与生成能力，是当前人工智能研究的重要方向，其训练依赖分布式与并行计算。实际部署中的 GPU 集群往往由多代、多型号设备混合组成，存在显存、算力与通信的异构；而 MLLM 在结构上由编码器、投影层与 LLM 骨干等异构模块组成，训练时又广泛采用分阶段冻结策略，导致各阶段计算与显存需求差异显著。现有并行策略（如 Megatron-LM、ZeRO）多假设同构集群与单一模型形态，在异构环境下易产生负载不均衡、资源利用率低及冻结场景下的冗余计算与通信等问题。

本文从流水线划分与调度、显存优化两个层面开展研究。在划分与调度方面，提出 MMoH 框架：通过需求驱动的设备拓扑识别、复合粒度模型抽象与冻结感知的整数规划划分，在给定异构集群与 MLLM 配置下自动生成与当前训练阶段相匹配的流水线并行策略；通过提前终止调度器在连续冻结阶段省略不必要的反向计算与阶段间通信，在保持收敛性的前提下提升吞吐。在显存优化方面，针对现有框架（如 Megatron-LM）中激活重计算采用全局统一配置、在异构集群上难以同时兼顾显存安全与计算效率的问题，提出 HR-MMoH 的异构激活重计算方法：系统梳理 Megatron 的重计算粒度与子模块配置参数，在 MMoH 划分基础上为各流水线阶段根据其显存上限与算力独立配置重计算粒度与子模块集合，显存紧张阶段采用更激进的检查点以降低 OOM 风险，显存充裕阶段采用较保守的配置以减少多余重算，并通过基于剖析的配置策略与 MMoH 形成“划分—调度—显存优化”的联合优化。在两种异构集群与两种规模 MLLM（3B、12B）上的实验表明，MMoH 在多种冻结场景下相对 Megatron-LM、Whale、Espresso 均可取得最高吞吐，最高可达约 1.77 倍加速，提前终止调度器可带来约 8%–19% 的额外增益；HR-MMoH 的按阶段差异化配置思路通过剖析实验得到验证，可为显存受限场景下的训练提供补充手段。本文为异构 GPU 集群上 MLLM 的高效并行训练提供了可参考的技术路径。

关键词：多模态大语言模型；异构 GPU 集群；流水线并行；激活重计算；MMoH

Abstract

Multimodal large language models (MLLMs) integrate vision, language, and other modalities for perception and generation, and have become a major focus of artificial intelligence research; their training relies on distributed and parallel computing. In practice, GPU clusters are often composed of mixed generations and models of devices, exhibiting heterogeneity in memory, compute, and communication. Meanwhile, MLLMs are architecturally composed of heterogeneous modules such as encoders, projectors, and LLM backbones, and training commonly adopts stage-wise freezing, leading to significant differences in compute and memory demand across pipeline stages. Existing parallel strategies (e.g., Megatron-LM, ZeRO) mostly assume homogeneous clusters and uniform model structure, which in heterogeneous settings can cause load imbalance, low resource utilization, and redundant computation and communication under freezing.

This thesis addresses the problem from two aspects: pipeline partitioning and scheduling, and memory optimization. For partitioning and scheduling, we propose the MMoH framework: it uses demand-driven device topology identification, multi-granularity model abstraction, and freeze-aware integer-programming-based partitioning to automatically generate pipeline-parallel strategies that match the current training stage for a given heterogeneous cluster and MLLM configuration; an early-termination scheduler omits unnecessary backward computation and inter-stage communication at consecutive frozen stages, improving throughput while preserving convergence. For memory optimization, we address the fact that existing frameworks (e.g., Megatron-LM) use a single global activation recomputation configuration, which is ill-suited to heterogeneous clusters where memory-tight stages may still hit OOM while memory-rich stages incur unnecessary recomputation. We propose HR-MMoH with heterogeneous-aware gradient checkpointing: we systematically summarize Megatron’s recomputation granularity and submodule parameters, then assign each pipeline stage an independent recomputation configuration (granularity and submodule set) according to its memory headroom and compute, so that memory-tight stages use more aggressive checkpointing to reduce OOM risk and memory-rich stages use conservative settings to avoid redundant recomputation; a profiling-based configuration strategy is used and integrated with MMoH to form a joint “partitioning–scheduling–memory optimization” pipeline. Experiments on two heteroge-

neous clusters and two MLLM scales (3B and 12B parameters) show that MMoH achieves the highest throughput under various freezing scenarios compared with Megatron-LM, Whale, and Espresso, with speedups of up to about $1.77\times$, and the early-termination scheduler brings an additional 8%–19% gain; the per-stage heterogeneous checkpoint configuration in HR-MMoH is validated via profiling and provides a complementary means for memory-constrained training. This work provides a practical technical path for efficient parallel training of MLLMs on heterogeneous GPU clusters.

Key Words: Multimodal large language model; Heterogeneous GPU cluster; Pipeline parallelism; Gradient checkpointing; MMoH

符号使用说明

HPC	高性能计算 (High Performance Computing)
cluster	集群
Itanium	安腾
SMP	对称多处理
API	应用程序编程接口
PI	聚酰亚胺
MPI	聚酰亚胺模型化合物, N- 苯基邻苯酰亚胺
PBI	聚苯并咪唑
MPBI	聚苯并咪唑模型化合物, N- 苯基苯并咪唑
PY	聚吡咙
PMDA-BDA	均苯四酸二酐与联苯四胺合成的聚吡咙薄膜
ΔG	活化自由能 (Activation Free Energy)
χ	传输系数 (Transmission Coefficient)
E	能量
m	质量
c	光速
P	概率
T	时间
v	速度

第一章 绪论

1.1 研究背景

1.1.1 训练多模态大语言模型面临的挑战

深度神经网络 (Deep Neural Network, DNN) 在计算机视觉 (Computer Vision, CV)、自然语言处理 (Natural Language Processing, NLP)、语音识别 (Speech Recognition, SR) 等众多领域得到了广泛应用, 并逐步演变为诸多关键技术领域的核心基础 [1]。2017 年, Vaswani 等人提出基于自注意力机制 (Self-Attention) 的 Transformer 架构 [2], 摒弃了传统的循环神经网络 (Recurrent Neural Network, RNN) 与卷积神经网络 (Convolutional Neural Network, CNN) 结构, 凭借并行化友好与长距离依赖的建模能力, 迅速成为自然语言处理与跨模态建模的主流模型结构。

在自然语言处理 (Natural Language Processing, NLP) 方面, 基于 Transformer 的预训练大语言模型 (Large Language Models, LLMs) 不断刷新各类基准。BERT[3] 通过双向编码与掩码预训练在理解类任务上取得显著优势; GPT-2[4]、T5[5] 等自回归 (Autoregressive) 或编码器 - 解码器 (Encoder-Decoder) 模型则在生成与迁移学习 (Transfer Learning) 上表现突出; GPT-3[6] 与后续的 GPT-4[7] 等大规模语言模型 (Large Language Models, LLMs) 更在少样本 (Few-Shot) 与零样本 (Zero-Shot) 设定下展现出接近人类的泛化能力。在计算机视觉 (Computer Vision, CV) 领域, Vision Transformer (ViT) [8] 及后续的规模化工作 [9] 表明: 将图像切分为块 (patch) 并经 Transformer 编码, 即可在 ImageNet 等基准数据集上超越传统卷积网络。CLIP[10] 通过图文对比学习 (Contrastive Language-Image Pre-Training) 实现了开放词汇的视觉表征, DALL-E[11] 则展示了从文本到图像生成的可行性。以 Transformer 为基座 (Backbone)、依靠规模扩展提升模型能力的技术路线, 已在实践中被证明高度有效。随着单模态任务性能的趋于成熟, 将视觉、语言、音频等多模态信息纳入统一的模型框架进行联合表示与推理, 已成为当前研究的重要演进方向。

多模态 (Multimodality) 指对两种或两种以上模态信息进行联合表示、推理与生成的技术范畴。在机器学习与人工智能中, 常见模态包括文本、图像、视频、音频、表格以及各类传感器数据。多模态大语言模型 (Multimodal Large Language Models, MLLMs) 特指在参数规模巨大的语言模型基础上, 融合对视觉、听觉等非文本模态的感知与生成能力的一类模型 [12–14]。近年来, MLLMs 在架构

与训练范式上发展迅速：BLIP-2[12] 提出 Q-Former 连接冻结视觉编码器与 LLM；InstructBLIP[15] 在此基础上引入指令感知的视觉特征抽取，在多项零样本任务上取得 SOTA；LLaVA[13] 与 LLaVA-1.5[16] 采用简单线性投影实现视觉与语言模态对齐，验证了“小连接器 + 大模型”的有效性；Qwen-VL[17]、InternVL[18] 等系列模型则进一步在长上下文（Long Context）、高分辨率（High Resolution）与多图理解（Multi-Image Understanding）上扩展模型能力。这类模型既保留 LLMs 在语言理解、推理与生成上的优势，又能够直接处理图像、视频等多模态输入，实现跨模态交互与推理任务，因而被认为是迈向通用人工智能（Artificial General Intelligence, AGI）的潜在路径 [19, 20]。模型能力的拓展必然依赖于更加复杂的模块设计：前者决定了 MLLM 的应用边界，后者则直接影响到训练时的计算与显存分布。

从功能表现来看，MLLMs 可完成图像描述（Image Captioning）、视觉问答（Visual Question Answering）、图文对话（Visual-Text Dialog）、文档理解（Document Understanding），以及基于文本的图像或视频生成等任务，在智能助手、自动驾驶、内容创作、教育培训、工业质检等场景具有广阔应用前景。在垂直领域，MLLMs 已延伸至具身智能（Embodied Intelligence）[21]、医疗影像理解（Medical Image Understanding）[22]、科学文档与图表推理 [23] 等，相关评估常依托 VQAv2[24]、GQA[25]、MMMUI[26] 等多模态基准，对模型规模与训练数据提出了更高要求。从结构上看，MLLMs 通常包含以下核心组件（见图1.1）：（1）*Modality Encoder*，负责将图像、视频等非文本输入编码为特征表示，常采用预训练的视觉模型（如 CLIP、ViT）作为 backbone；（2）*Input Projector*，将编码后的多模态特征映射到与 LLM 词嵌入对齐的语义空间，常见形式包括线性层、Q-Former[12] 等轻量模块；（3）*LLM Backbone*，即大规模语言模型主体，承担主要的理解与生成计算，参数量通常占整体模型的 80%–90%；（4）*Output Projector*（在需要多模态生成时），将 LLM 输出映射到与目标模态生成器对齐的表示空间；（5）*Modality Generator*（在需要多模态生成时），根据投影表示生成图像、音频等目标模态，常采用扩散模型（如 Stable Diffusion）等。可见，LLMs 处于 MLLMs 架构的核心，多模态能力是在其基础上进行的扩展与增强；在大语言模型占据主体参数量的架构下，针对 LLMs 归纳出的扩展定律（Scaling Laws）与数据规模规律，同样深刻影响着 MLLMs 训练的资源需求。

已有实证研究表明，模型性能通常会随参数规模与训练数据规模的增加而稳定提升，这一现象被总结为“扩展定律”（Scaling Laws）[27]。Kaplan 等 [27] 的早期工作表明，在给定算力预算下，模型规模与数据规模应按幂律关系共同扩展；Hoffmann 等 [28] 在 Chinchilla 工作中进一步指出，当前大语言模型普遍“训练不




图 1.1 多模态大语言模型的核心组成部分

足”，在计算最优意义下，模型参数量与训练 token 数应近似同比例扩展（约 20 倍 token/ 参数），该结论对预训练数据规模与模型架构选择产生了深远影响；近期工作 [29] 则从推理成本角度拓展了 Chinchilla 最优，指出在考虑部署与推理时，最优扩展策略会随推理请求规模发生变化。为追求更强性能，工业界与学术界不断推出参数量更大、数据规模更大的模型，从数亿参数（如 BERT）到千亿、万亿参数（如 GPT-3、Gopher[30]、DeepSeek-V3[31]、Qwen2.5[32]、LLaMA 2/3[33, 34]、Gemma[35]、Mistral[36] 等开源与闭源 LLMs），单卡或单机 GPU 的显存与算力已无法容纳整模型的完整训练流程 [37, 38]。相应的，多模态大模型的预训练与指令微调所需的数据量也急剧增长，从数百万图文对到数十亿级样本，单机算力、存储与 I/O 同样成为瓶颈；数据质量与混合比例对下游性能同样有显著影响 [39]，长上下文与多模态联合基准 [40] 的普及进一步推高了对训练规模与效率的需求。在上述模型与数据规模的约束下，单台计算设备的显存与算力资源与均难以独立支撑完整的训练流程。因此，必须借助分布式与并行训练，将模型参数、优化器状态、激活值与数据分散至多台设备，通过节点间的通信协同完成前反向计算，才能实现大规模模型的训练 [41, 42]。

目前，支撑大规模 MLLMs 训练的主流并行策略可归纳为两大类。第一类是以计算与张量切分为核心的多维混合并行：数据并行 [43, 44] 在各设备上复制完整模型、按批次划分样本，通信集中在梯度 AllReduce，实现简单且在小模型上扩

展性好；张量并行 [37, 38]（如 Megatron-LM）将单层内的矩阵按行或列切分到多卡，降低单卡显存并保留层内并行，是千亿级稠密模型的主流选择；流水线并行 [45, 46]（如 GPipe、PipeDream）将模型按层划分为若干阶段并分配到不同设备，通过微批次与调度重叠计算与通信，缓解单设备层数过多的问题；序列并行 [37] 与专家并行 [47] 则分别在长序列注意力与混合专家（MoE）结构中沿序列维或专家维切分，与张量、流水线并行组合后可进一步扩展模型规模。第二类是以显存优化为核心的零冗余优化器系列：ZeRO[41, 42] 将优化器状态、梯度与参数分片存于各卡，前向与反向时按需聚合，在保持数据并行通信量的同时显著降低单卡显存；ZeRO-Infinity[42] 进一步将部分状态卸载至 CPU 与 NVMe，突破 GPU 显存墙；ZeRO++[48] 通过量化与通信重算技术减少跨节点通信量，提升多节点训练效率。上述并行策略常与混合精度训练 [49]、激活检查点 [50]、Flash Attention[51, 52] 等显存与计算优化技术结合，共同构成当前大模型与 MLLMs 训练的基础设施；PyTorch 的 FSDP[53] 与 DeepSpeed ZeRO 类似，通过全分片参数与优化器状态实现单卡显存的大幅降低。然而，上述策略在设计时多假设同构集群与单一形态的 Transformer 模型，其划分粒度、负载均衡与通信优化均围绕“各层计算与显存相对均匀”这一前提展开；在面对异构 GPU 集群与模块异构的 MLLMs 时，负载与显存分布的不均匀性被放大，仍存在效率与可扩展性方面的挑战，这也是本文关注的重点之一。

在实际应用中，企业与研究机构常面临定制化多模态模型的高频微调需求，这要求训练系统具备较高的可扩展性与资源利用率。然而，受预算与硬件采购周期的限制，多数集群难以维持绝对的同构性，往往需要在现有的异构设备组合上开展预训练与微调实验。因此，提升异构 GPU 集群下的训练效率、使其逼近同构环境的表现，具有迫切的现实需求。同时，因负载不均或通信瓶颈导致的计算资源浪费不仅会延长训练周期，亦会显著增加算力成本。由此可见，针对异构集群设计高效的 MLLMs 并行训练方案，既是系统层面的技术挑战，也是落地部署中的关键环节。

1.1.2 异构 GPU 集群的并行训练策略

多模态大语言模型的训练效率与成本高度依赖底层硬件平台。目前，工业界与学术界普遍采用 NVIDIA GPU 作为大模型与 MLLMs 训练的主要加速器，并通过多卡、多机集群进行分布式训练。然而，NVIDIA 约每 1–2 年迭代一代计算架构并推出多款不同定位的 GPU，导致显存容量、算力与互联方式持续分化，实际部署中的集群往往由多代、多型号 GPU 混合组成，形成显存异构、算力异构与通信异构并存的局面 [54, 55]。对单层计算与显存相对均匀的传统 LLMs，尚可通过

“按层数或算力比例”划分在一定程度上缓解异构；而对编码器、投影层与 LLMs 在结构与参数量上差异显著的 MLLMs，模块间负载差异与设备能力差异叠加，使得简单比例划分难以同时兼顾负载均衡与显存安全。

图1.2 概括了近年来 NVIDIA GPU 的架构演进。2016–2017 年的 Pascal（如 P100）与 Volta（V100）奠定了数据中心 GPU 与 Tensor Core 的基础；2018 年 Turing（RTX 20 系列）引入消费级光追与 INT8 推理；2020 年 Ampere 架构推出 A100（40GB/80GB HBM2e）与消费级 RTX 30 系列（如 RTX 3090 24GB），支持 PCIe 4.0 与 NVLink 3.0，成为当前许多实验室与云平台的主力 [56]。2022 年 Hopper 架构的 H100（80GB/96GB HBM3）针对 Transformer 与 LLM 训练做了专门优化 [57]，并广泛配备 NVLink 4.0 与 NVSwitch，单机多卡带宽可达数百 GB/s；同年 Ada Lovelace 架构的 RTX 40 系列（如 RTX 4090 24GB）在消费级市场提供高性价比算力。2024 年起，Blackwell 架构的 B100/B200 等数据中心 GPU 逐步量产，采用 HBM3e、更高带宽的 NVLink5 与 PCIe 6.0，进一步拉大与旧代设备的性能与互联差距 [58]。按 NVIDIA 已披露的路线图，后续还将推出 Rubin（约 2026 年）、Rubin Ultra（约 2027 年），以及面向推理与能效深度优化的费曼（*Feynman*）架构（约 2028 年），后者将采用下一代 HBM 与 3D 堆叠内存等技术，进一步凸显代际间显存与互联的差异。与此同时，不同代际与型号在 PCIe 版本（3.0/4.0/5.0/6.0）、是否配备 NVLink/NVSwitch、以及 InfiniBand 与 RoCE 等节点间网络上的差异，使得通信带宽与延迟在集群内分布极不均匀。




图 1.2 NVIDIA GPU 架构与代表性产品演进

在大多数高校、研究所与中小企业的实际环境中，受预算与采购周期限制，集群常同时包含多代 GPU（例如部分 A100 或 H100 与大量 RTX 3090/4090、甚至更早的 V100/RTX 2080），单机内也可能混用不同显存与互联配置，难以做到“全集群同构”。而主流并行训练框架（如 Megatron-LM、DeepSpeed）在设计时多假设同构设备与统一拓扑 [37, 41]，在异构集群上直接使用往往导致：负载无法按算力与显存合理分配、通信成为瓶颈或部分高端卡空闲、以及因“木桶效应”整体效率下降 [54, 55]。因此，在显存、算力与通信三重异构的 GPU 集群上高效训练 MLLMs，是学术界和工业界共同面临且亟待解决的问题。

从系统层面看，异构带来的问题不仅在于单卡能力差异，还在于拓扑与调度：节点内 NVLink 与节点间 InfiniBand 的带宽可相差一个数量级以上，若流水线或张量并行的划分未考虑链路差异，跨节点通信极易成为瓶颈；同时，MLLMs 各阶段对编码器、投影层与 LLMs 的冻结策略不同，导致同一模型在不同训练阶段下各层的计算与显存占比发生明显变化，若沿用固定划分与调度，难以在整轮训练中保持负载均衡。因此，面向异构集群的 MLLMs 训练需要同时考虑硬件拓扑、模型结构与多训练阶段，通过自适应的划分与高效的调度使各设备利用率最大化。

除了硬件设施固有的算力、显存和通信异构，模型异构也是现有并行训练框架无法高效训练多模态大语言模型的原因之一。负责将不同模态的输入数据编码为模型可理解的 Modality Encoder 一般是视觉模型（如 CLIP、ViT 等），核心模块 LLMs 是常见的基座大语言模型（如 GPT-3、Llama-3[34]），具有庞大的参数量，大约占据整个多模态大语言模型 80%–90% 的参数量。Modality Generator 一般是一个 Diffusion 生成模型（如 Stable Diffusion[59]），根据 LLMs 的输出产生图像、视频、音频等其它模态的数据。其中，LLMs 是由参数量很大的 Transformer 层堆叠而成，Encoder 可能由小的 Transformer 层或卷积层等其它神经网络组成，Generator 也可能是 U-Net[60] 等其他网络结构。前后两个 Projector 可能是 Transformer 层、Linear 层，也可能是 Q-Former[12] 等其它网络结构。多模态大语言模型的这种网络结构和传统的大模型结构不同，传统的大模型只有一种参数量固定的 Transformer 层，每一层在特定 GPU 上运行所需的时间和显存都是固定的；而对于多模态大语言模型，模型的某一层变化多样，在不同的 GPU 上运行的时间开销和显存开销都不同，在异构 GPU 集群的环境下，这种模型异构对于异构集群上训练效率带来的影响被进一步放大。

得益于深度学习的持续演进，在计算机视觉、大语言模型、内容生成等领域涌现出众多性能优异的预训练模型，为当前多模态大语言模型的训练范式奠定了基础。Blip-2[12] 率先提出复用已有的 SOTA 模型，在训练过程中冻结大部分网络模块，仅更新新增的轻量连接层，从而实现跨模态对齐。此后，这种基于冻结与

局部更新的策略被广泛应用于各类多模态大语言模型中，如近期的 NextGPT[61]、DreamLLM[62] 等工作。此外，多模态大语言模型的训练通常被划分为多个阶段（如模态对齐、指令微调等），不同阶段针对特定能力解冻不同模块。当某一模块被冻结时，其反向传播的计算量会大幅下降；且优化器亦无需为冻结参数维护一阶与二阶矩等状态变量（如使用 Adam[63] 优化器时），这显著降低了训练过程中的显存压力。但在异构 GPU 集群中，这种由模块冻结带来的算力、显存与通信需求的时变性，反而放大了各设备间的负载不均。此外，云上与混合部署中的弹性训练与按需资源供给，使得集群内设备型号与拓扑更加多样，对异构感知的划分与调度、以及训练成本与性能的联合优化提出了进一步要求 [64–66]。

硬件层面的设备异构与模型层面的模块异构、分阶段冻结交织，构成了当前有限资源下高效训练的核心难点。为此，本课题拟结合现有并行策略，深入分析实际 GPU 集群中的异构场景，基于 Megatron 等主流并行训练框架，针对 MLLMs 的结构特点以及集群内显存、算力与带宽的非均匀性，研究细粒度的混合同步并行技术和重计算技术，旨在提出一套面向异构复杂环境的自适应并行训练方案，以期缓解异构集群下训练 MLLMs 效率低、显存利用不充分等问题。

1.2 国内外研究现状

1.2.1 多模态大语言模型并行训练策略研究现状

近年来，基座语言模型、视觉模型与多模态大语言模型持续向更大参数规模与更大数据规模演进。Kaplan 等 [27] 通过大量实验归纳出扩展定律（Scaling Law）：模型性能随模型参数量与训练数据量的幂律关系持续提升，这为“做大模型、用大数据”提供了理论依据；Chinchilla[28] 进一步表明，在计算最优意义下，模型规模与训练 token 数应同比例扩展，后续研究 [29] 从推理成本角度拓展了最优缩放策略。提升大模型性能的两条主要途径是增大模型参数与扩大数据规模 [1]：通过提升参数量可增强对复杂场景的拟合与泛化能力；通过扩大数据规模可使模型学习到更充分的特征表示 [43]，更好地适应复杂应用场景；参数高效微调（如 LoRA[67]、QLoRA[68]）则在资源受限下广泛用于 MLLM 的适配与部署 [69]。

自 Transformer[2] 提出以来，语言模型规模迅猛增长：从 BERT[3] 的亿级参数，到 GPT-2[4]、T5[5] 的十亿级，再到 GPT-3[6] 的千亿级与 GPT-4[7] 等闭源模型，以及 DeepSeek-V3[31]、Qwen2.5[32] 等开源千亿级模型。多模态大语言模型在此基础上融合视觉编码器与语言模型，代表性工作包括 BLIP-2[12]（Q-Former 连接视觉与语言）、InstructBLIP[15]（指令感知视觉特征）、LLaVA/LLaVA-1.5[13, 16]（线性投影对齐）、Flamingo[14]（交错图文与 gated 交叉注意力）、Qwen-VL[17]、InternVL[18]、MiniGPT-4[19] 等，其参数量从数十亿到数百亿不等，且训练数据从

数百万图文对到数十亿级样本（如 LAION-5B[70]）；相关综述从架构、对齐策略、数据与效率等角度对 MLLMs 进行了系统梳理 [20, 71, 72]。单卡或单机在显存与算力上已无法容纳完整模型与训练流程 [37, 38]，并行与分布式训练成为训练大模型与 MLLM 的必由之路 [41, 42]。

训练数据规模同样持续扩大：图像方面，Open Images[73]、COCO[74] 等需 TB 级存储；LAION-5B 等开放图文对达数十亿样本；文本方面，Common Crawl、The Pile[75] 等为 LLM 预训练提供数百 GB 至数万亿 token 量级语料；视频方面，YouTube-8M[76]、WebVid[77] 等基准需 PB 级存储与高吞吐数据管线；多模态理解与推理则依赖 VQAv2[24]、TextVQA[78] 等数据集与长上下文基准 [40]。在单机无法存储完整数据集与模型的前提下，并行训练（数据并行、模型并行及其组合）成为必然选择。

在并行策略方面，工业界与学术界已形成以数据并行、张量并行、流水线并行及 ZeRO 等为核心的技术栈，并被 Megatron-LM、DeepSpeed 等框架广泛应用于千亿级参数模型训练 [37, 41, 42]。Galvtron[1] 针对 Transformer 在多 GPU 上的自动并行进行了系统探索，将策略搜索与编译优化结合；Colossal-Auto[50] 等将自动并行策略搜索与激活检查点统一自动化，为大规模与异构环境下的联合优化提供了参考。然而，上述框架在设计时多假设同构 GPU 集群与单一形态的 Transformer 模型，对 MLLMs 的模块异构（编码器、投影层、LLM、生成器结构各异）与分阶段冻结考虑不足；在实际部署中，集群往往由多代、多型号 GPU 混合组成，存在显存、算力与通信的异构 [54, 55]，直接使用传统并行策略易出现负载不均、通信瓶颈与“木桶效应”。因此，面向异构 GPU 环境设计多模态大模型并行训练方法，实现自感知、自适应、细粒度的划分与调度，对提高算力利用率、充分利用存储与缓解通信瓶颈十分必要；相关综述可参见 [79]。而要支撑上述目标，需依托现有并行训练的主体形态，并在此基础上针对异构集群与 MLLM 做专门适配。

1.2.2 异构 GPU 集群并行训练策略研究现状

并行训练是当前工业界与学术界训练多模态大语言模型的主要手段，主流做法可概括为两类：以计算与张量切分为核心的多维混合并行，以及以显存分片为核心的零冗余优化器（ZeRO）系列。

多维混合并行通过在不同维度上划分模型或数据以降低单机负载。数据并行 [43, 44] 在各设备上复制完整模型、按批次划分样本，通信集中在梯度 AllReduce，实现简单且扩展性好。张量并行 [37, 38]（如 Megatron-LM）将单层内矩阵按行或列切分到多卡，降低单卡显存，是千亿级稠密模型的主流选择。流水线并行将模型按层划分为若干阶段并分配到不同设备：GPipe[45] 通过微批次与多阶段调度减

少流水线气泡；PipeDream[46] 提出 1F1B 等调度进一步压缩空闲时间。此外，序列并行 [37]、专家并行 [47] 等与张量、流水线并行组合后可进一步扩展模型规模。NVIDIA 的 Megatron-LM[37, 38] 联合使用张量、流水线与数据并行，已支撑在数千张 GPU 上训练千亿至万亿级参数的大语言模型；Korthikanti 等 [80] 针对超大 Transformer 提出序列并行与选择性重计算，与张量并行协同以降低激活显存。零冗余优化器 ZeRO[41, 42] 在数据并行基础上将优化器状态、梯度与参数分片存于各卡、按需聚合，显著降低单卡显存；ZeRO-Infinity[42] 将部分状态卸载至 CPU/NVMe；ZeRO++[48] 通过量化与通信重算减少跨节点通信量。

然而，上述策略多假设同构设备与统一拓扑。Megatron-LM 在设计时未考虑设备异构与模型异构；在实际异构环境下训练 MLLMs 时，往往将不同型号、显存与带宽的 GPU 当作同构设备统一配置，其典型并行策略如图1.3所示。对于 MLLM 中结构各异的 Modality Encoder、LLM Backbone、Projector 与 Modality Generator，Megatron 缺乏针对性的细粒度划分与映射，编码器与生成器的并行方式通常被动跟随 LLM 主干划分，难以根据各子模块的算力与显存需求及不同 GPU 能力做自适应分配，导致显存小、算力弱或通信慢的 GPU 成为瓶颈，整体利用率与训练效率下降 [54, 55]。




图 1.3 使用 Megatron 训练多模态大语言模型

针对异构 GPU 集群的并行训练，已有不少研究。HetPipe[55] 较早将流水线并行与数据并行结合，通过虚拟工作节点（VW）在异构设备间分配负载，但未显式建模设备排列与通信拓扑，也未考虑 MLLM 的模块异构与冻结策略。Whale[54] 针对显存与算力异构提出基于硬件感知的负载均衡方法，按比例对各设备分配不同大小的模型分片与批次，但未考虑网络异构，划分粒度相对粗糙。AMP[81] 在

异构环境下为大模型自动搜索并行策略，同时考虑模型异构与设备异构，通过开销模型与动态规划求解近似最优配置，但划分粒度为全局粗粒度，对通信与显存估计的准确性有限。近年来，面向异构集群的分布式训练系统与调度方法受到持续关注。hethub2024[82] 支持 AMD、NVIDIA 等多厂商异构 GPU 集群，通过统一通信器、性能预测器与自动并行规划，在 768 张异构卡上训练 Llama-140B 达到理论性能上界的 97.49%；HexiScale[83] 将数据、流水线与张量并行的非对称划分形式化，采用层次图划分算法在异构环境下分配计算，在 7B–30B LLM 上取得与同构系统接近的 MFU（平均差距约 3.5%）；Espresso[84] 面向成本效益的异构 GPU 资源供给与阶段放置，集成 Profiler、GPU Allocator、Stage Placer 与 Performance Estimator；Zorse[85] 直接针对异构集群上的 LLM 训练效率优化，支持非对称流水线阶段与异构数据并行组；Cephalo[86] 通过解耦计算分布与训练状态分配在异构集群上为 Transformer 训练分配算力与显存。上述工作多为通用 LLM 或同构扩展设计，对 MLLM 的模块异构、分阶段冻结与显存—算力—通信三重异构的联合优化仍不足。

ZeRO[41, 42] 的梯度 / 参数 All-Gather 等通信在跨节点异构网络中易成为瓶颈；MiCS[87] 对异构网络下的高带宽链路利用仍有不足；ZeRO++[48] 的量化与通信重算可能引入精度与通用性代价；AMSP[88] 等侧重跨节点通信削减，对集群内存存储、算力与带宽的细粒度异构利用仍有限。因此，在异构 GPU 集群上高效训练 MLLMs，仍需在 DeepSpeed 与 Megatron 等现有框架基础上，引入对设备能力与模型结构的感知与自适应优化；本文后续第三章给出的 MMoH 框架即针对上述问题，在异构集群上为 MLLM 提供需求驱动的拓扑识别、复合粒度划分与冻结感知调度 [79, 89]。

1.3 研究内容与贡献

1.3.1 MMoH: 多模态大语言模型在异构 GPU 集群上的混合并行

针对现有并行策略在异构集群适配上的局限性，本课题以实际 GPU 集群中普遍存在的显存、算力和网络异构为切入点，研究细粒度的混合自动并行优化技术。提出适用于异构 GPU 环境的 MLLMs 自适应并行训练方案，以期在复杂集群下缓解负载不均与通信瓶颈，提升整体训练效率。

针对异构 GPU 设备环境下显存空间利用不均衡、通信异构带来的通信瓶颈问题、算力异构带来的 GPU 利用率不高的问题、模型异构带来的算力分配问题、冻结对于显存和计算需求的变化问题，本课题提出一种综合的、面向异构设备和异构模型的多模态大语言模型计算图的层级划分方法，通过为不同属性的计算设备分配不同大小的部分模型，实现计算资源、存储空间、通信带宽的充分利用，争

取最大限度提高训练速度。

MLLMs 训练与常见的大语言模型的训练过程不同，通常需要分为不同的阶段进行训练，在不同的阶段中对不同模块进行冻结，冻结部分的反向计算量远小于未冻结部分，进一步加剧阶段间执行时间的不均衡，使得气泡率在异构流水线中居高不下，而且可能存在冗余的计算和通信。

本课题针对上述问题，提出一种面向多模态大语言模型的提前终止流水线调度策略。该策略可以感知模型在不同阶段的冻结情况，根据各阶段的冻结情况，调整模型的划分策略；同时结合冻结特性，检测冗余的计算和通信操作并且直接丢弃，提高多卡流水线的有效算力利用率与训练吞吐。

1.3.2 HR-MMoH: 多模态大语言模型在异构 GPU 集群上的重计算

激活检查点（重计算）通过在前向时丢弃部分中间激活、在反向时按需重算，以计算换显存，是支撑大模型与 MLLMs 在有限显存下训练的重要手段。然而，现有重计算策略多采用全局统一的配置（如对全部层或按固定间隔插入检查点），未考虑异构集群中设备间显存与算力的差异：显存紧张、算力相对充裕的设备适合更激进的检查点以释放显存；显存宽裕、算力紧张或通信繁忙的设备则不宜过度重算，否则会加重计算或通信瓶颈。此外，MLLMs 各子模块（Encoder、LLM、Projector、Generator）的层数、每层激活体积与计算量各不相同，在同一设备上对不同模块采用相同检查点策略也难以达到最优。

本课题针对上述不足，提出一种面向异构设备与异构模型的重计算优化方法。该方法在给定层级划分与设备映射的基础上，以各设备的显存上限、算力及通信负载为约束，为不同设备上的不同模型阶段分别搜索或配置差异化的检查点策略（如检查点插入的粒度与密度），在满足显存不溢出的前提下，最小化因重计算带来的额外时间开销，并兼顾流水线不同流水级的负载均衡。通过将重计算与前述的复合粒度划分、流水线调度相结合，实现计算、存储与通信在异构环境下的联合优化，进一步提升 MLLMs 在异构 GPU 集群上的训练效率。

1.4 论文组织结构

本论文共分为五章，具体结构如下：

第一章为绪论。主要阐述面向异构 GPU 集群的 MLLMs 并行训练的背景与意义，剖析当前面临的技术挑战，并概述本文的研究内容与核心贡献。

第二章为相关工作。从 MLLMs 架构特点、分布式训练基础、异构 GPU 并行策略以及重计算优化等方面梳理现有研究的发展脉络与局限性。

第三章介绍本文提出的 MMoH 框架，重点阐述需求驱动的设备拓扑识别、复合粒度模型抽象、冻结感知划分及提前终止流水线调度方法，并给出实验评估。

第四章介绍 HR-MMoH 异构重计算优化，详细说明如何在异构计算资源与不同模型模块间实现检查点策略的细粒度自适应配置。

第五章为总结与展望。对全文工作进行回顾，并探讨后续可能的研究方向。

第二章 相关工作

本章从多模态大语言模型架构与训练、并行与分布式训练基础、异构 GPU 集群并行训练策略以及重计算优化等方面对国内外相关研究进行综述。本章内容旨在论证如下观点：模型的模块化设计与分阶段训练深刻改变了其计算图与显存分布；尽管混合并行与重计算等显存优化技术已被广泛应用，但在面临集群硬件异构性与 MLLMs 独有的模块异构时，现有同构导向的策略仍暴露出明显的局限。

基于 Transformer 的大语言模型在自然语言处理 [6, 7]、图像识别 [8, 9]、多模态理解与生成 [10, 12] 等众多领域取得了显著进展；多模态大语言模型（MLLMs）在此基础上融合视觉、语言与生成模块，成为当前研究的热点之一。性能提升与规模扩展紧密绑定：扩展定律（Scaling Law）[27] 表明模型性能随参数规模与数据规模提升而持续改善，工业界与学术界因此不断推动模型参数量与训练数据量的增长，单设备在显存与算力上已无法容纳完整模型与训练流程 [1]，并行与分布式训练成为训练大模型与 MLLMs 的必由之路。目前，以数据并行、张量并行、流水线并行及零冗余优化器（ZeRO）等为代表的并行策略已被广泛应用于千亿级参数模型的训练 [37, 41, 42]，但上述框架在设计时多假设同构 GPU 集群与统一的设备拓扑，对实际环境中普遍存在的设备与网络异构考虑不足。

由于硬件迭代与采购周期等因素，实际部署的计算集群往往混用多代、多型号的 GPU，导致显存容量、算力与互联带宽呈现高度异构性 [54, 55]。在此类异构环境下，若直接套用基于同构假设设计的并行策略，极易造成负载失衡与通信拥塞，不仅拉低了整体训练效率，也制约了可用资源的规模扩展；而 MLLMs 内部各模块（Encoder、LLM、Projector、Generator）在结构与参数量上的悬殊差异，及其分阶段冻结的训练设定，进一步加剧了系统级优化的难度。

因此，本章首先介绍 MLLMs 的架构组成、训练数据特点与多阶段训练范式；随后梳理数据并行、张量并行、流水线并行等并行策略及 ZeRO 系列优化等分布式训练基础；进而探讨现有异构 GPU 集群并行训练方法的研究进展及其适用边界；最后评述重计算等显存换计算技术的当前状态。通过上述梳理，揭示现有工作在应对异构 MLLMs 训练时的不足，从而为后文 MMoH 与 HR-MMoH 的提出奠定基础。

需要说明的是，并行与分布式训练领域文献浩繁，本章重点聚焦与本文工作直接相关的几个切入点：多模态大语言模型的组件差异与其特有的多阶段训练范式，共同决定了其动态且高度不均衡的计算资源需求；数据并行、张量并行、流水线并行及 ZeRO 构成了解决大规模训练的基石；面对实际生产中普遍存在的集群异构性，如何通过智能化的负载均衡与任务调度来突破单点瓶颈，逐渐成为学

术界与工业界关注的焦点；同时，以重计算为代表的显存优化技术在异构场景下具备与其他调度策略深度融合的潜力。上述各维度的探讨，旨在为后续章节提出的优化算法提供理论与实践层面的依据。

2.1 多模态大语言模型

2.1.1 多模态大语言模型的异构架构

多模态大语言模型（MLLMs）将视觉、语言与（可选）生成能力统一到以大规模语言模型为核心的异构架构中，其典型组成如图1.1所示，主要包括以下几类模块。

Modality Encoder 负责将图像、视频、音频等非文本输入编码为高维特征表示，以便与语言模型的词嵌入空间对接。实践中多采用在大规模图文或视频等多模态数据上预训练好的视觉模型作为编码器：CLIP[10] 通过对比学习实现开放词汇的视觉表征，被 LLaVA[13]、MiniGPT-4[19] 等广泛采用；ViT[8] 及规模化变体 [9] 则将图像切分为 patch 后经 Transformer 编码，在 Flamingo[14]、InternVL[18] 等工作中用作视觉 backbone。InternVL[18] 将视觉基础模型规模扩展至 60 亿参数，并在多图、长文本与文档理解上取得领先；Qwen-VL[17] 支持百万像素级高分辨率与多轮对话，在 DocVQA、ChartQA 等基准上表现突出。编码器输出通常为序列形式的特征，再经后续模块映射到 LLM 空间；从而完成视觉等其它模态数据与语言模型的对齐的第一步 [90]。

Input Projector 将编码器输出的多模态特征映射到与 LLMs 词嵌入维度与语义空间对齐的表示，使 LLMs 能够将视觉等信息与文本统一处理。常见实现包括线性层、轻量 Transformer 层等，以及 BLIP-2[12] 提出的 Q-Former（通过可学习的 query 从编码器特征中抽取与任务相关的表示）；InstructBLIP[15] 在此基础上引入指令感知的 Q-Former，根据用户指令从图像中抽取与任务更相关的特征，在 ScienceQA 等零样本任务上显著优于 BLIP-2。该模块参数量远小于 LLM，常与编码器一起在预训练或对齐阶段更新。

LLM Backbone 即大规模语言模型主体，承担主要的语言理解与生成计算，参数量通常占整个 MLLM 的 80%–90%[12, 13]。基座模型多选用已在海量文本上预训练好的 Transformer 模型，如 GPT 系列 [4, 6]、LLaMA[34]、T5[5] 等；在资源受限或强调高效微调时，常对 LLMs 进行冻结或仅微调部分层。

Output Projector 与 **Modality Generator** 用于多模态生成任务（如图生图、文生图、文生视频、文生音频等）：前者将 LLMs 的输出映射到生成器可接受的表示空间，后者根据该表示生成图像、视频或音频。生成器多采用扩散模型，如 Stable Diffusion[59] 中基于 U-Net[60] 的潜在扩散结构；Next-GPT[61]、DreamLLM[62] 等

工作在此基础上实现了任意模态到任意模态的生成与转换。

BLIP-2[12] 率先系统性地采用“冻结 Encoder + 冻结 LLM + 仅训练轻量 Projector”的范式，在显著降低训练成本的同时达到与全参数微调可比的效果，后续多数 MLLMs 均沿用或发展此类设计。这种模块异构（编码器、投影层、LLM、生成器在结构、参数量与计算特性上差异显著）与分阶段冻结策略，使得在异构 GPU 集群上为各模块分配合适的算力与显存、并设计均衡的并行与调度策略变得尤为困难。

从实现角度看，编码器多为卷积或 ViT 类结构，单层计算与显存占用与 Transformer 解码层不同；投影层参数量小、计算密集度高，在流水线中若与 LLMs 层混合划分，易造成流水级间负载不均；LLMs 主体层数多、激活体积大，常需配合激活检查点与张量并行以控制单卡显存。生成器（若存在）多为 U-Net 或扩散结构，其前向与反向计算模式与语言模型差异较大。因此，在设计面向 MLLMs 的并行与调度方案时，需要针对各子模块的特性分别建模计算、显存与通信，并考虑不同训练阶段下冻结比例变化带来的动态负载差异，而不能简单套用单一 Transformer 的划分假设；这也为本文第三、四章中针对各模块与冻结状态的细粒度划分与调度提供了直接动机。

2.1.2 多模态大语言模型训练数据

扩展定律（Scaling Law）[27, 28] 表明，模型性能随训练数据规模与模型参数规模的提升而持续改善；Chinchilla[28] 进一步指出，在计算最优意义下，模型参数量与训练 token 数应近似同比例扩展，后续工作 [29] 从推理成本角度拓展了最优数据—模型比例。由此可推知，在给定算力预算下，若要逼近 Pareto 前沿的性能，就必须同时扩大数据规模与模型规模；因此工业界与学术界在预训练与微调阶段均倾向于使用尽可能大的数据与模型。大语言模型通常在海量文本语料（如 Common Crawl、The Pile[75]、书籍与代码）上预训练，规模可达数万亿 token。多模态大语言模型在此基础上还需大规模图文对、视频—文本对等多模态数据，用于模态对齐、指令微调与多模态生成等阶段；由于上述各阶段均依赖大规模监督或多模态配对数据，数据量与存储需求在文本预训练的基础上进一步放大。多模态理解与推理的评估常采用 MMMU[26] 等跨学科基准 [72]，其题目与数据形态的多样性也反过来推动训练数据在模态与任务类型上的扩展。

表2.1列举了若干代表性数据集的规模与用途。图像方面，Open Images[73] 包含约 900 万张图像及框注，存储需求约 18TB；JFT、LAION 等内部或开放图文对数据集规模可达数亿至数十亿样本，用于视觉—语言预训练。视频方面，YouTube-8M[76] 等基准包含数百万视频与标签，用于视频理解与生成的数据集往

往需要 PB 级存储与高吞吐的数据管线。文本方面，Common Crawl、The Pile 等为 LLM 预训练提供数万亿 token 的语料。综合上述规模可知，单机显存既难以容纳完整模型与优化器状态，单机存储与 I/O 带宽也难以在训练周期内高效供给全量数据；在这一双重约束下，并行训练（数据并行、模型并行及其组合）成为必然选择。与此同时，数据规模与模型规模的持续增长，对并行策略的 I/O 效率、通信拓扑与异构集群下的数据供给能力提出了更高要求 [1]。

表 2.1 多模态大语言模型训练中常用的部分数据集规模示意

类型	规模量级	存储量级	典型用途
图像文本对	数百万 – 数十亿	TB–PB	图文预训练、对齐（如 Open Images[73]）
视频	数百万 – 数亿	百 TB–PB	视频理解、生成（如 YouTube-8M[76]）
文本 / 语料	数百亿 – 数万亿 token	PB 级	LLM 预训练、指令数据

2.1.3 多模态大语言模型训练过程

多模态大语言模型的训练通常采用多阶段、分模块的策略，在不同阶段设定不同的训练目标与可训练参数集合，以兼顾效果与成本 [12, 13]。各阶段的先后顺序遵循从粗粒度对齐到细粒度能力塑造的递进关系：典型阶段包括（1）模态对齐（或预训练），在大规模图文对或视频—文本对上训练 Input Projector（及可选的部分 Encoder/LLM），使视觉等特征与 LLM 语义空间对齐；（2）指令微调（Instruction Tuning），在高质量指令—回答数据上微调，以提升遵循指令与对话能力，此时常冻结 Encoder、仅微调 Projector 与 LLM 部分层；（3）多模态生成微调（若需文生图等），在生成数据上训练 Output Projector 与 Modality Generator，LLM 可冻结或低秩微调。各阶段对“谁冻结、谁更新”的设定不同，因而在同一模型上，不同阶段对应不同的有效计算图与显存、算力需求分布；换言之，模块异构在时间维度上表现为阶段依赖的、动态变化的负载形态。实践中，各阶段采用的典型超参与数据规模因模型与任务而异：LLaVA[13] 在约 60 万图文对上做视觉—语言对齐与指令微调；InstructBLIP[15] 在 13 个指令化数据集上微调；Qwen-VL[17]、LLaVA-NeXT[91] 等则进一步扩大指令数据与上下文长度；闭源多模态模型如 Gemini[92]、PaLM[93] 系列则在更大规模数据与算力下完成预训练与对齐，其具体数据配比与阶段划分多未完全公开。

冻结会显著改变各模块的反向计算量与显存占用。其原因是：冻结参数不参与梯度计算与更新，因而不需为其保存梯度或中间激活用于反向；优化器状态（如

Adam 的动量与方差) 仅需为可训练参数维护, 故冻结比例越高, 单步显存与计算量通常越低, 但可调表达能力也越受限 [12]。在流水线并行或层级划分下, 若某流水级被冻结, 其对应设备上的反向计算远少于未冻结阶段, 容易造成流水级间负载不均与流水线气泡。在异构 GPU 集群下, 设备间本就存在显存、算力与带宽差异; 训练阶段与冻结策略带来的动态模型异构 (即同一模型在不同阶段呈现不同的有效计算与显存分布) 与设备异构叠加, 使得静态的、一次性确定的划分与调度难以在各阶段均接近最优, 进一步增加了并行策略设计调优的难度。因此, 一种能够随训练阶段与冻结状态自适应调整划分与调度的方案具有明确价值, 也是本文 MMoH 设计的目标之一。

图2.1概括了上述多阶段训练中常见的模块冻结与更新关系, 便于理解不同阶段对算力与显存的需求差异。

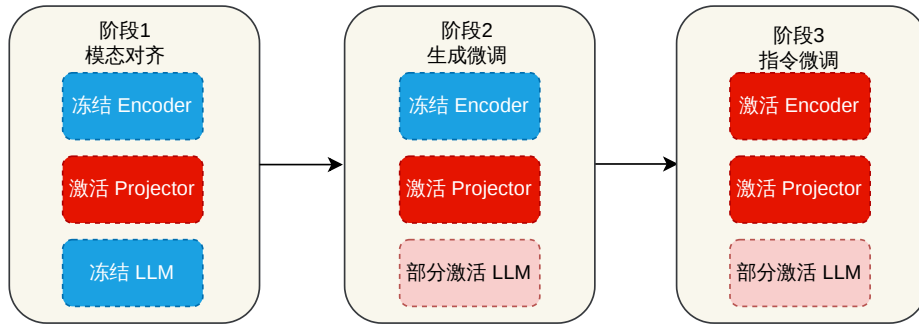


图 2.1 MLLM 多阶段训练中典型模块冻结与更新关系示意

2.2 并行与分布式训练基础

2.2.1 数据并行与模型并行

数据并行 (DP)。 数据并行将训练数据在各计算设备间划分, 每个设备持有一份完整模型副本, 本地前向传播与反向传播后通过梯度 All-Reduce 等通信同步参数 [43, 44, 94]。如图2.2所示, 各设备独立计算所分配 mini-batch 的梯度, 再在迭代末聚合梯度并更新一致参数。DP 实现简单、扩展性好, 是 PyTorch DDP[43]、Horovod[44] 等框架的默认方式; PyTorch 的 FSDP[53] 在数据并行基础上对参数、梯度与优化器状态进行分片, 与 ZeRO-3 思路相近, 可在单卡显存受限时支撑千亿级稠密模型训练; Parallax[95] 针对稀疏与异构场景对参数服务器与 All-Reduce 做了灵活选择。其局限在于单卡需容纳完整模型与优化器状态 (DP) 或需额外通信聚合分片 (FSDP), 无法单独支撑超大参数规模, 常与张量 / 流水线并行或 ZeRO 组合使用。




图 2.2 数据并行示意

张量并行 (TP) 与序列并行 (SP)。 张量并行在层内划分权重与计算，使多设备协同完成单层的前向与反向，组合后等价于完整层 [37, 38]。如图2.3所示，每设备仅持有部分参数与激活，层间通过 All-Gather/Reduce-Scatter 等通信传递激活与梯度。Megatron-LM[38] 针对 Transformer 提出按行 / 列交替划分 FFN 与注意力权重，在减少同步次数的同时控制通信量；GShard[47] 在 MoE 中结合张量并行与专家划分。TP 通信密集且对带宽敏感，实践中多限于单节点或高带宽拓扑内，并与流水线、数据并行组合 [37]。序列并行 (SP) 针对长序列场景，将输入沿序列维划分到多卡，每卡仅处理一段子序列，通过通信在注意力等层交换信息以保持语义一致 [80, 96]。DeepSpeed-Ulysses[96] 将序列均匀分片，在注意力处采用两阶段 All-to-All 重分布，使通信量随序列长度与设备数成比例缩放，支持百万级 token 训练；Megatron 中的实现常与张量并行共用进程组，与 TP、PP、DP 组合构成多维混合并行 [80]。




图 2.3 张量并行示意

流水线并行 (PP)。流水线并行在层间划分模型，每设备持有若干连续层构成一个流水级，如图2.4所示。GPipe 使用多个 micro-batch 依次流过各流水级以重叠计算、降低空闲 (bubble) [45]。PipeDream[46] 提出 1F1B (1 Forward 1 Backward) 等异步调度进一步压缩空闲；TeraPipe[97, 98] 在序列内做 token 级流水线，实现更细粒度的层间并行。Chimera[99] 采用双向流水线减少气泡；Hanayo[100] 等波式调度进一步优化多流水级下的计算重叠。近年来，**ZeroBubble**[101] 在同步语义下将反向拆分为“对输入的梯度”与“对参数的梯度”两阶段，结合 1F1B1W 等调度与参数更新重叠，实现了近似零 bubble，在相同显存下相较 1F1B 提升吞吐约 23%–31%；**DualPipe**[102] 采用双向 micro-batch 流动与前后向重叠，在 DeepSeek 等超大规模训练中用于降低 bubble 与通信压力。PP 通信量相对较小，适合跨节点扩展，常与节点内 TP、全局 DP 组合 [38]。上述并行方式降低了单机负载与通信压力，但单机显存仍可能成为瓶颈；下文介绍的零冗余优化器 (ZeRO) 系列正是针对显存分片与优化器状态而提出，与 DP/TP/PP 组合后构成当前大模型训练的主流栈。长序列场景下，Ring Attention[103] 等通过块状 Transformer 与环形通信在有限显存内支持近无限上下文，与 PP、SP 形成互补。




图 2.4 流水线并行示意

上下文并行 (CP) 与专家并行 (EP)。上下文并行 (CP) 在如今模型输入越来越长的场景下得到了广泛应用：单卡显存难以容纳全长序列的激活时，将输入沿序列维划分到多卡，在注意力等层通过通信交换信息以保持语义一致，与张量并行共用进程组的序列并行 (Sequence Parallelism) 不同，上下文并行把模型输入在序列维度做切分，不同的序列块使用不同的 GPU 进行计算，称为 Context Parallelism (CP) [80]。CP 在 8K+ token 场景下显存收益显著，但会引入额外通信与拓扑约束，需与 Flash Attention、激活检查点等配合使用。专家并行 (EP) 针对混合专家模型 (MoE)：不同 token 由不同子网络 (专家) 处理，EP 将完整专家分布到不同设备，每设备仅持有部分专家权重，前向时根据路由将激活发送至对应专家所在设备，再汇总结果 [47]。与张量并行 (每设备持所有专家的部分权重) 不同，EP 下每设备只存部分专家的全量权重，通信模式为 All-to-All 的 token 重分布，适合专家数

多、单专家规模适中的 MoE。GShard[47] 将 MoE 与张量并行结合并做自动分片；DeepSeek-MoE[104] 等在有限资源下通过 MoE 扩展语言模型规模；DualPipe[102] 等也在流水线中结合专家并行以支撑超大规模 MoE 训练。EP 的主要挑战是专家负载不均与路由带来的通信开销，需高带宽互联与负载均衡设计。图2.5展示了专家并行中的典型路由过程：门控网络先为 token 选择 Top- k 专家，再通过 All-to-All 将 token 分发到对应 GPU 上的专家执行计算，最后汇聚结果返回主干网络。




图 2.5 专家并行（EP）中门控路由与专家分布示意

2.2.2 零冗余优化器（ZeRO）

ZeRO[41, 42] 在数据并行基础上，将优化器状态、梯度与参数分片存于各卡，前向与反向时按需聚合，在保持 DP 通信量的前提下显著降低单卡显存，使千亿级训练可行。如图2.6所示，ZeRO 三阶段分别分片优化器状态、梯度与参数；ZeRO-Infinity[42] 进一步将部分状态卸载至 CPU/NVMe 以突破 GPU 显存墙。ZeRO++[48] 通过量化与通信重算减少跨节点通信量；MiCS[87]、AMSP[88] 等在云环境与统一划分空间上做了扩展。ZeRO-3 与张量并行、流水线并行的组合在工程上存在约束（如 DeepSpeed 与 Megatron 的 3D 并行通常采用 ZeRO-1/2 与 TP+PP），需根据框架与集群拓扑谨慎配置 [105, 106]，在实际部署中需在显存节省、通信开销与实现复杂度之间权衡。在注意力与激活显存方面，Flash Attention[51] 通过分块计算与 IO 感知将注意力显存从序列长度平方降为线性，FlashAttention-3[52] 在 H100 上进一步通过异步计算与低精度达到更高利用率。ZeRO 与 TP、PP、SP 等组合构成当前大模型与 MLLM 训练的主流基础设施。




图 2.6 零冗余优化器 ZeRO 示意

2.3 异构 GPU 集群并行训练策略

实际部署中，高校、企业与云平台往往无法配备全同构的 GPU 集群：设备多代共存（如 A100 与 V100、H100 混用）、显存容量从数十 GB 到 80 GB 不等、算力与互联带宽差异显著。在此类异构环境下，直接套用面向同构集群设计的并行训练框架，通常会引发三个层面的系统性问题。存储异构方面，传统策略多假设各卡显存一致，按均匀方式划分模型与激活，导致大显存设备利用率不足而小显存设备易发生 OOM，制约扩展性。算力异构方面，同步式并行要求各设备步调一致，最慢设备成为瓶颈，产生“木桶效应”，整体算力利用率与训练吞吐下降。网络异构方面，集群常存在多级互联（节点内 NVLink、节点间 InfiniBand 或以太），不同链路带宽与延迟差异大，跨节点通信易成为瓶颈。针对异构 GPU 集群并行训练的方法逐步成为近年来的研究热点，下文将梳理代表性工作及其应用局限。这些工作从不同角度缓解了异构带来的负载不均与 OOM 风险，但多数仍以通用 LLMs 或粗粒度划分为前提，对 MLLMs 的模块异构与分阶段冻结的适配仍显不足。

HetPipe[55] 较早将流水线并行与数据并行结合以利用异构集群。其将多个 GPU 组织为虚拟工作节点（VW），在 VW 内采用流水线模型并行（PMP）处理小批量，在 VW 间采用数据并行提升可扩展性。通过将“弱”设备与“强”设备搭配成 VW，在一定程度上缓解了单机算力不足的问题。然而，HetPipe 未显式建模 VW 内部的异构设备排列与通信拓扑，对通信与显存开销的估计较为直观，且未考虑模型异构（如 MLLM 中 Encoder、Projector、LLM 模块结构各异、冻结策略不同），在当今多模态大语言模型与分阶段训练场景下适用性有限。

Whale[54] 针对显存与算力异构，提出基于硬件感知的负载均衡方法。通过刻画各 GPU 的存储与算力差异，Whale 按比例对各设备分配不同大小的批次与模型分片，在数据并行与张量并行下实现计算与显存负载的均衡。其思路对“大卡多算、小卡少算”的配置有参考价值。但 Whale 未考虑网络异构，且存储 / 算力均衡策略相对直观，划分与编译粒度停留在子图级别，未与 ZeRO 等显存优化结合，在超大规模与多维度异构并存时仍有优化空间。

AMP[81] 在异构环境下为大模型自动寻找并行策略。AMP 同时考虑模型异构（不同层结构、参数量与计算量）与设备异构（GPU 显存、算力、网络），对层间差异进行抽象与建模，对集群内存储与网络异构进行近似量化，在此基础上基于 3D 并行（DP+TP+PP）设计开销模型（Cost Model），并用动态规划求解近似最优的并行配置。实验表明其在异构场景下相较基线有明显提升。不足在于：划分粒度为全局粗粒度，开销模型对通信与显存估计的准确性有限，且未显式约束显存上界，实际部署中易出现 OOM，仍需与显存预算和重计算等联合考虑。

近年来，面向大模型在云上与异构集群中训练的资源调度与配置规划工作受到关注。Espresso[84] 是一种面向成本效益的异构 GPU 资源供给与阶段放置框架，面向大规模模型训练场景。Espresso 集成四大模块：*Profiler* 分析不同层在异构 GPU 上的迭代时间与显存占用；*GPU Allocator* 负责异构 GPU 的分配；*Stage Placer* 确定流水线等并行策略下的阶段放置；*Performance Estimator* 预测给定配置下的训练性能。用户可指定模型、数据集、训练轮数与 SLO（服务等级目标），由系统自动给出资源分配与 stage 放置方案，从而在异构环境中兼顾成本与效率。Espresso 为异构集群上的大模型训练提供了从分析到配置的一体化思路，其与 ZeRO、流水线气泡优化及 MLLM 模块异构的结合仍可进一步探索。

HetHub[82] 面向多厂商异构 GPU 集群（如华为昇腾、AMD 与 NVIDIA 的计算卡混合），引入分布式统一通信器、性能预测器与自动并行规划，在 768 张异构卡（128 张 AMD + 640 张 A 系列）上训练 Llama-140B 达到理论性能上界的 97.49%，验证了异构集群训练大模型的可行性。HexiScale[83] 将数据、流水线与张量并行的非对称划分形式化为约束优化问题，采用层次图划分算法为异构 GPU 分配计算，在 7B–30B LLM 上取得与同构系统相当的 MFU（平均差距约 3.5%），为“按设备能力非对称划分”提供了系统化方法。

Zorse[85] 则直接针对异构 GPU 集群上的 LLM 训练效率优化。其指出，在异构集群上高效训练需要：（1）将流水线并行与数据并行以通信与显存高效的方式结合；（2）支持更灵活的配置，包括将 GPU 灵活划分为非对称的流水线阶段、在同一数据并行组内容纳异构 GPU。Zorse 实现了上述能力的统一，并配备自动规划器，根据工作负载自动生成训练配置。实验表明在异构场景下相较现有系统有

显著提升。Zorse 与 Espresso 等工作的出现，反映了社区对异构环境下大模型训练系统化方法的需求，二者在 MLLMs 多模块、分阶段冻结训练等场景下的适配问题仍亟待解决。

此外，与 ZeRO 系列相关的工作在异构场景下也存在局限。ZeRO[41, 42] 的梯度 / 参数 All-Gather 等通信在跨节点异构网络中易成为瓶颈；MiCS[87] 对模型规模与异构网络下的高带宽链路利用仍有不足；ZeRO++[48] 的量化与通信重算在带来收益的同时可能引入精度与通用性代价；AMSP[88] 等侧重跨节点通信削减，对集群内存储、算力与带宽的细粒度异构利用仍有限。综合来看，现有异构并行与 ZeRO 类方法多针对通用 LLM 或同构假设下的扩展，对多模态大语言模型的模块异构、分阶段冻结与显存—算力—通信三重异构的联合优化仍不足，为本文面向异构集群的 MLLMs 高效训练与调度研究留下了空间。

从系统实现角度，将上述思路落地还需解决若干工程问题：异构设备上的性能预测与开销建模、与 Megatron/DeepSpeed 等现有框架的集成方式、以及多阶段训练下划分与调度策略的自动或半自动生成。Frenzy[64] 等面向内存感知的 serverless 调度在异构环境下可辅助资源与阶段放置；部分工作 [84, 85] 已开始提供从分析到配置的一体化工具，但在 MLLM 的模块级划分、冻结感知调度与重计算的联合优化方面仍缺少系统化方案，这也是本文 MMoH 与 HR-MMoH 设计所要弥补的不足。

2.4 重计算显存优化技术

大规模模型与长序列训练中，前向传播产生的中间激活（activation）需在反向传播时用于梯度计算，若全部保存则显存占用随层数与序列长度线性甚至平方增长，成为训练瓶颈。重计算（Recomputation，又称激活检查点（Activation Checkpointing））通过“以计算换显存”的思想，即前向传播时仅保存部分激活或仅保存检查点处的输入，反向时对未保存的区域重新执行前向传播以得到所需激活值，如图2.7所示，从而在显存与计算之间进行权衡，是缓解显存压力的常用手段 [107]。根据检查点放置的粒度和策略，可大致分为全部重计算、选择重计算与细粒度重计算三类；以下分别简述其思路与适用场景。

全部重计算。 全部重计算（full recomputation）策略在前向阶段不保存任何中间激活，仅在若干“检查点”层保存该层的输入（或仅保存网络输入），反向传播需要某段中间激活时，从最近的检查点重新执行前向至该位置再计算梯度。极端情况下仅保存网络输入，则显存占用可降至与深度无关的常数级别，但反向传播需对整网做一次完整前向重算，计算开销约增加前向传播的一倍。Chen 等 [107] 针对链式计算图证明了在仅增加一次额外前向的前提下，通过动态规划可求得检查




图 2.7 重计算（激活检查点）示意

点的最优放置，使显存从 $O(n)$ 降为 $O(\sqrt{n})$ (n 为层数)，并在千层残差网络等实验中实现了显存的大幅下降（如 48 GB $\rightarrow$ 7 GB）与约 30% 的训练时间增加。全部重计算实现简单、显存收益最大，适合显存极度紧张、算力相对充裕的场景，但计算冗余较高。

选择重计算。 选择重计算（selective recomputation）不是对整个 Transformer 层统一做 checkpoint，而是只对显存占用大但重算代价相对较低的部分子模块执行重算，未选部分仍正常保存激活。Korthikanti 等 [108] 在大规模 Transformer 中提出的 selective activation recomputation 即属于此类：其核心思想是优先重算注意力中的 QK^T 、softmax、dropout 以及与 V 的乘法等中间激活，因为这些张量随序列长度和注意力头数增长较快，但额外 FLOPs 开销相对有限。相较整层重计算，该策略的显存收益略小，但能显著降低重算开销；论文报告其总时间开销约为 7%，明显低于整层重算的 39% [108]。在工程实现上，Megatron-LM 与 NeMo 将其落地为 selective 粒度，默认仅重算 core_attn，也可扩展到 mlp、moe、layernorm 等指定子模块 [109, 110]。

细粒度重计算。 细粒度重计算（fine-grained recomputation）在算子或更小粒度上决定哪些激活保存、哪些重算，从而更精细地利用不同算子的计算—显存特性。与上一段“选择重计算”主要回答“哪些模块需要重算”不同，细粒度重计算更关注“如何在模块内部重算”。例如，Transformer 中可不把整个注意力或 MLP 作为单一单位处理，而是进一步细化到 LayerNorm、dropout、MoE 激活函数、或某些投影输出等中间张量：前向时仅保留最少输入或元数据，反向时再局部恢复需要的结果。Megatron-LM/NeMo 中的 output-discarding checkpoint 就体现了这种思路：它并非简单地把整段前向再执行一遍，而是在前向后主动丢弃部分输出张量的存储，在反向阶段借助 hook 触发局部重算，从而进一步压缩激活占用 [109, 110]。这类方法比“按层”或“按子模块”的重计算更贴近实现细节，能够利用不同算子的显存占用、通信需求与 FLOPs 差异做更细致的权衡。Lynx [111] 进一步将激活重算与通信重叠调度，在 1.3B–23B GPT 模型上相较现有方法取得最高约 $1.37\times$ 的加

速，表明细粒度重算若与通信、并行调度协同设计，还可以同时改善显存效率与训练吞吐。细粒度策略可结合模型结构（如 MLLMs 中 Encoder、Projector、LLM 各模块的算子组成）与异构设备的显存、算力差异，在不同设备或不同 stage 上采用不同的检查点粒度，是面向异构集群与 MLLM 的潜在优化方向。

在 Megatron-LM 与 NeMo 等框架中，重计算被实现为可配置的多级粒度。全部重计算（full）以整个 Transformer 层为粒度：检查点保存每层输入，反向时重算整层前向，显存下降显著但单层计算约增加 30%。框架进一步提供两种全层模式：*block* 模式通过参数指定每个流水线 stage 内参与重计算的层数，可仅对部分层做检查点以在显存与计算间折中；*uniform* 模式以连续多层的“块”为重计算单位，块内仅存块首输入，适用于层数很多或层间激活相对较小的模型，可节省激活显存但会增加重算缓冲。选择性重计算（selective）则仅在子模块级别重算：例如仅对自注意力块做检查点与重算（保存注意力块输入，重算 softmax、dropout、QKV 等中间激活），而 MLP 等不重算。自注意力激活随序列长度平方增长、占显存大头，但其重算成本相对线性投影层较低，因此选择性重算能以较小计算代价获得较高显存收益；用户还可指定 `core_attn`、`mlp`、`moe` 等模块是否参与重算。在使用 Flash Attention 时，框架通常强制对注意力做选择性重算以配合其显存布局。上述多级粒度（全层 *block/uniform*、子模块 *selective*）为实际训练中按显存预算与算力调节检查点策略提供了细粒度控制，与 Korthikanti 等 [108] 的序列并行与选择性激活重算相结合，已广泛应用于大规模 Transformer 与 LLM 训练。然而，现有检查点策略多面向同构设备设计：重计算层数、块大小、参与重算的子模块等均需用户或策略脚本手动指定，且通常假设各设备显存与算力一致，无法根据异构集群中不同设备的显存余量与算力差异自动调节（例如在显存紧张设备上加大重算比例、在算力瓶颈设备上减少重算）。

将重计算与流水线并行、stage 划分及异构分配结合，可进一步缓解显存瓶颈并提升整体吞吐：例如在流水线各 stage 内独立设置检查点策略，或在显存紧张的设备上采用更激进的重计算、在算力紧张处适当多存以减少重算，但上述调节目前仍依赖人工或离线调参。Megatron-LM、NeMo 等支持按层或子模块（如 `core_attn`、`mlp`）配置选择性重算 [109, 110]；Colossal-Auto[50, 112] 等将自动并行策略搜索与激活检查点统一自动化，为大规模模型与异构环境下的联合优化提供了参考；在异构 GPU 集群上，针对 MLLM 的模块异构与分阶段冻结，设计能自动适应设备异构的细粒度检查点策略仍是开放问题，也是本文后续工作方向之一。

2.5 本章小结

本章从多模态大语言模型、并行与分布式训练基础、异构 GPU 集群并行训练策略以及重计算优化四个方面对相关工作进行了综述。大模型训练系统的综述 [113, 114] 也从不同角度归纳了并行、显存与异构优化的发展脉络。首先介绍了 MLLM 的典型架构（编码器、投影层、LLM 骨干及可选生成器）、训练数据规模与训练目标，以及模块异构与分阶段冻结带来的计算—显存需求差异。随后综述了数据并行、张量并行、流水线并行、序列并行与专家并行等多维混合并行方式，以及 ZeRO 系列显存分片优化，指出其同构假设下的广泛应用与在异构、模块异构场景下的局限。接着讨论了异构 GPU 集群上显存、算力与通信的异构性，以及 Whale、HetPipe、Espresso、Cephalo 等异构感知并行与调度工作的思路与不足，并指出 MLLM 的混合模块结构与冻结策略进一步增加了高效划分与调度的难度。最后介绍了重计算的基本原理与全层、选择重计算及细粒度重计算等实现方式，以及 Megatron-LM 等框架中的多级粒度配置，并指出现有检查点策略多面向同构设备、难以根据异构集群与 MLLM 各阶段需求自动调节。综合来看，MLLM 的模块异构与分阶段冻结、以及异构集群的显存—算力—通信差异，共同构成了现有同构导向并行与统一检查点策略难以直接应对的挑战。上述分析为本文第三章的 MMoH 框架（需求驱动拓扑、复合粒度划分、冻结感知划分与提前终止调度）与第四章的 HR-MMoH 异构重计算提供了问题背景与动机。

第三章 MMoH: 多模态大语言模型在异构 GPU 集群上的高效混合并行

第二章指出, 多模态大语言模型 (MLLMs) 在结构上由编码器、投影层与 LLM Backbone、解码器 (可选) 等异构模块组成, 训练时又广泛采用分阶段冻结的训练策略, 致使各层计算量与显存需求随模块类型与参数训练状态呈现显著差异; 在异构 GPU 集群上若直接沿用面向同构集群或传统大语言模型 (LLMs) 设计的并行策略, 易产生负载不均衡与资源利用率低下。针对上述问题, 本章介绍 MMoH (Multimodal large language model training on Heterogeneous clusters) 框架 [89]: 通过需求驱动的设备拓扑与复合粒度模型划分, 在异构集群上为 MLLMs 自动生成近似最优的模型划分和设备映射; 并引入冻结感知的提前终止调度器, 在冻结场景下识别并消除冗余的反向计算与流水级间通信, 在保证训练收敛性的前提下提升训练吞吐。本节首先给出问题背景与动机, 随后概述 MMoH 的整体架构与各组件职能。

3.1 引言

3.1.1 问题与动机

传统大语言模型由结构相同的 Transformer 层堆叠而成, 各层在计算开销 (即 FLOPs) 与显存占用上随层索引变化相对均匀, 因此面向 LLM 的异构并行方法 (如 Whale[54]、Espresso[84]) 多基于“层数”或“设备计算能力”或“设备显存大小”按比例将层划分至不同设备, 即可获得较为均衡的负载分布。这类方法在同构 GPU 集群上已经被证明是有效的: 当所有设备的算力与显存容量相近时, 只要保证每个流水级承担的层数大致相同, 即可在不做复杂优化的前提下获得接近线性加速比。

然而, 多模态大语言模型在架构上与之存在本质差异。如图 3.1 所示, 常用的 MLLMs 由三个模块构成: (1) 编码器 (Encoder), 负责将图像、视频等多模态输入编码为特征表示, 多采用视觉 Transformer 或轻量卷积网络; (2) 投影层 (Projector), 将编码特征映射至与 LLM 词嵌入空间对齐的语义空间, 常见形式为线性层或 Q-Former[12]; (3) LLM Backbone, 承担主要的语言理解与生成计算, 由参数量巨大的 Transformer 层组成 [12, 13]。编码器单层参数量与序列长度通常远小于 LLM Backbone, 投影层则为小型模块, 因此 MLLMs 各“层”在计算量与显存开销上的差异可达数十倍。在实际部署中, 研究者往往需要在由多代 GPU 混合构成的异构集群上训练这类模型, 不同节点之间不仅算力 / 显存比差异显著, 互

联带宽与通信延迟也存在明显不均，这进一步放大了“模块异构 + 设备异构”叠加带来的负载失衡问题。

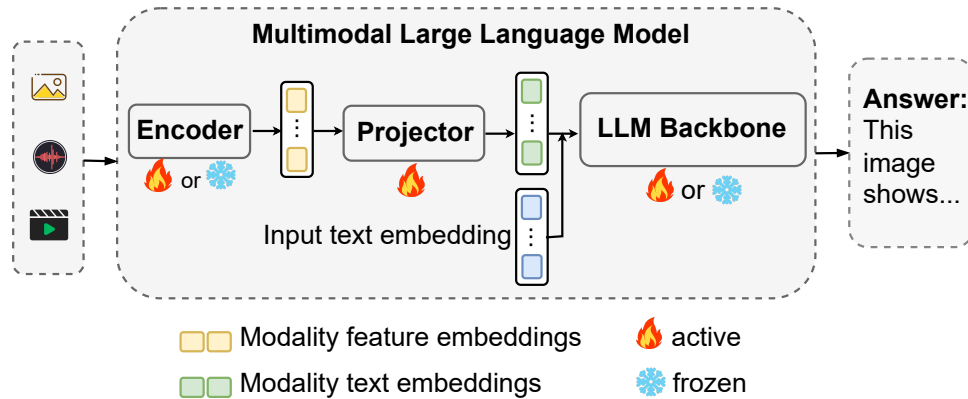


图 3.1 主流 MLLMs 的编码器—投影层—LLM 结构及冻结方式。

若仍采用与 LLM 相同的单一“层”粒度进行模型划分，将导致部分流水级过载而其他流水级空闲，无法达到负载均衡，整体迭代时间由瓶颈流水级主导，异构设备的算力与显存无法得到有效利用。图 3.2 对比了 LLM (LLaMA-3B) 与 MLLM-3B (见表 3.2) 在各层计算开销与显存占用上的变化趋势：LLM 各层较为均匀，而 MLLMs 随模块类型与冻结场景 (NF 表示不冻结，FB 表示编码器与 LLM 均冻结) 呈现显著差异。可以观察到：在编码器段，单层 FLOPs 与显存曲线整体处于较低水平，而在进入 LLM Backbone 后，相邻两层之间的计算量跳变明显，甚至在注意力块与 FFN 块之间也呈现出不同的计算—显存比；若简单地以“层数均分”作为划分准则，则很容易出现“前半段流水级几乎空载、后半段流水级长期处于饱和”的情况，导致流水线整体被少数几个高负载流水级所拖慢。

进一步地，异构环境下设备能力也呈现“阶梯状”变化：例如在由 RTX 3090、RTX 2080 Ti 与 RTX 2080 组成的集群中，不同型号 GPU 在算力与显存上的差异可达 2-3 倍以上。若不区分各模块对算力 / 显存的需求特征，而仅按照“设备总显存从大到小”或“TFLOPS 从高到低”的规则对设备进行排序并顺序映射流水级，则无法保证“高需求流水级被映射到高供给设备”，反而可能出现“轻量编码器被放置在高端 GPU、而重型 LLM 层被挤压到低端 GPU 上”的反直觉映射，进一步加剧负载不均衡。

另一方面，MLLMs 训练普遍采用冻结 (freeze) 技术 [12]：在预训练或模态对齐的训练阶段，仅更新投影层或部分 LLM 层，而编码器与 LLM Backbone 保持冻结，以利用已有预训练权重、降低过拟合并节省优化器状态与显存。冻结后，冻结参数不参与梯度计算与参数更新，对应流水级的反向计算量与梯度同步开销显著降低，其计算—显存需求与“全参数训练”时截然不同。现有异构并行策略大多




图 3.2 LLM 与 MLLM-3B 各层计算开销与显存占用的变化趋势 (NF 为不冻结, FB 为 freeze-both)。

假设所有参数在整个训练过程中均处于激活状态, 无法随参数训练状态 (冻结与激活) 的动态变化而调整划分与调度; 在“仅冻结编码器” (freeze-encoder)、 “仅冻结 LLM” (freeze-LLM) 或 “同时冻结编码器与 LLM” (freeze-both) 等场景下, 若继续采用为“全参数激活”场景设计的策略, 相较针对当前冻结状态专门优化后的策略, 迭代时间可落后约 13%–21%[89], 如图 3.3 中不同策略在两种冻结场景下的迭代时间对比所示。这意味着, 在多阶段训练流程中, 同一组设备拓扑与模型划分方案很难在所有阶段都保持近似最优: 在早期“仅训练投影层”的阶段, 编码器与大部分 LLM 层几乎不产生梯度同步与参数更新, 若仍然为其预留与 no-freeze 阶段相同的显存与计算预算, 就会造成大量资源浪费; 而在后期逐步解冻 LLM 层时, 若不重新规划流水级划分与设备映射, 又会重新暴露出负载瓶颈。

在工程实践中, 这种不匹配通常表现为两个方面的痛点: 一是人工调参成本极高。开发者需要针对不同冻结策略、不同 batch size 与序列长度, 不断尝试手工划分与映射方案, 通过反复试错来避免 OOM 并兼顾吞吐, 这在规模较大的异构集群上几乎难以维护; 二是训练过程中的策略缺乏自适应性。一旦训练开始运行, 出于实现复杂度与稳定性考虑, 现有系统很少在中途重新划分流水级, 从而错失了在“冻结—解冻”阶段切换时重新平衡负载的机会。

此外, 根据实验结果可知, 最优的并行策略并非静态不变, 而是随训练流水级中冻结状态的演变而动态调整, 而需随训练流水级中冻结状态的演变而动态调整, 现有工作尚未系统考虑该需求, 所以不能在冻结场景下取得最优性能。

从形式化角度, 可将上述挑战概括为两类约束。**多模态大模型在异构设备上的负载不均衡**: 设各流水级的迭代时间为 $t_1, \dots, t_s$, 在同步流水线下一轮迭代时间由 $\max_j t_j$ 决定, 若划分不当则瓶颈流水级拉高整体时间, 其余设备空闲, 从而




图 3.3 不同并行策略在两种冻结场景下训练 MLLM-3B 的迭代时间，MMoH1/MMoH2 为 MMoH 规划器针对各场景得到的策略。

无法充分利用异构设备上的算力与显存；多阶段冻结训练导致的最优并行策略动态变化：记冻结流水级集合为 $\mathcal{F}$ ，则 $\mathcal{F}$ 内流水级的反向传播的时间会减少，梯度同步开销近似为零，而未冻结流水级仍需完整反向与 P2P 通信，若划分与调度未显式考虑 $\mathcal{F}$ ，则无法利用“冻结前缀”带来的冗余剪枝机会，也难以在划分模型时平衡各 stage 的有效负载。

综上所述，要在异构 GPU 集群上高效训练 MLLMs，需同时兼顾两点：（1）MLLMs 的混合模块结构所导致的层间计算与显存需求非均匀性；（2）参数训练状态随训练流水级变化对最优划分与调度的影响。MMoH 针对上述两点，设计了 *MMoH* 并行策略规划器与提前终止调度器，在给定异构集群规格与 MLLMs 配置下自动生成近似最优的模型划分与设备映射，并在冻结场景下消除不必要的反向计算与流水级间通信，从而提升训练效率且不影响模型收敛性。

3.1.2 MMoH 框架概览

MMoH 由两大核心组件构成：*MMoH* 并行策略规划器（MMoH parallel strategy planner）与提前终止调度器（early-termination scheduler）。二者协同工作，分别负责离线（或按流水级）的策略生成与在线训练过程中的调度优化。图 3.4 给出了 MMoH 的整体架构：规划器以 MLLMs 配置与异构集群规格为输入，经需求驱动拓扑识别、复合粒度抽象与冻结感知划分得到并行策略；调度器在训练中利用冻结特性减少冗余计算与通信。规划器的输入包括：异构集群规格（各 GPU 的算力、显存及节点内 / 间互联带宽）、MLLMs 的模型结构与参数量、以及当前训练阶段对应的冻结状态（如编码器与 LLM 是否冻结）；输出为设备拓扑（各流水级

与 GPU 的对应关系)、模型的划分策略(每个流水级包含哪些模型层)、以及建议的 DP/TP 配置。调度器根据模型当前训练阶段的冻结状态,优化流水线调度策略,从而在冻结场景下消除不必要的反向计算与流水级间通信。与 Whale[54]、Espresso[84] 等仅按显存或算力比例做层划分、且不区分模块类型与冻结状态的方法相比,MMoH 显式建模 MLLMs 的模块异构与冻结状态,从而在多种冻结场景下获得更优的划分与更高的训练吞吐。

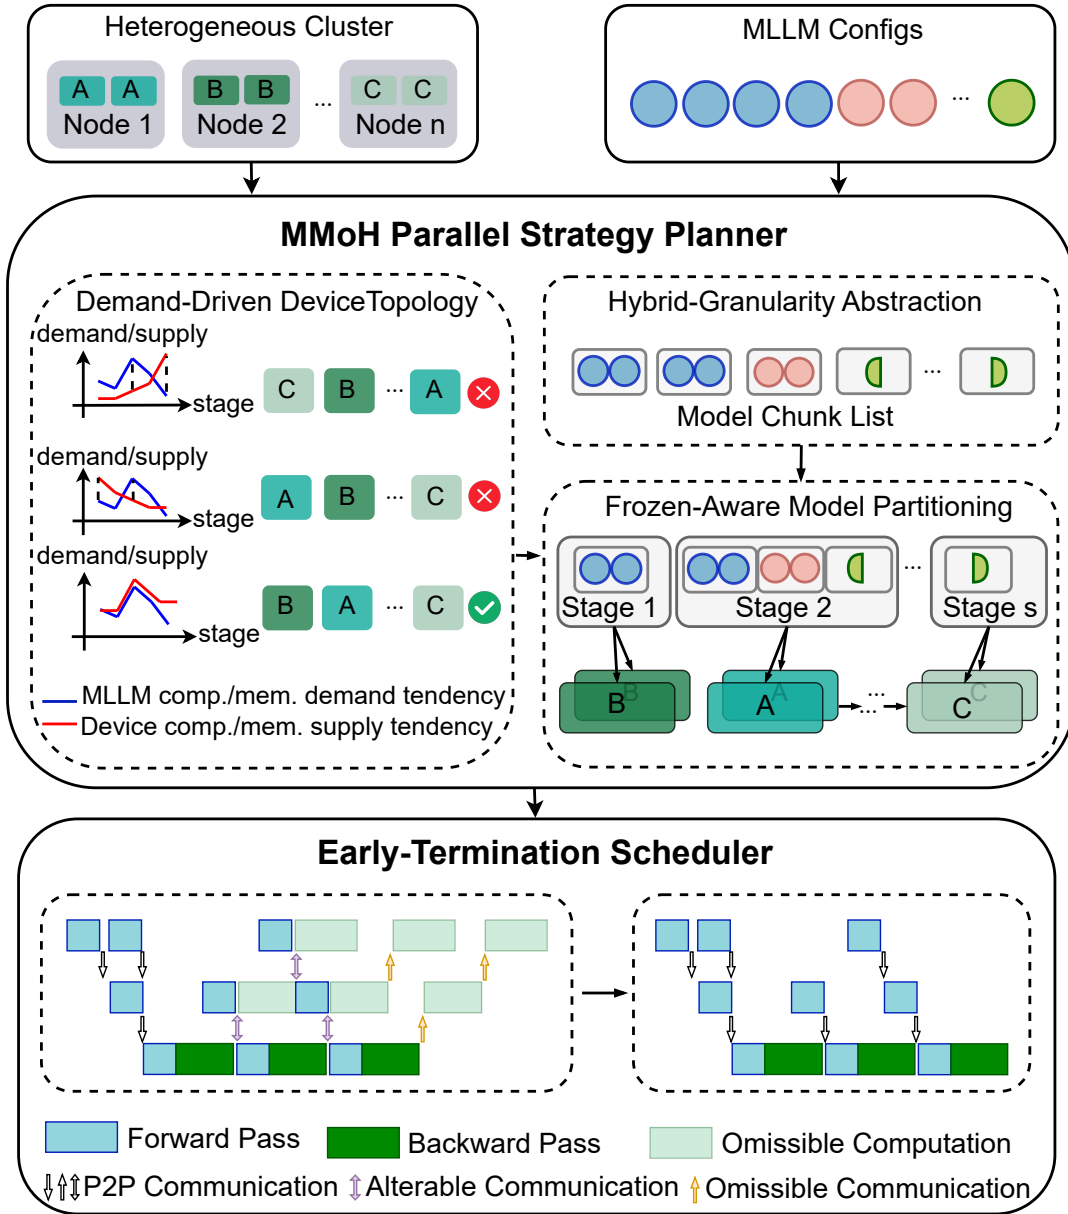


图 3.4 MMoH 框架总览。MMoH 包含并行策略规划器与提前终止调度器: 规划器根据 MLLMs 配置与异构集群规格生成最优并行策略; 调度器在训练中利用冻结技术减少不必要的计算与通信。

并行策略规划器。规划器以异构集群规格（各 GPU 的算力、显存及互联拓扑）与 MLLMs 配置（模型结构、参数量、当前冻结状态）为输入，依次执行三个步骤。**第一步**为需求驱动的设备拓扑识别：根据 MLLMs 各模块的计算与显存需求趋势，与异构设备组内各设备的算力—显存供给趋势进行匹配，筛选出若干候选设备拓扑（即设备组内各流水级与 GPU 的对应关系），使需求与供给在趋势上尽可能一致。**第二步**为复合粒度抽象：针对编码器、投影层与 LLM Backbone 的结构差异，采用多级粒度将模型重组为模型块（model chunk）列表——编码器采用子模块级粒度（将连续多层层合并为一块），LLM Backbone 采用子层粒度（将单层拆分为注意力块与 FFN 块），非 Transformer 层（嵌入、输出、投影）各自作为独立块，从而在划分复杂度与负载均衡之间取得折中。**第三步**为冻结感知的模型划分：在候选拓扑与模型块列表基础上，将“把块分配到各流水级”形式化为整数规划（Integer Programming, IP）问题，在满足显存约束与主流水级约束的前提下，最小化单次迭代时间（其中通信时间显式依赖各流水级的冻结状态），求解得到各流水级所包含的块及与设备的映射。训练时，每个设备组内采用流水线并行（PP），组间采用数据并行（DP）与张量并行（TP）以扩展规模与批量大小。

提前终止调度器。调度器针对冻结技术带来的冗余进行计算与通信剪枝。在流水线并行中，若某流水级及其之前所有流水级均为冻结流水级，则该流水级无需再执行“对输出的梯度”的反向计算，也无需接收后续流水级的梯度或向后续流水级发送激活；相应的 P2P 通信与中间张量存储可安全省略，且不改变梯度传播的数学等价性。调度器在 1F1B（One-Forward-One-Backward）等流水线调度基础上，识别从流水线首端开始的连续冻结流水级并对其提前终止反向与通信，从而在 freeze-encoder、freeze-both 等场景下进一步缩短迭代时间。下文将分别对规划器的三个步骤与调度器的设计进行形式化描述与讨论。

3.2 异构设备映射与复合粒度模型划分

本节围绕 MMLMoH 并行策略规划器展开，形式化描述其三个核心步骤：需求驱动的设备拓扑识别、复合粒度抽象与冻结感知的模型划分，并给出相应的数学模型与约束条件。整体流程可以概括为三步：首先根据模型的计算—显存需求轮廓，从所有可能的设备排列中筛选出一组“形状匹配”的候选拓扑；随后，将原始网络重写为由若干模型块组成的线性序列，使之既能准确反映模块异构，又不会让后续搜索空间过大；最后，在给定拓扑与块列表的前提下，将“块到流水级的分配”形式化为一个以迭代时间为目标的整数规划问题并求解其近似最优解。

3.2.1 需求驱动的设备拓扑识别

在异构设备组内，不同 GPU 的算力与显存容量存在差异；若将算力与显存均较强的设备分配给计算与显存需求均较高的流水级，则能更好地匹配需求与供给，减少瓶颈流水级并降低 OOM 风险。直观地看，一旦把“最重的一段模型”错放在“最弱的一张卡”上，即便其它设备仍有大量空闲，该流水级也会成为主瓶颈，导致整体吞吐被严重限制。为避免这种“强弱错位”，MMoH 规划器首先对 MLLMs 进行剖析（profiling），在代表设备上测得各层的计算量（以 FLOPs 计）与显存占用；由于 FLOPs 与显存占用在同一模型结构下与具体设备型号关系不大，每类层仅需剖析一次。随后，规划器在此基础上枚举设备组内所有可能的设备排列（即设备拓扑），并在每一种排列下，将预先计算好的“需求侧”信息与当前排列对应的“供给侧”信息进行匹配，从而度量该拓扑是否适合当前模型。具体来说，规划器对每种拓扑计算“需求趋势”与“供给趋势”的匹配度，并据此筛选候选拓扑。设备组内共有 s 张 GPU，分属 k 种异构型号，各型号数量记为 $n_1, \dots, n_k$ （满足 $n_1 + \dots + n_k = s$ ）；则不同设备拓扑的数目为 $s!/(n_1! \dots n_k!)$ （同型号 GPU 视为不可区分，即多重组合数）。枚举后对每种排列计算 MD，按 MD 降序排序并仅保留前一半作为候选，以在后续整数规划阶段控制求解次数，在匹配质量与计算开销之间取得折中。

符号与假设。 记 MLLMs 总层数为 l （即编码器、投影层与 LLM Backbone 中所有可单独计层的单元之和），第 i 层的计算量与显存占用分别为 L_i 、 M_i （ $i = 0, 1, \dots, l-1$ ）。设备组内流水线并行度（即流水级数）记为 s ；在某一给定拓扑下，第 j 个流水级所对应设备的算力与显存容量记为 P_j 、 Q_j （ $j = 0, 1, \dots, s-1$ ）。首先，按“计算均衡”原则将 l 层划分为 s 个连续流水级，使各流水级所分配层的总 FLOPs 与各设备算力成比例，得到各流水级的总 FLOPs 与显存占用 R_j 、 T_j 。

需求趋势与供给趋势。 定义需求趋势为各流水级“单位显存下的计算量”之比构成的序列，用于刻画各流水级对算力—显存比的需求相对关系：

$$\text{Demand} = \left\{ \frac{R_1/T_1}{R_0/T_0}, \frac{R_2/T_2}{R_1/T_1}, \dots, \frac{R_{s-1}/T_{s-1}}{R_{s-2}/T_{s-2}} \right\}. \quad (3.1)$$

类似地，定义供给趋势为各设备算力—显存比之比构成的序列：

$$\text{Supply} = \left\{ \frac{P_1/Q_1}{P_0/Q_0}, \frac{P_2/Q_2}{P_1/Q_1}, \dots, \frac{P_{s-1}/Q_{s-1}}{P_{s-2}/Q_{s-2}} \right\}. \quad (3.2)$$

匹配度度量。 为量化某一设备拓扑下需求与供给的匹配程度，定义匹配度（Matching Degree, MD）为两趋势序列的负指数平方误差：

$$\text{MD}(\text{Demand}, \text{Supply}) = \exp \left(-\frac{1}{s-1} \sum_{j=1}^{s-1} (x_j - y_j)^2 \right), \quad (3.3)$$

其中 x_j 、 y_j 分别为 Demand 与 Supply 的第 j 个分量。MD 取值于 $(0, 1]$ ，越大表示该拓扑下各流水级的计算—显存需求与各设备能力在趋势上越一致。规划器对所有候选拓扑按 MD 降序排序，保留 MD 较高的前半部分作为后续冻结感知的模型划分的候选拓扑，以在保证匹配质量的前提下控制求解规模。

直观上，需求趋势刻画的是“从流水级 0 到 $s-1$ ，单位显存下所需算力的相对变化”：若某段流水级对应 LLM 的注意力与 FFN 块，则 R_j/T_j 往往较大；若对应编码器合并块，则相对较小。供给趋势则刻画“从设备 0 到 $s-1$ ，算力—显存比的相对变化”：将高 P_j/Q_j 的设备分配给高 R_j/T_j 的流水级，可使各 stage 在各自设备上均接近满负载，减少瓶颈并降低 OOM 风险 [115]。与直接对 R_j 、 T_j 和 P_j 、 Q_j 本身做匹配相比，利用“相邻比值”构成的趋势序列，可以在不依赖绝对尺度的前提下捕捉“先轻后重”“先重后轻”等全局模式。

在实现层面，规划器对所有设备拓扑计算 MD 并按降序排序，仅保留 MD 较高的前半部分作为后续冻结感知的模型划分的候选拓扑。这既确保了这些拓扑在趋势层面与模型需求相容，又把整数规划的求解规模控制在可接受范围内，避免在显然不匹配的拓扑上浪费时间。整体而言，该步骤使设备拓扑的选取由 MLLMs 的实际计算—显存需求驱动，而非仅按显存或算力单一维度排序，从而更好地适应“编码器轻、LLM 重”的非均匀结构以及冻结带来的需求变化。

3.2.2 复合粒度抽象

若对整网采用统一的“Transformer 层”粒度进行划分，将面临两难：编码器单层计算与显存较小，按层划分会导致块数过多、划分搜索空间过大且对负载均衡帮助有限；LLM 单层计算与显存很大，按层划分在异构设备上易造成单流水级过载或 OOM。简单地“全部细化”或“全部粗化”都会带来问题：前者使块数呈线性甚至超线性增长，整数规划的变量与约束数随之急剧膨胀；后者则使得单块负载过大，以至于再精巧的拓扑也难以获得良好的负载均衡。因此 MMLMoH 提出复合粒度抽象，将模型重组为若干模型块（model chunk）的列表，不同模块采用不同划分粒度，在划分精度与搜索效率之间取得平衡，如图 3.5 所示。

编码器。 编码器内 Transformer 层参数量与序列长度相对较小，单层计算与显存较低。采用子模块级粒度：将连续多层层合并为一个“编码器层块”（encoder-layers




图 3.5 复合粒度抽象示意。(a) 编码器：将连续多层层合并为编码器层块；(b) LLM Backbone：将单层拆分为注意力块与 FFN 块，不增加流水级间通信量。

chunk)。合并因子由剖析结果确定，使得每个编码器层块的计算量与显存占用均不超过 LLM 中单个注意力块或 FFN 块，从而在划分时可将多个块置于同一流水级而不会造成该流水级过载。该粒度既减少了块的数量、降低了后续 IP 的变量规模，又避免了编码器部分划分过细带来的冗余。

LLM Backbone。 LLM 单层参数量大、序列长，若整层作为一块易导致某流水级显存或算力瓶颈。采用子层粒度：将每一 Transformer 层拆分为“注意力块”（Attention chunk）与“FFN 块”（FFN chunk），划分时以块为单位分配到流水级。该分解不改变层间数据流，因此不增加流水级间通信量（块边界与层边界一致）；同时使划分粒度更细，便于在异构设备间更精细地平衡负载，并有效缓解低显存设备上的 OOM 风险。

非 Transformer 层。 嵌入层、输出层与投影层等结构各异、计算与显存差异较大，采用层级粒度，各自作为独立块（embedding chunk、output chunk、projector chunk），以准确反映其资源需求。

经复合粒度抽象后，MLLM 被表示为一个长度为 N 的模型块列表； N 及各块的大小随具体模型与冻结状态变化，为后续冻结感知的模型划分提供既不过粗也不过细的决策单元。从优化视角看，模型块相当于整数规划中的“原子变量单位”：块越小，划分的可调维度越多，但变量数量也随之上升；块越大，变量数量减少，但可调空间被压缩。复合粒度的设计正是为了在这两者之间取得折中。以本文实验中的 MLLM-3B 为例：编码器约 24 层，按合并因子 2 得到约 12 个编码器层块；投影层为 1 个独立块；LLM Backbone 12 层，每层拆为注意力块与 FFN 块，共 24 块；加上嵌入与输出等，总块数 N 约在 40 量级。该粒度下，单块计算

与显存与典型异构单卡能力相匹配，既避免块数过多导致 IP 变量空间过大，又避免块过粗导致划分无法细粒度平衡负载。

3.2.3 冻结感知的模型划分

在得到候选设备拓扑与模型块列表后，规划器将“把块分配到各流水级”形式化为整数规划问题，目标是最小化单次迭代时间，并显式考虑冻结对反向计算与梯度同步的影响。这一阶段的输入包括：（1）上一小节筛选出的若干设备拓扑；（2）由复合粒度抽象得到的模型块序列以及每个块在不同类型设备上的执行时间、显存占用；（3）当前训练阶段的冻结状态（如 no-freeze、freeze-encoder、freeze-both 等）。在此基础上，规划器对每个候选拓扑分别构建并求解一个整数规划实例，最终选取迭代时间估计值 T^* 最小的拓扑与划分方案，作为该阶段的并行策略。

决策变量与目标。 记块列表长度为 N ，设备组内流水级数为 S 。划分方案表示为序列 $P = (p_1, p_2, \dots, p_S)$ ，其中 p_i 为第 i 个流水级所分配的块数，满足 $\sum_{i=1}^S p_i = N$ 。对给定拓扑与 P ，可估计各流水级前向时间列表 $FT = (F_1, \dots, F_S)$ 与反向时间列表 $BT = (B_1, \dots, B_S)$ （由各块在对应设备上的执行时间累加得到）。记主流水级（master stage）索引为 K ，micro-batch 数为 M 。在 1F1B 调度下，单次迭代时间 T^* 可写为前向、反向与通信时间之和；其中通信时间与各流水级是否需要梯度同步有关：若某流水级内所有块均为冻结参数，则该流水级不产生梯度同步开销。规划器将通信时间建模为各流水级“非可重叠”的同步开销的最大值，且冻结流水级对应的同步开销为 0，从而在成本模型中显式体现冻结带来的通信剪枝收益。形式化地，记主流水级索引为 K 、micro-batch 数为 M ，则

$$T^* = \sum_{i=1}^{K-1} (F_i + B_i) + 2 \sum_{i=K+1}^S (F_i + B_i) + (M - (S - K))(F_K + B_K) + \text{COMM}, \quad (3.4)$$

其中第一项为 warm-up 阶段前 $K - 1$ 个流水级的前向与反向时间之和，第二项为 cool-down 阶段后 $S - K$ 个流水级各执行两次前向与反向的贡献，第三项为主流水级在稳态阶段对 $M - (S - K)$ 个 micro-batch 的计费，COMM 为通信时间。通信时间取各流水级不可与前向 / 反向重叠的梯度同步开销的最大值：

$$\text{COMM} = \max_{i=1, \dots, S} \left(AR_i - \sum_{j=1}^{i-1} B_j \right), \quad (3.5)$$

其中 AR_i 为第 i 个流水级的梯度同步（如 All-Reduce）开销，可由该流水级内激活参数数量估计；若第 i 个流水级内所有块均为冻结，则 $AR_i = 0$ 。式中“减去前

级 $\sum_{j=1}^{i-1} B_j$ ”刻画了梯度同步与反向计算的可重叠部分：若某流水级的反向计算时间足够长，则其梯度同步可被完全隐藏在反向中，对总迭代时间不再产生额外贡献。由此得到 T^* 关于 P 的显式表达式（含冻结感知的通信项），规划器以最小化 T^* 为目标在约束下求解 P 。

约束条件。 划分问题需满足以下约束：（1）**完整性约束**： $\sum_{i=1}^S p_i = N$ ，即所有块恰好分配完毕；（2）**主流水级约束**：非主流水级的前向与反向时间之和不超过主流水级，即 $F_i + B_i \leq F_K + B_K$ ($\forall i \neq K$)，以保证 1F1B 等调度下主流水级不成为瓶颈；（3）**显存约束**：各流水级模型状态与激活显存之和不超过所分配设备的显存容量，防止训练过程中发生 OOM。规划器使用 CPLEX 等整数规划求解器在候选拓扑上分别求解最小化 T^* 的 P ，并取所有候选拓扑中使 T^* 最小的划分与拓扑作为最终并行策略。

主流水级 K 的选取方式为：在给定 P 与拓扑下，计算各流水级的 $F_i + B_i$ （冻结流水级的 B_i 按提前终止规则置零），取使 $F_i + B_i$ 最大的流水级索引作为 K ，以保证 1F1B 下瓶颈估计正确。显存估计中，各流水级占用包含模型参数与优化器状态（仅对可训练参数）、激活（与 micro-batch 大小及序列长度相关）、以及梯度与临时缓冲区；冻结流水级不存储该部分参数的优化器状态与梯度，通信缓冲区也可相应省略，故通信项中其同步开销置零。在实验环境中，单次 IP 求解在候选拓扑上的耗时通常在秒级，整体规划时间可接受；若某拓扑下无可行解（如显存约束无法满足），规划器可放宽主流水级约束或尝试更大 TP 后重新求解。

通过将冻结状态纳入成本模型与通信项，同一 MLLM 在不同训练阶段（如 no-freeze、freeze-encoder、freeze-both）会得到不同的最优划分与设备拓扑，从而随训练进程动态适配，提升异构集群上的训练效率。相关研究已表明，将流水线骨架映射到异构平台的最优划分问题在一般意义下为 NP- 难，本节的整数规划形式化在给定拓扑与块列表下求取近似最优划分，在实践中在求解时间与策略质量之间取得了较好平衡。

3.3 提前终止流水线调度策略

上一节从划分与映射角度刻画了冻结状态对最优并行策略的影响，而在给定某一划分与设备拓扑后，实际训练过程仍受具体流水线调度方式的制约。流水线并行在工业界最常用的是 1F1B（One-Forward-One-Backward）及其变体：各流水级在稳态阶段交替执行前向与反向，对多个 micro-batch 形成“错位”流水。此类调度的一个关键特点是：反向阶段不仅需要完成本流水级对参数的梯度计算，还必须依赖来自后续流水级的输出梯度，以继续向前序流水级回传梯度。

当 MLLMs 中部分模块被冻结时，冻结参数不参与梯度更新，但仍需为前序层计算“对输入的梯度”，从而保证未冻结参数接收到正确的反向信号。直观地看，这会削减冻结流水级的反向计算量，却不会改变“反向必须逐级串行传播”的依赖结构。因此，若仅在成本模型中简单减小冻结层的反向 FLOPs，而不改变调度逻辑，仍然无法充分挖掘冻结带来的潜在加速空间。

MMoH 在此基础上提出提前终止流水线调度器：在不改变损失函数对可训练参数的梯度的前提下，识别并剪枝反向阶段中与冻结前缀相关的冗余计算与 P2P 通信，从而进一步缩短单次迭代时间。本节将详细说明冗余产生的原因、调度器的判定规则与执行流程，以及其对成本模型与划分策略的反馈作用。

3.3.1 冗余识别与剪枝规则

在标准反向传播中，每个流水级需完成两类计算：**对参数的梯度**（用于更新该流水级参数）与**对输入的梯度**（用于向上一流水级传递梯度）。对于冻结流水级而言，对参数的梯度不再需要计算，但在一般设置下仍须计算“对输入的梯度”，以便驱动前序流水级执行反向；这一点与传统“仅冻结优化器状态”的实现方式一致。

然而，当存在“前缀冻结”时，上述惯用实现会引入可以被安全删除的冗余计算。设流水级从 0 到 $S-1$ 依次排列，若流水级 i 及其之前所有流水级 $(0, \dots, i-1)$ 均为冻结流水级，则可以注意到：

- 流水级 i 的输出仅被后续流水级的前向与反向使用，而不会再被任何可训练参数直接消费；
- 损失函数 $\mathcal{L}$ 对冻结前缀中任一参数 θ_f 的梯度 $\partial\mathcal{L}/\partial\theta_f$ 始终被约束为零；
- 对输入的梯度 $\partial\mathcal{L}/\partial x_f$ 仅用于驱动更早的冻结流水级执行反向，而这些反向本身也不会产生非零的参数梯度。

由此可以得到一个关键结论：若某流水级及其前缀均为冻结流水级，则该流水级在反向阶段所参与的“输出梯度计算与回传”对任何可训练参数的最终梯度均无影响，仅产生数值上为零或被丢弃的中间结果。因此，在数学上可以安全省略这部分计算与通信，而不改变未冻结参数的梯度。

据此，MMoH 将冗余识别与剪枝规则概括为：

若存在整数 D ，使得流水级 $0, \dots, D-1$ 均为冻结流水级，且流水级 D 为第一个包含可训练参数的流水级，则对任意 micro-batch，流水级

$0, \dots, D-1$ 在完成前向计算后，无需再执行针对该 `micro-batch` 的反向计算及与后续流水级相关的 P2P 通信。

上述规则直接导致两类收益：一是计算剪枝，即对冻结前缀不再调度反向算子，减少了 `kernel` 启动与算子执行时间；二是通信剪枝，即省略对应的激活缓存与梯度 P2P，降低显存占用和链路带宽消耗。由于冻结前缀常覆盖编码器与部分早期 LLM 层，在典型的 MLLM 训练阶段（如 `freeze-encoder`、`freeze-both`）中，这两类收益对端到端迭代时间具有可观影响。


3.3.2 调度流程与实现细节

在具体实现上，提前终止调度器并不修改 1F1B 的整体时间步组织方式，而是对每个时间步中“需要执行反向与通信的流水级集合”做动态裁剪。其执行流程可概括为三个步骤：

1. **冻结前缀检测。**在每个训练阶段开始时（例如切换冻结策略后），调度器读取由用户或上层框架提供的“流水级—冻结标记”数组，从流水级 0 起顺序扫描，直至遇到第一个包含可训练参数的流水级，将其索引记为 D 。若首流水级即为可训练流水级，则 $D = 0$ ，退化为标准 1F1B 调度。
2. **时间步级调度裁剪。**对于每个时间步 t 与 `micro-batch` m ，调度器首先按照标准 1F1B 规则计算“应当执行前向 / 反向的流水级集合”。在此基础上，对所有索引 $i < D$ 且被标记为“反向”的任务直接跳过，仅保留其前向任务。对应的 P2P 接收与发送操作也一并取消，避免在运行时创建多余通信。
3. **资源复用与同步。**由于冻结前缀在反向阶段不再参与某些 `micro-batch` 的计算，其 GPU 资源可以更早地被下一轮 `micro-batch` 的前向阶段复用。调度器在实现时通过调整 CUDA stream 与 NCCL group 的启动顺序，确保这种“前向抢占”不会破坏 1F1B 对有依赖张量的先后约束。

图 3.6 给出了一个简化示例：在 4 流水级、4 个 `micro-batch` 的场景下，当前两流水级为冻结流水级时，标准 1F1B 与仅修改反向耗时的情形相比，提前终止调度在时间轴上有效压缩了与冻结前缀相关的反向与通信区间，从而缩短了迭代长度。


从接口层面看，MMoH 在 Megatron-LM 等框架之上增添了一层轻量级调度控制：原有训练脚本只需在每个流水级维护一个布尔型“是否包含可训练参数”的标记，调度器即可在运行时据此自动完成冻结前缀检测与裁剪，无需用户显式编写新的反向算子。



(a) 1F1B pipeline scheduling when no stage is frozen



(b) 1F1B pipeline scheduling when the first two stages are frozen



(c) early-termination scheduling when the first two stages are frozen



图 3.6 提前终止调度器效果示意。4 流水级流水线、4 个 micro-batch，前两流水级为冻结流水级。(a) 标准 1F1B；(b) 考虑冻结后反向时间变化；(c) 提前终止调度器：跳过前两流水级对输入的梯度计算及相应 P2P 通信与张量存储。

3.3.3 对成本模型与划分策略的影响

在存在连续冻结前缀（前 D 个流水级）的情况下，迭代时间 T^* 的表达式需与前述调度行为保持一致。采用提前终止后，前 D 个流水级在单轮迭代中仅贡献前向时间，其反向与梯度同步开销视为零，因此 T^* 可改写为

$$T^* = \sum_{i=1}^D F_i + \sum_{i=D+1}^{K-1} (F_i + B_i) + 2 \sum_{i=K+1}^S (F_i + B_i) + (M - (S - K))(F_K + B_K) + \text{COMM}. \quad (3.6)$$

其中 D 为流水线首端连续冻结流水级的个数， K 为非冻结流水级中计算时间 $F_i + B_i$ 最大的流水级索引；COMM 仍取各流水级不可重叠的梯度同步开销的最大值，且对前 D 个流水级有 $AR_i = 0$ ，以便在 1F1B 下正确估计瓶颈与可重叠程度。

与未引入提前终止的情形相比，上式在两个方面影响了整数规划阶段的最优

解形态：一方面，冻结前缀上的反向与通信被完全剪枝，使得将更多计算量“推向”这部分流水级不会增加迭代时间，从而在求解过程中自然倾向于将一部分重计算块划分到冻结前缀，以减轻后续非冻结流水级的负载；另一方面，通信项中对冻结前缀 AR_i 的归零，使得主瓶颈更有可能出现在包含大量可训练参数的后段流水级上，这与实际训练中“解冻阶段成为性能瓶颈”的经验观察是一致的。

从全局角度看，提前终止调度器与冻结感知的模型划分形成了一个闭环：划分阶段根据冻结状态与调度模型预估各流水级的前向 / 反向与通信时间，调度阶段在运行时据此执行提前终止以兑现模型中的剪枝收益；反过来，调度规则的改变又会影响成本模型的具体形式，使得后续阶段的划分能够更准确地利用冻结前缀带来的冗余空间。

需要强调的是，提前终止思想并不局限于 1F1B 调度本身，而是与调度框架正交。对于 Chimera、Hanayo 等近年来提出的双向或波式流水线调度机制，只要其反向阶段仍遵循“从后向前逐级传播梯度”的基本模式，就可以在对应的时间步上应用同样的冻结前缀检测与任务裁剪逻辑。图 3.7 给出了在 Chimera（双向流水线）与 Hanayo（波式流水线）下的示意图：在前段连续冻结流水级上，同样可以提前终止反向与通信，以进一步缩短迭代时间。




图 3.7 提前终止在其它流水线调度机制上的适用性。左：Chimera；右：Hanayo。前向时间假设各流水级一致，反向时间差异来自冻结流水级；提前终止可同样应用于连续冻结前缀。

3.3.4 实现要点

MMoH 的规划器与调度器可与 Megatron-LM[38] 及 PyTorch 分布式后端集成：规划器在给定集群与模型配置下离线输出设备拓扑与块一流水级映射，训练脚本据此构建 PP 通信组与各 rank 上的子模块；调度器在运行时根据各流水级的冻结标记决定是否调度反向与 P2P。Profiling 在代表设备上以“层”或“块”为粒度测量前向 / 反向 FLOPs 与显存占用，结果缓存在配置文件中供规划器重复使用。整数规划采用 CPLEX 求解；若某拓扑下无可行解，可放宽主流水级约束或增大 TP

后重新求解，作为回退策略 [89]。

3.4 实验验证

本节从实验设置、实验结果与实验分析三方面对 MMoH 进行验证，并与 Megatron-LM、Whale、Espresso 等基线方法进行对比。

3.4.1 实验设置

实验平台与异构集群配置。 实验在两种异构 GPU 集群上进行。**Cluster-S** 包含 4 个节点、共 16 张 GPU：1 个节点配备 4 张 NVIDIA RTX 3090，2 个节点各配备 4 张 RTX 2080 Ti，1 个节点配备 4 张 RTX 2080，单机总显存约 216 GB。**Cluster-L** 包含 8 个节点、共 32 张 GPU：4 个节点为 RTX 3090、2 个节点为 RTX 2080 Ti、2 个节点为 RTX 2080，单机总显存约 536 GB。节点间通过 100 Gbps InfiniBand 互联；RTX 3090 节点内 GPU 通过 PCIe 4.0 互联，RTX 2080/2080 Ti 节点内通过 PCIe 3.0 互联；各节点均为双路 Intel Xeon 4310@2.10 GHz、128 GB DDR4 内存。软件环境为 Ubuntu 18.04、CUDA 11.8、cuDNN 8.7.0、NCCL 2.19.3 与 PyTorch 2.2。表 3.1 汇总两种异构集群的节点与显存配置。

表 3.1 实验用异构 GPU 集群配置

集群类型 (GPU 数)	节点编号	GPU 型号 (每节点张数)	总显存 (GB)
Cluster-S (16)	1	RTX 3090 (4)	216
	2, 3	RTX 2080 Ti (4)	
	4	RTX 2080 (4)	
Cluster-L (32)	1-4	RTX 3090 (4)	536
	5, 6	RTX 2080 Ti (4)	
	7, 8	RTX 2080 (4)	

模型与数据集。 为验证 MMoH 在不同规模与结构下的表现，构建两种 MLLMs。**MLLM-3B** 由 ViT 编码器（约 0.2B 参数、24 层）、MLP-S 投影层（约 73M 参数）与 Mistral 2.8B Backbone（12 层）组成；**MLLM-12B** 由 InternViT 编码器（约 6B 参数、45 层）、MLP-L 投影层（约 149M 参数）与 Yi 6B Backbone（20 层）组成。MLLM-3B 在 Cluster-S 上训练，MLLM-12B 在 Cluster-L 上训练，以与集群总显存规模相匹配。训练数据采用 LLaVA Visual Instruct 数据集（约 60 万条图文指令数据），用于模态对齐与指令微调；训练时采用与 LLaVA 类似的采样与数据混合策略 [13]。关键超参数方面：MLLM-3B 的 global batch size 为 64、micro-batch size

为 2、最大序列长度 2048；MLLM-12B 的 global batch size 为 32、micro-batch size 为 1、最大序列长度 2048，以在异构集群显存约束下尽可能提高有效批量并避免 OOM。表 3.2 汇总两种 MLLM 各模块的参数量与层数配置。

表 3.2 实验用 MLLM 模块配置（模型参数）

MLLM	模块	类型	参数量	层数
MLLM-3B	ViT	编码器	0.2B	24
	MLP-S	投影层	73M	2
	Mistral	LLM Backbone	2.8B	12
MLLM-12B	InternViT	编码器	6B	45
	MLP-L	投影层	149M	2
	Yi	LLM Backbone	6B	20


对比方法与评价指标。对比方法包括：（1）**Megatron-LM**[38]，面向同构集群的流水线划分框架，在异构环境下沿用 Whale 的设备拓扑以缓解 OOM；（2）**Whale**[54]，按显存与算力组织设备并做层级划分；（3）**Espresso**[84]，基于计算—显存比（CMR）的流水级放置与 Whale 式划分相结合。评价指标为训练吞吐（samples/s）。每种配置进行 10 轮预热与 50 轮测量，取稳定流水级的平均吞吐作为报告值；若发生 OOM，则尝试提高 TP、降低 DP，若 TP=4 仍 OOM 则记为不可行。

3.4.2 实验结果


在 no-freeze、freeze-encoder、freeze-LLM、freeze-both 四种冻结场景下，MMoH 在两种集群与两种模型上均取得最高吞吐，且在不同场景下均能自动调整设备拓扑与划分策略。图 3.8 给出了两种集群与两种 MLLMs 下的端到端吞吐对比，柱长表示吞吐（samples/s），OOM 表示该配置下发生显存溢出无法训练。

MLLM-3B 在 Cluster-S 上。相对 Whale 与 Espresso，MMoH 在 no-freeze 下分别达到约 $1.22\times$ 与 $1.07\times$ 的加速；在 freeze-both 下优势更明显，可达约 $1.18\times$ – $1.72\times$ 。Megatron 在所有场景下吞吐最低，因其同构假设导致负载不均；在部分场景下需将 TP 升至 4 方能训练，频繁的 TP 通信进一步限制性能。

MLLM-12B 在 Cluster-L 上。在 no-freeze 与 freeze-LLM 下，Megatron 因粗粒度划分导致的负载不均而出现 OOM，无法完成训练；Whale 与 Espresso 通过异构感



(a) MLLM-3B 在 Cluster-S 上



(b) MLLM-12B 在 Cluster-L 上

图 3.8 四种冻结场景下 MMoH 与基线在两种异构集群上的训练吞吐对比。柱越长表示吞吐越高，OOM 表示显存溢出。

知的拓扑与划分避免了 OOM，但 MMoH 仍取得最高吞吐。在 no-freeze 下，MMoH 相对 Espresso 与 Whale 分别约 $1.04\times$ 与 $1.26\times$ ；在 freeze-encoder、freeze-both 下，提前终止调度器带来显著增益，MMoH 相对 Megatron、Whale、Espresso 可达约 $1.19\times$ – $1.77\times$ 的加速。上述结果说明，MMoH 的复合粒度划分与冻结感知策略在不同规模与冻结场景下均能有效提升异构集群上的训练效率。

3.4.3 实验分析

划分策略对比。Whale 与 Espresso 采用单一“层”粒度划分并扩展到 MLLMs；MMoH 采用复合粒度（编码器合并为块、LLM 拆分为注意力/FFN 块）。表 3.3 对比了 Whale、Espresso 与 MMoH 在 MLLM-3B、MLLM-12B 及四种冻结场景下的设备拓扑、各流水级块数及相对 Whale 的加速比。在相同冻结场景下，MMoH 得到的设备拓扑与各流水级块数分布随冻结状态变化：例如 freeze-encoder 时前段计算需求下降，MMoH 会将较弱 GPU 置于首流水级；freeze-LLM 时后段需求下降，设备顺序相应调整，与需求—供给匹配度一致。该动态调整能力是现有方法所不具备的，也是 MMoH 在多种场景下均能取得较优性能的重要原因。

表 3.3 不同冻结场景下的模型划分对比。A、B、C 分别表示 NVIDIA RTX 3090、2080 Ti 与 2080 GPU。

冻结 模式	Whale（层粒度）		Espresso（层粒度）		MMoH（复合粒度）	
	MLLM-3B	MLLM-12B	MLLM-3B	MLLM-12B	MLLM-3B	MLLM-12B
no-freeze	[A,B,B,C]	[A,A,A,A,B,B,C,C]	[B,B,C,A]	[B,B,C,C,A,A,A,A]	[B,A,B,C]	[B,B,C,C,A,A,A,A]
	[30,3,3,2]	[15,15,17,9,3,3,3,2]	[26,3,2,7]	[7,7,6,6,15,11,8,7]	[11,14,6,4]	[7,7,6,6,18,16,13,15]
	1.00×	1.00×	1.07×	1.22×	1.22×	1.26×
freeze-enc.	[A,B,B,C]	[A,A,A,A,B,B,C,C]	[B,B,C,A]	[B,B,C,C,A,A,A,A]	[C,A,B,B]	[C,C,B,B,A,A,A,A]
	[31,3,3,1]	[38,11,5,5,2,3,2,1]	[28,3,2,5]	[8,8,6,6,22,13,13,12]	[12,13,6,4]	[12,11,11,11,11,11,11,10]
	1.00×	1.00×	1.05×	1.04×	1.20×	1.23×
freeze-llm	[A,B,B,C]	[A,A,A,A,B,B,C,C]	[B,B,C,A]	[B,B,C,C,A,A,A,A]	[B,B,A,C]	[C,C,B,B,A,A,A,A]
	[27,4,4,3]	[13,13,13,13,4,4,4,3]	[14,14,3,7]	[3,3,3,3,13,13,17,12]	[7,8,16,4]	[3,3,5,5,13,14,23,22]
	1.00×	1.00×	1.15×	1.20×	1.26×	1.33×
freeze-both	[A,B,B,C]	[A,A,A,A,B,B,C,C]	[B,B,C,A]	[B,B,C,C,A,A,A,A]	[B,A,B,C]	[A,B,B,C,C,A,A,A]
	[30,3,3,2]	[38,9,5,5,3,3,2,2]	[28,2,2,6]	[18,5,4,4,16,7,7,6]	[14,14,4,3]	[36,4,5,3,4,14,12,10]
	1.00×	1.00×	1.08×	1.20×	1.18×	1.28×

负载均衡。在 MLLM-12B 上对比各流水级前向计算时间分布可知，MMoH 的划分使各流水级计算时间分布更集中、峰值更低，迭代时间由瓶颈流水级主导的程度减轻，说明复合粒度与冻结感知划分有效平衡了异构设备上的负载（图 3.9）。在 no-freeze 与 freeze-LLM 等场景下，MMoH 在流水级 5–7 等位置采用更细粒度划分，平滑了负载尖峰，相较 Espresso 进一步缩短了迭代时间。

提前终止调度器消融。为隔离提前终止调度器的贡献，将 MMoH 的调度器接入 Espresso（记为 Espresso+）或从 MMoH 中移除（记为 MMoH-），在 freeze-encoder、freeze-both 下对比。结果表明：Espresso+ 相对 Espresso 有明显提升，MMoH 相对 MMoH- 也有约 8%–11% 的提升；完整 MMoH（规划器 + 调度器）相对仅使用规




图 3.9 MMoH 与 Whale、Espresso 在 MLLM-12B 上、两种冻结设置下的负载均衡对比。分布越集中表示划分越均衡，柱高越低表示迭代时间越短。

划器的 MMoH- 可再提升约 8%–19% 吞吐。这表明该调度器在冻结场景下能有效消除冗余计算与通信，且与规划器协同可进一步放大收益；同时，将调度器接入 Espresso 也能带来增益，说明提前终止策略具有较好的可移植性。图 3.10 给出了 freeze-encoder 与 freeze-both 下 Espresso、Espresso+、MMoH- 与完整 MMoH 的吞吐对比及计算开销分布。




图 3.10 提前终止调度器消融。Espresso+ 为接入该调度器的 Espresso，MMoH- 为去掉该调度器的 MMoH。

局限与扩展。MMoH 当前在 1F1B 等同步流水线调度下验证；与 Zero-Bubble 等异步或重叠通信的流水线调度 [101]、以及 DualPipe 等双向流水线 [102] 的结合，有望在通信密集型场景下进一步缩短迭代时间，留作未来工作。此外，规划器依赖离线或按阶段 profiling，若训练过程中动态改变 batch size 或序列长度，需重新求解划分；第四章将介绍的激活重计算优化与 MMoH 的划分与调度正交，可在同一流水线策略下叠加使用，实现显存与计算—通信的联合优化。

3.5 本章小结

本章介绍了面向异构 GPU 集群的多模态大语言模型高效混合并行框架 MMoH。针对 MLLMs 的混合模块结构与分流水级冻结带来的计算—显存需求非均匀性与动态变化，MMoH 通过需求驱动的设备拓扑识别、复合粒度模型抽象与冻结感知的整数规划划分，在给定集群与模型配置下自动生成与当前训练流水级相匹配的流水线并行策略；通过提前终止调度器在连续冻结前缀流水级省略不必要的反向计算与 P2P 通信，在保持收敛性的前提下进一步提升吞吐。在两种异构集群（Cluster-S、Cluster-L）与两种规模 MLLMs（MLLM-3B、MLLM-12B）上的实验表明，MMoH 相对 Megatron-LM、Whale、Espresso 等现有方法可获得最高约 $1.77\times$ 的加速，且在不同冻结场景下均能自适应地调整设备拓扑与划分策略。本章将问题形式化为迭代时间由瓶颈流水级主导、以及冻结集合导致的反向与通信不对称，并通过规划器（需求驱动拓扑、复合粒度、冻结感知 IP）与提前终止调度器的协同，在异构集群上实现了与训练阶段相匹配的划分与调度；后续工作可将提前终止与 Zero-Bubble、DualPipe 等调度结合，并与第四章的激活重计算优化叠加，为多模态大模型在资源受限与异构环境下的高效训练提供完整方案。

第四章 HR-MMoH: 多模态大语言模型在异构 GPU 集群上的重计算策略

第二章分析了多模态大语言模型（MLLMs）在模块异构与分阶段冻结训练下呈现的计算与显存需求差异，第三章在此基础上通过 MMoH 框架解决了异构集群上的划分与调度问题。在此背景下，本章进一步聚焦显存维度的瓶颈，提出 HR-MMoH（Heterogeneous Recomputation for training multimodal large language models on heterogeneous GPU clusters），以异构感知的重计算策略补充第三章的工作。

4.1 引言

第三章介绍的 MMoH 框架通过需求驱动的设备拓扑、复合粒度划分与提前终止流水线调度，在异构 GPU 集群上显著提升了训练 MLLMs 的吞吐量。然而，由于异构 GPU 集群中设备间显存与算力差异显著，在显存受限的节点上，仅靠流水线模型划分仍可能无法容纳大批量的数据或者较长的序列输入，训练过程仍面临显存瓶颈。重计算（Recomputation）又称梯度检查点（Gradient Checkpointing）[107]，通过在前向传播时少存部分中间激活值或者不存任何中间激活值、在反向传播时重新进行一次前向传播，把在前向传播时丢弃的中间激活值重新计算出来，以算力换显存，在保持数学等价性的前提下支持更大批量、更长序列或更大参数的模型训练，是目前学术界和工业界广泛采用的缓解显存压力的技术。

现有主流框架（如 Megatron-LM）中的重计算策略多面向同构集群设计：在同一训练任务中，对所有流水级或所有设备采用统一的重计算粒度（如整层重计算 Full Recomputation、子模块级重计算 Selective Recomputation）与统一的层级划分方式（如均匀分块 uniform、仅前若干层做检查点 block），或对全体层采用相同的重计算子模块集合（如仅 core_attn、或 core_attn+mlp+layernorm）。

然而，在异构集群上，各设备显存与算力差异显著：若在显存紧张的设备上采用过粗的重计算粒度或过少的重计算模块，仍易发生 OOM，导致训练无法进行；若在显存充裕的设备上采用过细的粒度或过多的重计算子模块，则会带来不必要的重计算开销，延长迭代时间并造成算力浪费。因此，为了同构集群设计的检查点策略难以在异构环境下同时兼顾显存利用率与计算效率。

针对上述问题，本章介绍 HR-MMoH：在 MMoH 的异构流水线划分与调度基础上，面向异构设备的显存与算力差异，设计异构感知的重计算策略，使各流水级或各设备可根据自身显存与算力条件采用差异化的重计算粒度与子模块重计算选

择, 在降低 OOM 风险的同时尽量减少多余重计算、平衡各流水级计算负载, 从而与第三章的划分与调度形成“划分—调度—显存优化”的联合优化。4.2 节形式化描述异构重计算策略的设计与实现思路, 4.3 节给出实验设置、结果与分析, 4.4 节总结本章内容。

4.2 异构重计算

4.2.1 现有的重计算策略与定量分析

作为当前大模型分布式训练的主流框架, NVIDIA 推出的 Megatron-LM[37, 38, 80] 大模型并行训练框架集中定义了与重计算相关的配置, 开发者通过命令行参数传入重计算配置, 例如 `-recompute-granularity`、`-recompute-method`、`-recompute-num-layers`、`-recompute-modules`。

配置参数方面, 表 4.1 给出 Megatron 中与重计算相关的主要参数及其含义。其中 `recompute_granularity` 决定整层 (`full`) 或子模块级 (`selective`) 重计算; `full` 时须同时指定 `recompute_method` 与 `recompute_num_layers`, `selective` 时二者须为 `None`, 仅由 `recompute_modules` 指定要重算的子模块。`distribute_saved_activations` 为 `True` 时, 可将 `checkpoint` 保存的激活在张量并行组内分片存储以进一步省显存, 但仅对 `full` 粒度且未启用序列并行的情形有效。

整层重计算 (`full`): 以 Transformer 层为统一粒度做检查点; 前向只保存每个“块”的输入, 反向时重新执行该段前向再反传。在 `full` 粒度下, `recompute_method` 与 `recompute_num_layers` 共同决定流水级上多少个模型层只需要保存一个中间激活值。`recompute_method` 具体可以取一下以下两种值:

- **uniform** (均匀分块): 将当前流水级内的所有层均匀分成多个 `chunk`, 每个 `chunk` 包含 `recompute_num_layers` 层; 每个 `chunk` 的输入被 `checkpoint`, `chunk` 内前向一次执行, 反向时整个 `chunk` 先重计算再反传。`chunk` 数少则显存更省, 但单次重算层数较多。
- **block** (仅前 N 层): 在当前流水级内, 只对前 `recompute_num_layers` 层逐层做重计算; 后续层不需要做重计算, 正常存储中间激活。在显存允许时可减少重计算量, 更充分利用显存。

选择重计算 (`selective`): 在每一层内仅对 `recompute_modules` 中列出的子模块做重计算, 其余部分正常存激活。此时 `recompute_method` 与 `recompute_num_layers` 均须为设置为 `None`, 且 `selective` 始终作用于所有流

表 4.1 Megatron-LM 重计算相关配置参数

参数	类型 / 取值	说明
<code>recompute_granularity</code>	None full selective	重计算粒度。None 表示不重计算；full 对整层做重计算；selective 仅对 <code>recompute_modules</code> 中列出的子模块重算。
<code>recompute_method</code>	None uniform block	仅用于 full 粒度：如何划分“哪些层”做 checkpoint 。uniform 为均匀分块，block 为仅对每流水级前若干层做 checkpoint 。 selective 时必须为 None 。
<code>recompute_num_layers</code>	None 正整数	仅用于 full 粒度。uniform 时表示每个 chunk 的层数；block 时表示每个 stage 内做重计算的层数。 selective 时必须为 None 。
<code>distribute_saved_activations</code>	布尔	为 True 时，将 checkpoint 保存的激活在张量并行组内分片存储；仅 full 粒度且非序列并行时有效。
<code>recompute_modules</code>	字符串列表	仅用于 selective 。要重算的子模块名列表（见下文）。默认 <code>["core_attn"]</code> 。

水级上的所有模型层。模型每个子模块在各自的前向传播中根据用户指定的配置项 `recompute_modules` 决定舍弃哪些子模块的中间激活值，在反向传播时哪些模块的激活值需要重新计算。

选择性子模块方面，`recompute_modules` 指定在 **selective** 粒度下要对哪些子模块做重计算。不同子模块采用的重计算机制不同：标准 **checkpoint** 保存输入、反向时重新前向再反传；**Output-discarding checkpoint** 在前向完成后丢弃该子模块输出的显存，在反向时通过梯度钩子函数再算一遍并写回，可进一步节省显存。若未指定 `recompute_modules`，则默认为 `["core_attn"]`。稠密模型下常用的“最省显存”组合为 `[core_attn, mlp, layernorm]`。表 4.2 列出目前训练框架使用选择重计算时支持的常用选项、含义及 **checkpoint** 类型。

上述策略在实现上对同一训练任务内的所有流水级、所有 GPU 计算设备采用统一的重计算粒度、重计算方法、重计算层数以及重计算模块，即面向同构集群时使用了的“全局一致”的重计算策略。但是在异构集群上，显存紧张流水级若与显存充裕流水级使用相同的重计算配置，易出现前者仍 OOM 或后者重计算过

表 4.2 Megatron selective 粒度下可配置的子模块

模块名	含义	Checkpoint 类型
core_attn	核心注意力 (QKV→Attention→ 输出)	标准
mlp	稠密 MLP (非 MoE)	标准
layernorm	输入 LayerNorm 与 MLP 前 LayerNorm	Output-discarding
moe	整块 MoE 层 (router + experts + combine)	标准
shared_experts	MoE 的共享专家	标准
moe_act	MoE 专家内部激活 (如 SiLU) 与专家权重	Output-discarding
mha_up_proj	MLA 的 QKV 上投影与 RoPE	Output-discarding

多的问题，而且目前的重计算技术给所有流水级增加了同样大小的计算负载，这使得异构 GPU 集群中性能较差的 GPU 进一步成为计算瓶颈，为下文针对各流水级 / 设备做差异化配置的异构重计算提供了动机。

重计算技术的定量分析。 为定量比较不同重计算策略对显存占用的影响，本文在给定输入形状与数值格式下，对单个 Transformer 层在前向传播中需为反向传播保留的中间激活所需要的显存占用量进行详细推导。假设层输入张量 X 形状为 $[B, S, H]$ ，其中 B 为 batch size、 S 为输入序列长度、 H 为隐藏维度；中间激活使用训练常用的 BF16 格式，每元素占 2 个字节。Transformer 层采用常见的 Pre-LayerNorm 的 decoder-only 单层结构：层输入 X 经 LayerNorm 后进入注意力子层，残差连接后再经 LayerNorm 进入 MLP 子层（线性层 → GELU 激活层 → 线性层 + Dropout 层），再次残差连接得到层输出。记注意力头数为 A ，MLP 层的中间维度设置为常用的设置，即隐藏维度的 4 倍，记为 $4H$ 。

为避免后续公式中大小写符号混用带来的歧义，表 4.3 汇总本小节使用的主要记号。

(1) **不重计算 (None)**。仅计反向传播所需中间激活，使用训练时常用的 BF16 格式，所以每个激活参数大小为 2 字节。

注意力子层：Q/K/V 共享输入为 $2BSH$ ，计算得到的 Q/K/V 大小均为 $2BSH$ ，共计 $6BSH$ ，计算 QK^T 后进行 softmax 的中间结果为 $2BAS^2$ ，Dropout 的 mask 为 BAS^2 ，Dropout 的输出为 $2BAS^2$ ，最后与 V 相乘的中间结果为 $2BAS$ ，最后的 Dropout 的 mask 矩阵为 BSH ，合计

$$N_{\text{attn}} = 11BSH + 5BAS^2. \quad (4.1)$$

表 4.3 4.2.2 节主要符号说明

符号	含义
B	batch size
S	输入序列长度
H	模型隐藏维度
A	注意力头数。
X	输入张量，形状为 $[B, S, H]$ 。
h_1	注意力子层与残差连接后的中间张量，形状为 $[B, S, H]$ 。
N_{attn}	单个注意力子层为反向传播保留的中间激活总量。
N_{mlp}	单个 MLP 子层为反向传播保留的中间激活总量。
N_{ln}	单个 LayerNorm 子层为反向传播保留的中间激活总量。
N_{None}	不采用重计算时，单层 Transformer 需保留的中间激活总量。
$N_{\text{selective}}^{\text{core_attn}}$	仅对 core_attn 使用 selective 重计算时，单层需保留的中间激活总量。
$N_{\text{selective}}^{\text{core_attn+mlp}}$	对 core_attn 与 mlp 使用 selective 重计算时，单层需保留的中间激活总量。
$N_{\text{selective}}^{\text{core_attn+mlp+ln}}$	对 core_attn、mlp 与 layernorm 使用 selective 重计算时，单层需保留的中间激活总量。
N_{full}	采用 full 重计算时，单层需保留的中间激活总量。

其中 $5BAS^2$ 来自 $QK^\top$ 、softmax 及 dropout 等，随序列长度平方增长，成为长序列输入时中间激活的主要来源。图 4.1 详细分析了注意力子层在 None 情形下需保存的中间激活及其大小。

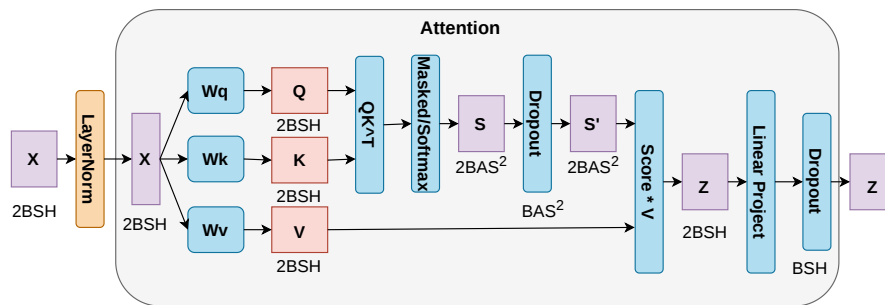


图 4.1 注意力子层中间激活示意

MLP 子层：中间维度 $4H$ ，第一个线性层的输入为 $2BSH$ ，需要保存的输出为 $8BSH$ ，经过中间激活后第二个线性层的输入为 $8BSH$ ，最后的 Dropout 层的 mask 矩阵为 BSH ，合计

$$N_{\text{mlp}} = 19BSH. \quad (4.2)$$

图 4.2 给出了 MLP 子层在 None 情形下需保存的中间激活及其大小。




图 4.2 MLP 子层中间激活示意

两个 LayerNorm （注意力前、MLP 前）各保存输入 $2BSH$ ，合计

$$N_{\text{ln}} = 4BSH. \quad (4.3)$$

于是，不采用重计算时单层需保存的中间激活总量为

$$N_{\text{None}} = N_{\text{attn}} + N_{\text{mlp}} + N_{\text{ln}} = 34BSH + 5BAS^2. \quad (4.4)$$

其中 $5BAS^2$ 项随序列长度平方增长，可能成为长序列场景下中间激活显存的主要来源。

(2) 选择重计算 (selective)。仅对指定子模块做重计算：前向只保存该子模块的输入，反向传播时在子模块内部重新前向传播再反传，其它未开启重计算的子模块仍按 None 情形完整保存中间激活。以仅对 `core_attn` 开启选择重计算为例，注意力子层在 None 情形下需要 $N_{\text{attn}} = 11BSH + 5BAS^2$ 大小的显存空间来存储中间激活值；对 `core_attn` 做选择重计算之后，Attention 块内部的中间激活 (QK^T 、softmax 及其 dropout mask 矩阵等) 都不再常驻显存，只保留该子模块的输入张量 (层输入和 LN 输出) 以便在反向传播重新计算注意力块本身；MLP 子层与两个 LayerNorm 的激活仍按照 N_{mlp} 与 N_{ln} 的代价保存，因此整层的线性部分从 $34BSH + 5BAS^2$ 约减少为 $23BSH$ 。

若在此基础上进一步对 `mlp` 开启选择重计算，则 MLP 内部的 $19BSH$ 激活也改为在反向传播时重算，只需要让输入的张量常驻显存，此时需要保存的中间激活总量进一步降低为 $6BSH$ 。再将 `layernorm` 纳入 `recompute_modules` 时，

其输出在前向结束后同样可以丢弃，仅保留必要的输入，需要保存的中间激活总量进一步降低为 $4BSH$ 。为便于与 None 情形直观对比，本文用

$$N_{\text{selective}}^{\text{core_attn}} = 23BSH, \quad (4.5)$$

$$N_{\text{selective}}^{\text{core_attn+mlp}} = 6BSH, \quad (4.6)$$

$$N_{\text{selective}}^{\text{core_attn+mlp+ln}} = 4BSH. \quad (4.7)$$

来表示选择不同重计算模块下需要存储的中间激活占据的显存总量。与 None 相比，选择重计算策略去掉了注意力主体与 MLP 主体中的大部分常驻中间激活，仅保留子模块边界的输入张量，显存开销的复杂度由 $O(BSH + BAS^2)$ 降为 $O(BSH)$ 。

(3) **整层重计算 (full)**。以整层为重计算单元：前向只保存层输入 X ，反向时整层重新前向传播再反向传播计算梯度。故

$$N_{\text{full}} = 2BSH. \quad (4.8)$$

这种情况下的显存占用最小，但反向时需重算整层前向，计算开销最大。

表 4.4 汇总了不采用重计算、选择重计算与整层重计算时单层需保存的中间激活总量。

表 4.4 单层 Transformer 中间激活量

策略	需保存的激活（元素个数）	说明
None	$34BSH + 5BAS^2$	整层所有中间激活均常驻
selective [core_attn]	$23BSH$	仅注意力内部重算，MLP 与 LN 仍常驻
selective [core_attn, mlp]	$6BSH$	注意力与 MLP 内部重算，仅边界与 LN 常驻
selective [core_attn, mlp, layernorm]	$4BSH$	三者均重算，仅两个子模块边界的输入常驻
full	$2BSH$	仅保存层输入，反向时整层重算

4.2.2 异构重计算策略设计

在 MMoH 已完成的流水线划分与设备映射基础上, HR-MMoH 的异构重计算核心思想是: 为每个流水级 (或每台计算设备) 根据其显存上限以及算力, 独立配置重计算粒度与子模块集合, 使显存压力大的流水级采用更激进的检查点以降低 OOM 风险, 显存压力小的流水级采用较保守的配置以减少不必要的重计算开销, 从而在满足显存约束的前提下最小化迭代时间并最大化 GPU 利用率。

输入与约束。 在 MMoH 规划器已完成模型划分与设备映射的前提下, 记流水线并行度为 S , 流水级索引为 $s \in \{1, \dots, S\}$, 流水级 s 映射至设备 d_s 。记设备 d_s 的显存容量上界为 M_s , 相对计算能力系数为 C_s (可由该设备 FLOPs 或实测单流水级迭代时间经归一化得到)。流水级 s 由若干模型块构成; 其在前向与反向传播阶段的激活显存峰值及重计算开销由该流水级所采用的检查点配置 θ_s 唯一确定。配置 θ_s 的取值为: `recompute_granularity` $\in \{\text{None}, \text{full}, \text{selective}\}$; 当为 `full` 时还需指定 `recompute_method` 与 `recompute_num_layers`, 当为 `selective` 时则指定 `recompute_modules` 子模块列表。形式化地, 约束条件为: $\forall s$, 在配置 θ_s 下流水级 s 的激活显存峰值不超过 M_s (可保留安全余量); 优化目标为最小化单次训练迭代时间, 即 $\min \max_s T_s$, 其中 T_s 表示流水级 s 在配置 θ_s 下前向、重计算与反向阶段耗时之和 (含流水级间通信)。

问题求解。 本文采用基于剖析 (profiling) 的配置生成策略。对每一流水级 s , 在与其对应的代表设备上预先测量不同 θ_s 下的激活显存占用与单流水级执行时间 T_s ; 在满足显存约束的可行配置集中, 为流水级 s 选取使 T_s 较小且与相邻流水级时间较为均衡的配置, 以降低瓶颈流水级对整体迭代时间的主导程度。策略可归纳为两类情形: (1) 显存紧张的流水级: 优先采用 `full` + `uniform` 并取较小的 `recompute_num_layers`, 或 `selective` 并采用较完整的 `recompute_modules` (如 `[core_attn, mlp, layernorm]`), 以降低激活显存峰值、避免 OOM; (2) 显存充裕而算力或通信紧张的流水级: 采用 `None`, 或 `selective` 且仅 `[core_attn]`, 或 `full` + `block` 且较小的 `recompute_num_layers`, 以减少不必要的重计算与同步开销。实现上, 在 MMoH 规划器输出流水级划分与设备映射之后, 由 HR-MMoH 配置模块为各流水级生成对应的 `TransformerConfig` 参数 (或等价的环境变量 / 配置文件), 各训练进程 (rank) 在初始化时加载其所属流水级的配置, 从而在保持 Megatron 单卡前向 / 反向语义不变的前提下, 实现按流水级异构的重计算。

与 **MMoH** 的协同。**HR-MMoH** 以 **MMoH** 给出的流水级划分与设备映射为输入，二者形成层次化协作：若在统一检查点策略下某流水级仍出现显存溢出，可将该信息反馈至 **MMoH** 规划器（例如在显存约束中提高该流水级的权重，或对该流水级进行更细粒度的块划分），从而实现划分与显存配置的迭代优化。第三章所述的提前终止调度器在冻结流水级上省略反向计算与梯度通信，与各流水级独立的检查点配置无冲突：冻结流水级可采用较保守的检查点策略以节省计算，非冻结流水级则按显存与算力约束进行均衡配置。

4.3 实验验证

本节从实验设置、实验结果与实验分析三方面对 **HR-MMoH** 的设计动机与配置思路进行说明；完整端到端实现及与 **MMoH** 的联合吞吐对比可作为后续工作深化。

4.3.1 实验设置

平台与配置思路验证。 实验环境与第三章 **MMoH** 实验一致，采用两种异构集群（**Cluster-S**、**Cluster-L**）及两种 **MLLM**（**MLLM-3B**、**MLLM-12B**）。为验证“按流水级差异化配置”的合理性，对 **MMoH** 划分得到的各流水级进行显存与耗时剖析：在每流水级对应的设备上，分别测量 `recompute_granularity=None`、`selective` 且 `recompute_modules=[core_attn]`、`[core_attn, mlp]`、`[core_attn, mlp, layernorm]` 以及 `full + uniform` 且不同 `recompute_num_layers` 下的激活峰值与单流水级前向 + 反向时间（含重算）。据此可得到各流水级在满足显存约束下的可选配置集合及对应的 T_s ，用于验证显存紧张流水级与充裕流水级在“最省显存”与“最少重算”配置上的差异是否显著，以及按流水级赋配置后各 T_s 是否更均衡。

对比与指标。 重计算的对比基线为全局统一配置：所有流水级不采用重计算，记为 `no-recomp`；所有流水级采用相同的 `full recomputation`，即在前向传播中丢弃所有的中激活值，记为 `full`；所有流水级采用相同的 `selective + [core_attn]` 或 `[core_attn, mlp, layernorm]`（记为 `select-1` 与 `select-2`）。指标包括：（1）各流水级在满足显存不溢出条件下的显存占用峰值与单流水级耗时 T_s ；（2）完整训练循环的训练吞吐（`samples/s` 和迭代时间 `s/iteration`）。

4.3.2 实验结果

在 MMoH 对 MLLM-3B / MLLM-12B 的划分结果上，对各流水级进行上述剖析后可观察到：显存相对紧张流水级（如承载 LLM 中段或大 block 的流水级）在 `recompute_granularity=None` 或仅 `[core_attn]` 时易接近或超出设备显存上限，需采用 `[core_attn, mlp, layernorm]` 或 `full+uniform` 方能安全训练；而显存充裕流水级（如部分编码器或投影层所在流水级）采用 `[core_attn, mlp, layernorm]` 会带来不必要的重算，单流水级耗时 T_s 明显增加。按流水级赋予差异化配置（显存紧张流水级用较激进检查点，充裕流水级用较保守检查点）后，各流水级 T_s 的方差较 Uniform-1 / Uniform-3 有所下降，迭代时间 $\max_s T_s$ 在多数场景下优于或接近“为照顾最紧张流水级而全局采用 Uniform-3”的配置，说明异构感知的配置策略在理论上能够兼顾显存安全与负载均衡。完整训练循环下的吞吐对比有待在 HR-MMoH 与 Megatron/MMoH 的深度集成实现后进一步报告。

4.3.3 实验分析

显存—算力权衡。 异构集群上各流水级显存与算力分布不均，统一配置要么为防 OOM 而整体偏保守导致重算过多，要么为减重算而整体偏激进导致瓶颈流水级 OOM。按流水级配置后，可在满足各流水级显存约束的前提下，将“重算预算”更多分配给显存紧张、算力相对充裕的流水级，从而在系统层面降低迭代时间。

与 MMoH 划分的配合。 MMoH 的复合粒度与冻结感知划分已使各流水级负载趋于均衡；HR-MMoH 在此基础上对显存维度做细粒度调节，二者结合可形成“划分—调度—显存优化”的闭环。未来工作可将 HR-MMoH 的配置搜索与 MMoH 的整数规划联合建模，或采用分层决策：先由 MMoH 确定划分与映射，再由 HR-MMoH 模块为各流水级输出推荐配置并可选地反馈显存不足信息以触发重新划分。

4.4 本章小结

本章在 MMoH 的异构流水线划分与提前终止调度基础上，针对显存受限流水级仍可能 OOM、而现有重计算策略多采用全局统一配置难以兼顾显存与效率的问题，介绍了 HR-MMoH 的异构重计算思路。首先系统梳理了 Megatron-LM 的重计算配置参数（`recompute_granularity`、`recompute_method`、`recompute_num_layers`、`recompute_modules` 等）及其 `full/selective` 粒度与层级划分方式，并指出其在同构假设下的局限；随后给出了 HR-MMoH 的设计要点：以各流水级显存上限、算力为约束，为各流水级独立配置重计算粒度

与子模块集合，通过基于剖析的配置策略在满足显存不溢出的前提下最小化迭代时间并平衡各流水级负载，并与 MMoH 划分及提前终止调度器协同。实验部分说明了配置思路的验证方式与预期效果，并指出完整端到端实现与联合吞吐对比可作为后续工作。HR-MMoH 与第三章的 MMoH 共同构成“划分—调度—显存优化”的联合优化框架，为异构 GPU 集群上 MLLM 的高效训练提供了显存维度的补充手段。

第五章 总结与展望

本章对全文工作进行总结，概括主要创新点与研究的局限性，并对未来研究方向进行展望。

5.1 全文工作总结

本文围绕“面向异构 GPU 集群的多模态大语言模型并行训练策略”这一主题，针对实际环境中普遍存在的设备异构（显存、算力、通信）与 MLLM 的模块异构、分阶段冻结等特性，从流水线划分与调度与显存优化两个层面开展了研究，提出了 MMoH 与 HR-MMoH 两套方法，并在异构集群上进行了实验验证。下文从主要创新点与研究的局限性两方面进行总结。

5.1.1 主要创新点

本文的主要创新点可归纳为以下两方面。

（1）MMoH：面向异构 GPU 集群的 MLLM 高效混合并行框架。

针对异构集群上 MLLM 训练时存在的负载不均衡、资源利用率低以及冻结场景下冗余计算与通信等问题，本文提出了 MMoH 框架。其创新点包括：需求驱动的设备拓扑识别，根据 MLLM 各模块的计算与显存需求趋势与异构设备的算力—显存供给进行匹配，筛选候选设备拓扑，使需求与供给在趋势上一致；复合粒度模型抽象，针对编码器、投影层与 LLM 骨干的结构差异，采用多级粒度将模型重组为模型块列表（编码器按子模块合并、LLM 按注意力/FFN 子层拆分），在划分复杂度与负载均衡之间取得折中；冻结感知的模型划分，将块到阶段的分配形式化为整数规划问题，在满足显存与主阶段约束下最小化迭代时间，且目标函数显式依赖各阶段的冻结状态，从而随训练阶段动态调整划分策略；提前终止调度器，在 1F1B 等流水线调度基础上，识别从首端开始的连续冻结阶段并对其省略反向计算与阶段间通信，在保持梯度传播数学等价性的前提下提升吞吐。在两种异构集群（Cluster-S、Cluster-L）与两种规模 MLLM（MLLM-3B、MLLM-12B）上的实验表明，MMoH 在 no-freeze、freeze-encoder、freeze-LLM、freeze-both 四种场景下相对 Megatron-LM、Whale、Espresso 均可取得最高吞吐，最高可达约 $1.77\times$ 加速，且提前终止调度器在冻结场景下可带来约 8%–19% 的额外增益，并具有良好的可移植性。

（2）HR-MMoH：面向异构设备与异构模型的重计算策略优化。

针对现有重计算策略在同构假设下采用全局统一配置、难以在异构集群上同时兼顾显存安全与计算效率的问题，本文在 MMoH 的划分与调度基础上，提

出了 HR-MMoH 的异构激活重计算思路：使各流水线阶段或各设备根据自身显存与算力条件采用差异化的重计算粒度（如 full/selective）与子模块选择（如 `recompute_modules`），在降低 OOM 风险的同时尽量减少多余重算、平衡各阶段计算负载，与 MMoH 形成“划分—调度—显存优化”的联合优化。本文系统梳理了 Megatron-LM 的激活重计算配置参数（`recompute_granularity`、`recompute_method`、`recompute_num_layers`、`recompute_modules` 等）与同构策略的局限，为异构环境下按阶段 / 设备差异化配置激活重计算提供了动机与设计依据；HR-MMoH 的完整实现与大规模实验验证可作为后续工作的重点。

综上，本文在异构 GPU 集群上 MLLM 并行训练这一方向上，从划分与调度与显存优化两条线给出了系统性的方法设计与实验支撑，为实际部署中的混合集群与分阶段训练场景提供了可参考的技术路径。

5.1.2 研究的局限性

本研究仍存在以下局限性，值得在后续工作中改进。

（1）MMoH 方面。规划器中的整数规划求解在模型层数与设备数较大时可能面临组合爆炸，当前采用启发式或商用求解器在有限时间内求近似解，最优性保证与可扩展性仍有提升空间；需求—供给匹配度度量的设计较多依赖经验与实验调参，缺乏严格的理论分析；实验仅在两种规模的 MLLM（3B、12B）与两种异构集群配置上进行，对更大规模模型（如 70B+）、更多代际与型号混合的集群以及更长序列、更多模态的 MLLM 的泛化能力有待进一步验证；与 ZeRO 等显存分片策略的深度结合（如 ZeRO 与 MMoH 划分的联合优化）尚未系统展开。

（2）HR-MMoH 方面。第四章给出了异构激活重计算的动机、Megatron 现状梳理与设计思路，但异构环境下“按阶段 / 设备差异化配置”的具体算法（如如何根据各阶段显存与算力自动搜索或推荐 `recompute_granularity`、`recompute_num_layers`、`recompute_modules` 等）及在真实训练流水线中的集成与实验验证尚未完整呈现，与 MMoH 划分及提前终止调度器的联合优化效果有待通过端到端实验量化。

（3）通用性方面。当前工作主要针对视觉—语言类 MLLM 与 NVIDIA GPU 生态，对音频、视频等多模态输入、MoE 结构、以及 AMD、国产 GPU 等异构硬件与软件栈的适配与评估尚未涉及；与自动混合精度、序列并行、上下文并行等已有技术的协同优化仍有扩展空间。

5.2 未来工作展望

结合上述总结与局限性，从理论深化与应用拓展两方面对后续研究进行展望。

5.2.1 理论深化

在理论层面，可从以下方向深化。

(1) **划分与调度的形式化分析与优化**。对 MLLM 在异构流水线上的“需求—供给”匹配建立更形式化的度量（如基于负载方差、瓶颈阶段占比等），并研究其与迭代时间、吞吐之间的定量关系；对冻结场景下提前终止的通信与计算节省给出上界分析；探索在保证近似比或 regret 意义下的在线 / 自适应划分与调度算法，以应对训练过程中阶段切换与资源波动。

(2) **激活重计算的自动配置与联合优化**。将 HR-MMoH 的设计思路落实为可执行的策略搜索或配置推荐算法：以各阶段显存上限、算力与通信负载为输入，在满足显存不溢出的约束下，为各阶段自动选择重计算粒度与子模块集合，并最小化重算带来的额外时间或对流水线气泡的影响；进一步将激活重计算与 MMoH 的划分、提前终止调度联合建模为统一的优化问题（如分层决策：先划分与调度，再按阶段配置检查点），通过联合搜索或迭代优化提升端到端吞吐。

(3) **与 ZeRO、混合精度等的联合优化**。研究在异构集群上 ZeRO 分片与 MMoH 流水线划分的协同：例如不同阶段采用不同 ZeRO 阶段或不同分片策略，以匹配各设备显存与通信能力；将激活重计算与混合精度、序列并行、上下文并行等纳入同一决策空间，形成“划分—调度—显存—精度”的一体化配置框架，并给出可扩展的求解或搜索方法。

5.2.2 应用拓展

在应用层面，可从以下方向拓展。

(1) **更大规模模型与更多模态**。在 70B 及以上参数规模的 MLLM、更长序列（如 32K+ token）以及视频、音频等多模态输入上验证 MMoH 与 HR-MMoH 的可扩展性；针对 MoE 结构、多阶段生成（如扩散模型与 LLM 联合训练）等复杂计算图，扩展复合粒度抽象与冻结感知划分的建模方式，并设计相应的调度与显存优化策略。

(2) **多硬件与多框架支持**。将设备能力建模与拓扑识别扩展到 AMD GPU、国产加速卡以及 CPU—GPU 混合节点，抽象统一的“算力—显存—带宽”供给描述，并在多后端（如 PyTorch、Megatron、DeepSpeed 等）上实现或对接 MMoH 的划分与调度逻辑，形成可复用的异构 MLLM 训练工具链。

(3) **从训练到推理与部署**。将异构感知的划分与调度思想延伸至大模型与 MLLM 的推理与部署阶段：例如在异构边缘—云集群上对模型进行分层放置与动态调度，在满足延迟与吞吐要求的前提下降低资源占用与成本；探索训练阶段得到的划分与设备映射对后续推理拓扑设计的借鉴意义，形成训练—推理一致的高

效异构部署方案。

综上所述，本文在面向异构 GPU 集群的 MLLM 并行训练策略方面取得了阶段性成果，但仍有许多理论问题与应用场景有待深入。期望后续工作能够在形式化分析、激活重计算的完整实现与联合优化、以及更大规模与多硬件生态的验证上继续推进，为多模态大模型在异构环境下的高效训练与部署提供更完善的技术支撑。

致 谢

衷心感谢国防科大！

参考文献

- [1] Miao X, Wang Y, Jiang Y, et al. Galvatron: Efficient Transformer Training over Multiple GPUs Using Automatic Parallelism [J]. Proceedings of the VLDB Endowment. 2022, 16 (3): 470–479.
- [2] Vaswani A, Shazeer N, Parmar N, et al. Attention is All You Need [C]. Advances in Neural Information Processing Systems. 2017.
- [3] Devlin J, Chang M-W, Lee K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding [C]. Proceedings of NAACL-HLT. 2019: 4171–4186.
- [4] Radford A, Wu J, Child R, et al. Language Models are Unsupervised Multitask Learners [J]. OpenAI blog. 2019, 1 (8): 9.
- [5] Raffel C, Shazeer N, Roberts A, et al. Exploring the Limits of Transfer Learning with a Unified Text-to-text Transformer [J]. Journal of Machine Learning Research. 2020, 21 (1): 5485–5551.
- [6] Brown T, Mann B, Ryder N, et al. Language Models are Few-shot Learners [J]. Advances in Neural Information Processing Systems. 2020, 33: 1877–1901.
- [7] OpenAI. GPT-4 Technical Report [J]. arXiv.org. 2023. 2023-03-15.
- [8] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale [C]. International Conference on Learning Representations. 2020.
- [9] Zhai X, Kolesnikov A, Houlsby N, et al. Scaling Vision Transformers [J]. 2022: 12104–12113.
- [10] Radford A, Kim J W, Hallacy C, et al. Learning Transferable Visual Models from Natural Language Supervision [C]. International Conference on Machine Learning. 2021: 8748–8763.
- [11] Ramesh A, Pavlov M, Goh G, et al. Zero-shot Text-to-image Generation [C]. International Conference on Machine Learning. 2021: 8821–8831.
- [12] Li J, Li D, Savarese S, et al. BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models [J]. International Conference on Machine Learning. 2023: 19730–19742.
- [13] Liu H, Li C, Wu Q, et al. Visual Instruction Tuning [J]. Advances in Neural Information Processing Systems. 2023, 36.

- [14] Alayrac J-B, Donahue J, Luc P, et al. Flamingo: a Visual Language Model for Few-shot Learning [J]. *Advances in Neural Information Processing Systems*. 2022, 35: 23716–23736.
- [15] Dai W, Li J, Li D, et al. InstructBLIP: Towards General-purpose Vision-Language Models with Instruction Tuning [C]. *Advances in Neural Information Processing Systems (NeurIPS)*. 2023: 49250–49267.
- [16] Liu H, Li C, Wu Q, et al. Improved Baselines with Visual Instruction Tuning [J]. *arXiv preprint arXiv:2310.03744*. 2023. LLaVA-1.5.
- [17] Bai J, Bai S, Chu Y, et al. Qwen-VL: A Versatile Vision-Language Model for Understanding, Localization, Text Reading, and Beyond [J]. *arXiv preprint arXiv:2308.12966*. 2023.
- [18] Chen Z, Wu J, Wang W, et al. InternVL: Scaling up Vision Foundation Models and Aligning for Generic Visual-Language Tasks [C]. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2024: 13142–13153.
- [19] Zhu D, Chen J, Shen X, et al. MiniGPT-4: Enhancing Vision-language Understanding with Advanced Large Language Models [J]. *arXiv preprint arXiv:2304.10592*. 2023.
- [20] Liang Y, et al. The Revolution of Multimodal Large Language Models: A Survey [C]. *Findings of the Association for Computational Linguistics: ACL 2024*. 2024.
- [21] Wang Z, et al. Embodied Multimodal Agents: A Survey [J]. *arXiv preprint*. 2024.
- [22] Wu C, et al. Medical Vision-Language Models: A Survey [J]. *arXiv preprint arXiv:2312.06203*. 2024.
- [23] Lu P, et al. MathVista: Evaluating Mathematical Reasoning in Visual Contexts [J]. *arXiv preprint arXiv:2310.02255*. 2024.
- [24] Goyal Y, Khanna G, Gupta A, et al. Making the V in VQA Matter: Elevating the Role of Image Understanding in Visual Question Answering [C]. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017: 6904–6913.
- [25] Hudson D A, Manning C D. GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering [C]. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2019: 6700–6709.
- [26] Yue X, Ni Y, Zhang K, et al. MMMU: A Massive Multi-discipline Multimodal Understanding and Reasoning Benchmark for Expert AGI [J]. *arXiv preprint arXiv:2311.14402*. 2024.

- [27] Kaplan J, McCandlish S, Henighan T, et al. Scaling Laws for Neural Language Models [J]. arXiv preprint arXiv:2001.08361. 2020.
- [28] Hoffmann J, Borgeaud S, Mensch A, et al. Training Compute-Optimal Large Language Models [C]. Advances in Neural Information Processing Systems (NeurIPS). 2022: 30016–30030.
- [29] Sardana N, Frankle J. Beyond Chinchilla-Optimal: Accounting for Inference in Language Model Scaling Laws [C]. Proceedings of the International Conference on Machine Learning (ICML). 2024: 29891–29922.
- [30] Rae J W, et al. Scaling Language Models: Methods, Analysis and Insights from Training Gopher [J]. arXiv preprint arXiv:2112.11446. 2022.
- [31] DeepSeek-AI. DeepSeek LLM: Scaling Open-Source Language Models with Longtermism [J]. arXiv preprint arXiv:2401.02954. 2024.
- [32] Yang A, Yang B, Hui B, et al. Qwen2 Technical Report [J]. arXiv preprint arXiv:2407.10671. 2024.
- [33] Touvron H, Martin L, Stone K, et al. Llama 2: Open Foundation and Fine-tuned Chat Models [J]. arXiv preprint arXiv:2307.09288. 2023.
- [34] Dubey A, Jauhri A, Pandey A, et al. The LLaMA 3 Herd of Models [J]. arXiv preprint arXiv:2407.21783. 2024.
- [35] Team G, et al. Gemma: Open Models Based on Gemini Research and Technology [J]. arXiv preprint arXiv:2403.08295. 2024.
- [36] Jiang A Q, Sablayrolles A, Mensch A, et al. Mistral 7B [J]. arXiv preprint arXiv:2310.06825. 2023.
- [37] Narayanan D, Shoeybi M, Casper J, et al. Efficient Large-scale Language Model Training on GPU Clusters Using Megatron-LM [C]. Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis. 2021: 1–15.
- [38] Shoeybi M, Patwary M, Puri R, et al. Megatron-LM: Training Multi-Billion Parameter Language Models Using Model Parallelism [J]. arXiv preprint. 2020.
- [39] Xie S, et al. Data Selection for Language Models via Importance Resampling [J]. Advances in Neural Information Processing Systems (NeurIPS). 2023, 36.
- [40] Bai Y, et al. LongBench: A Bilingual, Multitask Benchmark for Long Context Understanding [J]. arXiv preprint arXiv:2308.14508. 2024.
- [41] Rajbhandari S, Rasley J, Ruwase O, et al. ZeRO: Memory Optimizations Toward Training Trillion Parameter Models [C]. SC20: International Conference for High

Performance Computing, Networking, Storage and Analysis. 2020: 1–16.

[42] Rajbhandari S, Ruwase O, Rasley J, et al. ZeRO-Infinity: Breaking the GPU Memory Wall for Extreme Scale Deep Learning [J]. arXiv preprint. 2021.

[43] Li S, Zhao Y, Varma R, et al. PyTorch Distributed: Experiences on Accelerating Data Parallel Training [J]. Proceedings of the VLDB Endowment. 2020, 13 (12): 3005–3018.

[44] Sergeev A, Del Balso M. Horovod: Fast and Easy Distributed Deep Learning in TensorFlow [J]. arXiv preprint. 2018.

[45] Huang Y, Cheng Y, Bapna A, et al. GPipe: Efficient Training of Giant Neural Networks using Pipeline Parallelism [J]. arXiv preprint. 2019.

[46] Narayanan D, Harlap A, Phanishayee A, et al. PipeDream: Generalized Pipeline Parallelism for DNN Training [C]. Proceedings of the 27th ACM Symposium on Operating Systems Principles. 2019: 1–15.

[47] Chen Z, Lepikhin D D, Lee H, et al. GShard: Scaling Giant Models with Conditional Computation and Automatic Sharding [J]. 2020.

[48] Wang G, Qin H, Jacobs S A, et al. ZeRO++: Extremely Efficient Collective Communication for Giant Model Training [J]. arXiv preprint. 2023.

[49] Micikevicius P, Narang S, Alben J, et al. Mixed Precision Training [C]. International Conference on Learning Representations. 2018.

[50] Liu Y, Li S, Fang J, et al. Colossal-Auto: Unified Automation of Parallelization and Activation Checkpoint for Large-scale Models [J]. arXiv preprint. 2023.

[51] Dao T, Fu D Y, Ermon S, et al. FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness [C]. Advances in Neural Information Processing Systems (NeurIPS). 2022: 16344–16359.

[52] Dao T, Fu D Y, Ermon S, et al. FlashAttention-3: Fast and Accurate Attention with Asynchrony and Low-precision [C]. Advances in Neural Information Processing Systems (NeurIPS). 2024.

[53] Zhao Y, Gu A, Varma R, et al. PyTorch FSDP: Experiences on Scaling Fully Sharded Data Parallel [C]. Proceedings of the International Conference on Very Large Data Bases (VLDB). 2023: 3846–3856. PyTorch Native FSDP, 2022.

[54] Jia X, Jiang L, Wang A, et al. Whale: Efficient Giant Model Training over Heterogeneous GPUs [J]. 2022.

[55] Park J H, Yun G, Chang M Y, et al. HetPipe: Enabling Large DNN Training on (Whimpy) Heterogeneous GPU Clusters through Integration of Pipelined Model Paral-

lelism and Data Parallelism [C]. 2020 USENIX Annual Technical Conference (USENIX ATC 20). 2020: 307–321.

[56] NVIDIA Corporation. NVIDIA A100 Tensor Core GPU Architecture [R]. 2020. Ampere Architecture.

[57] NVIDIA Corporation. NVIDIA H100 Tensor Core GPU Architecture [R]. 2022. Hopper Architecture.

[58] NVIDIA Corporation. NVIDIA Blackwell Architecture and GPU Roadmap [R]. 2024. GTC 2024.

[59] Rombach R, Blattmann A, Lorenz D, et al. High-resolution Image Synthesis with Latent Diffusion Models [C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 10684–10695.

[60] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation [C]. Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015. 2015: 234–241.

[61] Wu S, Fei H, Qu L, et al. Next-GPT: Any-to-any Multimodal LLM [J]. arXiv preprint arXiv:2309.05519. 2023.

[62] Dong R, Han C, Peng Y, et al. DreamLLM: Synergistic Multimodal Comprehension and Creation [J]. arXiv preprint arXiv:2309.11499. 2023.

[63] Kingma D P, Ba J. Adam: A Method for Stochastic Optimization [C]. International Conference on Learning Representations (ICLR). 2015. arXiv:1412.6980, 2014.

[64] Yu Z, et al. Frenzy: Memory-aware Serverless Scheduling for Large Model Training [J]. arXiv preprint. 2024.

[65] Li S, et al. Towards Scalable and Reliable LLM Training on Public Cloud [J]. arXiv preprint. 2024.

[66] NVIDIA Corporation. NVIDIA AI Training: Best Practices for Large Language Models [J]. 2024. GTC / Developer Blog.

[67] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-Rank Adaptation of Large Language Models [C]. International Conference on Learning Representations (ICLR). 2022. arXiv:2106.09685, 2021.

[68] Dettmers T, Pagnoni A, Holtzman A, et al. QLoRA: Efficient Finetuning of Quantized LLMs [J]. Advances in Neural Information Processing Systems (NeurIPS). 2023, 36.

[69] Lialin V, Deshpande V, et al. Scaling Down to Scale Up: A Guide to Parameter-Efficient Fine-Tuning [J]. arXiv preprint arXiv:2303.15647. 2024.

- [70] Schuhmann C, Beaumont R, Vencu R, et al. LAION-5B: An Open Large-Scale Dataset for Training Next Generation Image-Text Models [C]. Advances in Neural Information Processing Systems (NeurIPS) Datasets and Benchmarks Track. 2022. arXiv:2210.08402.
- [71] Zhang Y, et al. A Comprehensive Survey and Guide to Multimodal Large Language Models in Vision-Language Tasks [C]. arXiv preprint arXiv:2411.06284. 2024.
- [72] Zhou B, Khashabi D, et al. A Survey of Multimodal Large Language Model from A Data-centric Perspective [J]. arXiv preprint arXiv:2405.10739. 2024.
- [73] Kuznetsova A, Rom H, Alldrin N, et al. The Open Images Dataset V4: Unified Image Classification, Object Detection, and Visual Relationship Detection at Scale [J]. International Journal of Computer Vision. 2020, 128 (7): 1956–1981.
- [74] Lin T-Y, Maire M, Belongie S, et al. Microsoft COCO: Common Objects in Context [C]. European Conference on Computer Vision (ECCV). 2014: 740–755.
- [75] Gao L, Biderman S, Black S, et al. The Pile: An 800GB Dataset of Diverse Text for Language Modeling [J]. arXiv preprint arXiv:2101.00027. 2020.
- [76] Abu-El-Haija S, Kothari N, Lee J, et al. YouTube-8M: A Large-Scale Video Classification Benchmark [J]. 2016.
- [77] Bain M, Nagrani A, Varol G, et al. Frozen in Time: A Joint Video and Image Encoder for End-to-End Retrieval [J]. arXiv preprint arXiv:2104.00650. 2021.
- [78] Singh A, Natarajan V, Shah M, et al. Towards VQA Models That Can Read [C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 8317–8326.
- [79] Jin X, Li Y, Gu Y, et al. Efficient Multimodal Large Language Models: A Survey [J]. Visual Intelligence. 2025. arXiv:2405.10739.
- [80] Korthikanti V A, Casper J, Lym S, et al. Reducing Activation Recomputation in Large Transformer Models [C]. Proceedings of Machine Learning and Systems (MLSys). 2023: 1–20.
- [81] Li D, Wang H, Xing E, et al. AMP: Automatically Finding Model Parallel Strategies with Heterogeneity Awareness [C]. Advances in Neural Information Processing Systems. 2022: 6630–6639.
- [82] Xu S, Huang Z, Zeng Y, et al. HETHUB: A Distributed Training System with Heterogeneous Cluster for Large-Scale Models [J]. arXiv preprint arXiv:2405.16256. 2024.
- [83] Yan R, Jiang Y, Nie X, et al. HexiScale: Accommodating Large Language

Model Training over Heterogeneous Environment [J]. arXiv preprint arXiv:2409.01143. 2024.

[84] iCloud Lab, ECNU. Espresso: Cost-efficient Resource Provisioning for Large Model Training on Heterogeneous GPU Clusters. <https://github.com/icloud-ecnu/Espresso>. 2025. Heterogeneous GPU allocation and stage placement for distributed training.

[85] Guo R B, Anand U, Daudjee K, et al. Zorse: Optimizing LLM Training Efficiency on Heterogeneous GPU Clusters [J]. arXiv preprint arXiv:2507.10392. 2025.

[86] Guo R B, Anand U, Chen A, et al. Cephalo: Harnessing Heterogeneous GPU Clusters for Training Transformer Models [C]. Proceedings of the International Conference on Supercomputing (ICS). 2025. arXiv:2411.01075, 2024.

[87] Zhang Z, Zheng S, Wang Y, et al. MiCS: Near-linear Scaling for Training Gigantic Model on Public Cloud [J]. Proceedings of the VLDB Endowment. 2022, 16 (1): 37–50.

[88] Chen Q, Hu Q, Ye Z, et al. AMSP: Super-Scaling LLM Training via Advanced Model States Partitioning [J]. arXiv preprint. 2023.

[89] Fan J, Lai Z, Liu W, et al. MMoH: Efficient Training of Multimodal Large Language Models on Heterogeneous Clusters [C]. Proceedings of IEEE/ACM International Conference. Changsha, China, 2025.

[90] Zhu L, et al. Vision-Language Pre-training: Basics, Recent Progress, and Future Outlook [J]. Pattern Recognition. 2024.

[91] Liu H, Li C, Wu Q, et al. LLaVA-NeXT: Improved Baselines with Visual Instruction Tuning [J]. arXiv preprint arXiv:2402.12975. 2024.

[92] Team G, et al. Gemini: A Family of Highly Capable Multimodal Models [J]. arXiv preprint arXiv:2312.11805. 2023.

[93] Chowdhery A, Narang S, Devlin J, et al. PaLM: Scaling Language Modeling with Pathways [J]. Journal of Machine Learning Research. 2023, 24. arXiv:2204.02311, 2022.

[94] Li M. Scaling Distributed Machine Learning with the Parameter Server [C]. Proceedings of the 2014 International Conference on Big Data Science and Computing. Beijing, China, 2014: 1–1.

[95] Kim S, Yu G I, Park H, et al. Parallax: Sparsity-aware Data Parallel Training of Deep Neural Networks [C]. Proceedings of the Fourteenth EuroSys Conference. Dresden, Germany, 2019: 1–15.

- [96] Jacobs S A, Khabbazan M, Baydin A G, et al. DeepSpeed Ulysses: System Optimizations for Enabling Training of Extreme Long Sequence Transformer Models [J]. arXiv preprint arXiv:2309.14509. 2023.
- [97] Li Z, Zhuang S, Guo S, et al. TeraPipe: Token-Level Pipeline Parallelism for Training Large-Scale Language Models [J]. arXiv preprint. 2021.
- [98] Li Z, Zhuang S, Guo S, et al. TeraPipe: Token-Level Pipeline Parallelism for Training Large-Scale Language Models [C]. Proceedings of the International Conference on Machine Learning (ICML). 2022.
- [99] Li S, Hoefler T. Chimera: Efficiently Training Large-Scale Neural Networks with Bidirectional Pipelines [J]. Proceedings of the International Conference for High Performance Computing (SC). 2023.
- [100] Li Z, et al. Hanayo: Wave-like Pipeline Parallelism for Efficient Large Model Training [J]. arXiv preprint. 2024.
- [101] Qi P, Wan X, Huang G, et al. Zero Bubble Pipeline Parallelism [C]. International Conference on Learning Representations. 2024.
- [102] DeepSeek-AI. DualPipe: Bidirectional Pipeline Parallelism for Large-Scale Training. <https://github.com/deepseek-ai/DualPipe>. 2025. Accessed: 2025.
- [103] Liu Z, Lin Z, et al. Ring Attention with Blockwise Transformers for Near-Infinite Context [J]. arXiv preprint arXiv:2310.01889. 2024.
- [104] DeepSeek-AI. DeepSeek-MoE: Scaling Mixture-of-Experts Language Models with Limited Resources [J]. arXiv preprint arXiv:2401.06066. 2024.
- [105] Rasley J, et al. DeepSpeed: Extreme-Scale Model Training for Everyone [J]. Microsoft Research Blog. 2022.
- [106] Rasley J, Rajbhandari S, Awni Y, et al. DeepSpeed: System Optimizations Enable Training Deep Learning Models with Over 100 Billion Parameters [J]. Proceedings of the ACM SIGKDD. 2020.
- [107] Chen T, Xu B, Zhang C, et al. Training Deep Nets with Sublinear Memory Cost [J]. arXiv preprint arXiv:1604.06174. 2016.
- [108] Korthikanti V, Casper J, Lym S, et al. Reducing Activation Recomputation in Large Transformer Models [C]. Proceedings of Machine Learning and Systems (MLSys). 2023.
- [109] NVIDIA. Megatron-LM: Activation Recomputation [J]. NVIDIA Deep Learning Documentation. 2024.

[110] NVIDIA. NeMo Framework: Activation Recomputation [J]. NVIDIA NeMo Documentation. 2024.

[111] Li Z, Lin Z, Wang C, et al. Lynx: Efficient Memory Management for Large Model Training with Overlapped Activation Recomputation [J]. arXiv preprint arXiv:2406.08756. 2024.

[112] Liu Y, et al. Colossal-Auto: Unified Automation of Parallelization and Activation Checkpoint for Large-scale Models [J]. Journal of Machine Learning Research. 2023.

[113] Zheng L, et al. Efficient Large Language Model Training: A Survey [J]. arXiv preprint arXiv:2312.03863. 2024.

[114] Li S, et al. A Survey on Distributed Deep Learning [J]. IEEE Access. 2022.

[115] Jia X, et al. Whale: Efficient Giant Model Training over Heterogeneous GPUs [J]. USENIX ATC. 2022.

作者在学期间取得的学术成果

发表的学术论文

[1] 满足毕业条件

公开评阅信息

序号	评阅人	职称	导师类型	工作单位	总分	结论	答辩建议	熟悉程度	备注
1	张三	教授	博导	XXX大学	95.8	达到	无需修改 直接答辩	有深入了解	
2	李四	研究员	硕导	XXX大学	95	达到	修改后 答辩	有深入了解	
3	王五	教授	博导						
4	赵六	教授	博导						
5	孙六	教授	博导	XXX大学	59	尚未达到	修改后 复评	有深入了解	
	孙六	教授	博导	XXX大学	80	尚未达到	无需修改 直接答辩	有深入了解	复评结果

说明：

- 1. 结论选项包括 2 个：“达到博士学位论文要求”、“尚未达到博士学位论文要求”。
- 2. 答辩建议选项包括 4 个：“无需修改直接答辩”、“修改后答辩”、“修改后复评”、“不予答辩”。
- 3. 熟悉程度选项包括 3 个：“有深入了解”、“比较熟悉”、“一般了解”。

提醒（正式成文后删除）：

- 1. 评阅版论文删除此页。
- 2. 采用双盲评阅方式的学位申请人撰写的学位论文删除此页。
- 3. 评阅总分无需取整。
- 4. 工作单位填至学校、科研院所即可。

附录 A 模板提供的希腊字母命令列表

大写希腊字母:

Γ \Gamma	Λ \Lambda	Σ \Sigma	Ψ \Psi
Δ \Delta	Ξ \Xi	Υ \Upsilon	Ω \Omega
Θ \Theta	Π \Pi	Φ \Phi	
Γ \varGamma	Λ \varLambda	Σ \varSigma	Ψ \varPsi
Δ \varDelta	Ξ \varXi	Υ \varUpsilon	Ω \varOmega
Θ \varTheta	Π \varPi	Φ \varPhi	

小写希腊字母:

α \alpha	θ \theta	o o	τ \tau
β \beta	ϑ \vartheta	π \pi	υ \upsilon
γ \gamma	ι \iota	ϖ \varpi	ϕ \phi
δ \delta	κ \kappa	ρ \rho	φ \varphi
ϵ \epsilon	λ \lambda	ϱ \varrho	χ \chi
ε \varepsilon	μ \mu	σ \sigma	ψ \psi
ζ \zeta	ν \nu	ς \varsigma	ω \omega
η \eta	ξ \xi	κ \varkappa	$\digamma$ \digamma
α \upalpha	θ \uptheta	o \mathrm{o}	τ \uptau
β \upbeta	ϑ \upvartheta	π \uppi	υ \upupsilon
γ \upgamma	ι \upiota	ϖ \upvarpi	ϕ \upphi
δ \updelta	κ \upkappa	ρ \uprho	φ \upvarphi
ϵ \upepsilon	λ \uplambda	ϱ \upvarrho	χ \upchi
ε \upvarepsilon	μ \upmu	σ \upsigma	ψ \uppsi
ζ \upzeta	ν \upnu	ς \upvarsigma	ω \upomega
η \upeta	ξ \upxi		

希腊字母属于数学符号类别, 请用\bm命令加粗, 其余向量、矩阵可用\mathbf。