

分类号 TP302

学号

UDC

密级 公开

工学博士学位论文

基于先验模型与深度学习的图像去噪
方法研究

博士生姓名

学科专业 控制科学与工程

研究方向 多媒体信息系统与虚拟现实技术

指导教师

二〇二六年三月

Joint Demosaicing and Denoising of Bayer Images

Candidate:

Supervisor:

A dissertation

Submitted in partial fulfillment of the requirements

for the degree of Ph.D of Engineering

in Control Science and Engineering

March, 2026

目 录

摘 要	i
Abstract	ii
第一章 绪论	1
1.1 研究背景	1
1.1.1 训练多模态大语言模型面临的挑战	1
1.1.2 异构 GPU 集群的并行训练策略	4
1.2 国内外研究现状	7
1.2.1 多模态大语言模型并行训练策略研究现状	7
1.2.2 异构 GPU 集群并行训练策略研究现状	8
1.3 研究内容与贡献	10
1.3.1 MMoH: 多模态大语言模型在异构 GPU 集群上的混合并行	10
1.3.2 HR-MMoH: 多模态大语言模型在异构 GPU 集群上的重计算 .	11
1.4 论文组织结构	11
第二章 相关工作	13
2.1 多模态大语言模型	14
2.1.1 多模态大语言模型的异构架构	14
2.1.2 多模态大语言模型训练数据	15
2.1.3 多模态大语言模型训练过程	16
2.2 并行与分布式训练基础	17
2.2.1 数据并行与模型并行	17
2.2.2 零冗余优化器 (ZeRO)	20
2.3 异构 GPU 集群并行训练策略	21
2.4 重计算显存优化技术	23
2.5 本章小结	26
致谢	27
参考文献	29
作者在学期间取得的学术成果	29
附录 A 本文中英文对照表	30

表 目 录

表 2.1	多模态大语言模型训练中常用的部分数据集规模示意	16
表 A.1	本文主要术语中英文对照表	30

图 目 录

图 1.1	多模态大语言模型的核心组成部分	3
图 1.2	NVIDIA GPU 架构与代表性产品演进	5
图 1.3	使用 Megatron 训练多模态大语言模型	9
图 2.1	MLLM 多阶段训练中典型模块冻结与更新关系示意	17
图 2.2	数据并行示意	18
图 2.3	张量并行示意	18
图 2.4	流水线并行示意	19
图 2.5	专家并行 (EP) 中门控路由与专家分布示意	20
图 2.6	零冗余优化器 ZeRO 示意	21
图 2.7	重计算 (激活检查点) 示意	24

摘 要

多模态大语言模型（MLLM）融合视觉、语言等模态的感知与生成能力，是当前人工智能研究的重要方向，其训练依赖分布式与并行计算。实际部署中的 GPU 集群往往由多代、多型号设备混合组成，存在显存、算力与通信的异构；而 MLLM 在结构上由编码器、投影层与 LLM 骨干等异构模块组成，训练时又广泛采用分阶段冻结策略，导致各阶段计算与显存需求差异显著。现有并行策略（如 Megatron-LM、ZeRO）多假设同构集群与单一模型形态，在异构环境下易产生负载不均衡、资源利用率低及冻结场景下的冗余计算与通信等问题。

本文从流水线划分与调度、显存优化两个层面开展研究。在划分与调度方面，提出 MMoH 框架：通过需求驱动的设备拓扑识别、复合粒度模型抽象与冻结感知的整数规划划分，在给定异构集群与 MLLM 配置下自动生成与当前训练阶段相匹配的流水线并行策略；通过提前终止调度器在连续冻结阶段省略不必要的反向计算与阶段间通信，在保持收敛性的前提下提升吞吐。在显存优化方面，针对现有框架（如 Megatron-LM）中激活重计算采用全局统一配置、在异构集群上难以同时兼顾显存安全与计算效率的问题，提出 HR-MMoH 的异构激活重计算方法：系统梳理 Megatron 的重计算粒度与子模块配置参数，在 MMoH 划分基础上为各流水线阶段根据其显存上限与算力独立配置重计算粒度与子模块集合，显存紧张阶段采用更激进的检查点以降低 OOM 风险，显存充裕阶段采用较保守的配置以减少多余重算，并通过基于剖析的配置策略与 MMoH 形成“划分—调度—显存优化”的联合优化。在两种异构集群与两种规模 MLLM（3B、12B）上的实验表明，MMoH 在多种冻结场景下相对 Megatron-LM、Whale、Espresso 均可取得最高吞吐，最高可达约 1.77 倍加速，提前终止调度器可带来约 8%–19% 的额外增益；HR-MMoH 的按阶段差异化配置思路通过剖析实验得到验证，可为显存受限场景下的训练提供补充手段。本文为异构 GPU 集群上 MLLM 的高效并行训练提供了可参考的技术路径。

关键词: 多模态大语言模型；异构 GPU 集群；流水线并行；激活重计算；MMoH

Abstract

Multimodal large language models (MLLMs) integrate vision, language, and other modalities for perception and generation, and have become a major focus of artificial intelligence research; their training relies on distributed and parallel computing. In practice, GPU clusters are often composed of mixed generations and models of devices, exhibiting heterogeneity in memory, compute, and communication. Meanwhile, MLLMs are architecturally composed of heterogeneous modules such as encoders, projectors, and LLM backbones, and training commonly adopts stage-wise freezing, leading to significant differences in compute and memory demand across pipeline stages. Existing parallel strategies (e.g., Megatron-LM, ZeRO) mostly assume homogeneous clusters and uniform model structure, which in heterogeneous settings can cause load imbalance, low resource utilization, and redundant computation and communication under freezing.

This thesis addresses the problem from two aspects: pipeline partitioning and scheduling, and memory optimization. For partitioning and scheduling, we propose the MMoH framework: it uses demand-driven device topology identification, multi-granularity model abstraction, and freeze-aware integer-programming-based partitioning to automatically generate pipeline-parallel strategies that match the current training stage for a given heterogeneous cluster and MLLM configuration; an early-termination scheduler omits unnecessary backward computation and inter-stage communication at consecutive frozen stages, improving throughput while preserving convergence. For memory optimization, we address the fact that existing frameworks (e.g., Megatron-LM) use a single global activation recomputation configuration, which is ill-suited to heterogeneous clusters where memory-tight stages may still hit OOM while memory-rich stages incur unnecessary recomputation. We propose HR-MMoH with heterogeneous-aware gradient checkpointing: we systematically summarize Megatron’s recomputation granularity and submodule parameters, then assign each pipeline stage an independent recomputation configuration (granularity and submodule set) according to its memory headroom and compute, so that memory-tight stages use more aggressive checkpointing to reduce OOM risk and memory-rich stages use conservative settings to avoid redundant recomputation; a profiling-based configuration strategy is used and integrated with MMoH to form a joint “partitioning–scheduling–memory optimization” pipeline. Experiments on two heteroge-

neous clusters and two MLLM scales (3B and 12B parameters) show that MMoH achieves the highest throughput under various freezing scenarios compared with Megatron-LM, Whale, and Espresso, with speedups of up to about $1.77\times$, and the early-termination scheduler brings an additional 8%–19% gain; the per-stage heterogeneous checkpoint configuration in HR-MMoH is validated via profiling and provides a complementary means for memory-constrained training. This work provides a practical technical path for efficient parallel training of MLLMs on heterogeneous GPU clusters.

Key Words: Multimodal large language model; Heterogeneous GPU cluster; Pipeline parallelism; Gradient checkpointing; MMoH

本文主要符号使用说明

HPC	高性能计算 (High Performance Computing)
cluster	集群
Itanium	安腾
SMP	对称多处理
API	应用程序编程接口
PI	聚酰亚胺
MPI	聚酰亚胺模型化合物, N- 苯基邻苯酰亚胺
PBI	聚苯并咪唑
MPBI	聚苯并咪唑模型化合物, N- 苯基苯并咪唑
PY	聚吡咙
PMDA-BDA	均苯四酸二酐与联苯四胺合成的聚吡咙薄膜
ΔG	活化自由能 (Activation Free Energy)
χ	传输系数 (Transmission Coefficient)
E	能量
m	质量
c	光速
P	概率
T	时间
v	速度

第一章 绪论

1.1 研究背景

1.1.1 训练多模态大语言模型面临的挑战

深度神经网络（Deep Neural Network, DNN）在计算机视觉（Computer Vision, CV）、自然语言处理（Natural Language Processing, NLP）、语音识别（Speech Recognition, SR）等众多领域得到了广泛应用，并逐步演变为诸多关键技术领域的核心基础 [?]。2017 年，Vaswani 等人提出基于自注意力机制（Self-Attention）的 Transformer 架构 [?]，摒弃了传统的循环神经网络（Recurrent Neural Network, RNN）与卷积神经网络（Convolutional Neural Network, CNN）结构，凭借并行化友好与长距离依赖的建模能力，迅速成为自然语言处理与跨模态建模的主流模型结构。

在自然语言处理（Natural Language Processing, NLP）方面，基于 Transformer 的预训练大语言模型（Large Language Models, LLMs）不断刷新各类基准。BERT[?] 通过双向编码与掩码预训练在理解类任务上取得显著优势；GPT-2[?]、T5[?] 等自回归（Autoregressive）或编码器 - 解码器（Encoder-Decoder）模型则在生成与迁移学习（Transfer Learning）上表现突出；GPT-3[?] 与后续的 GPT-4[?] 等大规模语言模型（Large Language Models, LLMs）更在少样本（Few-Shot）与零样本（Zero-Shot）设定下展现出接近人类的泛化能力。在计算机视觉（Computer Vision, CV）领域，Vision Transformer（ViT）[?] 及后续的规模化工作 [?] 表明：将图像切分为块（patch）并经 Transformer 编码，即可在 ImageNet 等基准数据集上超越传统卷积网络。CLIP[?] 通过图文对比学习（Contrastive Language-Image Pre-Training）实现了开放词汇的视觉表征，DALL-E[?] 则展示了从文本到图像生成的可行性。以 Transformer 为基座（Backbone）、依靠规模扩展提升模型能力的技术路线，已在实践中被证明高度有效。随着单模态任务性能的趋于成熟，将视觉、语言、音频等多模态信息纳入统一的模型框架进行联合表示与推理，已成为当前研究的重要演进方向。

多模态（Multimodality）指对两种或两种以上模态信息进行联合表示、推理与生成的技术范畴。在机器学习与人工智能中，常见模态包括文本、图像、视频、音频、表格以及各类传感器数据。多模态大语言模型（Multimodal Large Language Models, MLLMs）特指在参数规模巨大的语言模型基础上，融合对视觉、听觉等非文本模态的感知与生成能力的一类模型 [?]。近年来，MLLMs 在架构与

训练范式上发展迅速：BLIP-2[?] 提出 Q-Former 连接冻结视觉编码器与 LLM；InstructBLIP[?] 在此基础上引入指令感知的视觉特征抽取，在多项零样本任务上取得 SOTA；LLaVA[?] 与 LLaVA-1.5[?] 采用简单线性投影实现视觉与语言模态对齐，验证了“小连接器 + 大模型”的有效性；Qwen-VL[?]、InternVL[?] 等系列模型则进一步在长上下文（Long Context）、高分辨率（High Resolution）与多图理解（Multi-Image Understanding）上扩展模型能力。这类模型既保留 LLMs 在语言理解、推理与生成上的优势，又能够直接处理图像、视频等多模态输入，实现跨模态交互与推理任务，因而被认为是迈向通用人工智能（Artificial General Intelligence, AGI）的潜在路径[?]。模型能力的拓展必然依赖于更加复杂的模块设计：前者决定了 MLLM 的应用边界，后者则直接影响到训练时的计算与显存分布。

从功能表现来看，MLLMs 可完成图像描述（Image Captioning）、视觉问答（Visual Question Answering）、图文对话（Visual-Text Dialog）、文档理解（Document Understanding），以及基于文本的图像或视频生成等任务，在智能助手、自动驾驶、内容创作、教育培训、工业质检等场景具有广阔应用前景。在垂直领域，MLLMs 已延伸至具身智能（Embodied Intelligence）[?]、医疗影像理解（Medical Image Understanding）[?]、科学文档与图表推理[?] 等，相关评估常依托 VQAv2[?]、GQA[?]、MMMUI[?] 等多模态基准，对模型规模与训练数据提出了更高要求。从结构上看，MLLMs 通常包含以下核心组件（见图1.1）：（1）*Modality Encoder*，负责将图像、视频等非文本输入编码为特征表示，常采用预训练的视觉模型（如 CLIP、ViT）作为 backbone；（2）*Input Projector*，将编码后的多模态特征映射到与 LLM 词嵌入对齐的语义空间，常见形式包括线性层、Q-Former[?] 等轻量模块；（3）*LLM Backbone*，即大规模语言模型主体，承担主要的理解与生成计算，参数量通常占整体模型的 80%–90%；（4）*Output Projector*（在需要多模态生成时），将 LLM 输出映射到与目标模态生成器对齐的表示空间；（5）*Modality Generator*（在需要多模态生成时），根据投影表示生成图像、音频等目标模态，常采用扩散模型（如 Stable Diffusion）等。可见，LLMs 处于 MLLMs 架构的核心，多模态能力是在其基础上进行的扩展与增强；在大语言模型占据主体参数量的架构下，针对 LLMs 归纳出的扩展定律（Scaling Laws）与数据规模规律，同样深刻影响着 MLLMs 训练的资源需求。

已有实证研究表明，模型性能通常会随参数规模与训练数据规模的增加而稳定提升，这一现象被总结为“扩展定律”（Scaling Laws）[?]。Kaplan 等[?] 的早期工作表明，在给定算力预算下，模型规模与数据规模应按幂律关系共同扩展；Hoffmann 等[?] 在 Chinchilla 工作中进一步指出，当前大语言模型普遍“训练不




图 1.1 多模态大语言模型的核心组成部分

足”，在计算最优意义下，模型参数量与训练 token 数应近似同比例扩展（约 20 倍 token/ 参数），该结论对预训练数据规模与模型架构选择产生了深远影响；近期工作 [?] 则从推理成本角度拓展了 Chinchilla 最优，指出在考虑部署与推理时，最优扩展策略会随推理请求规模发生变化。为追求更强性能，工业界与学术界不断推出参数量更大、数据规模更大的模型，从数亿参数（如 BERT）到千亿、万亿参数（如 GPT-3、Gopher[?]、DeepSeek-V3[?]、Qwen2.5[?]、LLaMA 2/3[?]、Gemma[?]、Mistral[?] 等开源与闭源 LLMs），单卡或单机 GPU 的显存与算力已无法容纳整模型的完整训练流程 [?]。相应的，多模态大模型的预训练与指令微调所需的数据量也急剧增长，从数百万图文对到数十亿级样本，单机算力、存储与 I/O 同样成为瓶颈；数据质量与混合比例对下游性能同样有显著影响 [?]，长上下文与多模态联合基准 [?] 的普及进一步推高了对训练规模与效率的需求。在上述模型与数据规模的约束下，单台计算设备的显存与算力资源与均难以独立支撑完整的训练流程。因此，必须借助分布式与并行训练，将模型参数、优化器状态、激活值与数据分散至多台设备，通过节点间的通信协同完成前反向计算，才能实现大规模模型的训练 [?]。

目前，支撑大规模 MLLMs 训练的主流并行策略可归纳为两大类。第一类是以计算与张量切分为核心的多维混合并行：数据并行 [?] 在各设备上复制完整模型、按批次划分样本，通信集中在梯度 AllReduce，实现简单且在小模型上扩

展性好；张量并行 [10]（如 Megatron-LM）将单层内的矩阵按行或列切分到多卡，降低单卡显存并保留层内并行，是千亿级稠密模型的主流选择；流水线并行 [11]（如 GPipe、PipeDream）将模型按层划分为若干阶段并分配到不同设备，通过微批次与调度重叠计算与通信，缓解单设备层数过多的问题；序列并行 [12] 与专家并行 [13] 则分别在长序列注意力与混合专家（MoE）结构中沿序列维或专家维切分，与张量、流水线并行组合后可进一步扩展模型规模。第二类是以显存优化为核心的零冗余优化器系列：ZeRO [14] 将优化器状态、梯度与参数分片存于各卡，前向与反向时按需聚合，在保持数据并行通信量的同时显著降低单卡显存；ZeRO-Infinity [15] 进一步将部分状态卸载至 CPU 与 NVMe，突破 GPU 显存墙；ZeRO++ [16] 通过量化与通信重算技术减少跨节点通信量，提升多节点训练效率。上述并行策略常与混合精度训练 [17]、激活检查点 [18]、Flash Attention [19] 等显存与计算优化技术结合，共同构成当前大模型与 MLLMs 训练的基础设施；PyTorch 的 FSDP [20] 与 DeepSpeed ZeRO 类似，通过全分片参数与优化器状态实现单卡显存的大幅降低。然而，上述策略在设计时多假设同构集群与单一形态的 Transformer 模型，其划分粒度、负载均衡与通信优化均围绕“各层计算与显存相对均匀”这一前提展开；在面对异构 GPU 集群与模块异构的 MLLMs 时，负载与显存分布的不均匀性被放大，仍存在效率与可扩展性方面的挑战，这也是本文关注的重点之一。

在实际应用中，企业与研究机构常面临定制化多模态模型的高频微调需求，这要求训练系统具备较高的可扩展性与资源利用率。然而，受预算与硬件采购周期的限制，多数集群难以维持绝对的同构性，往往需要在现有的异构设备组合上开展预训练与微调实验。因此，提升异构 GPU 集群下的训练效率、使其逼近同构环境的表现，具有迫切的现实需求。同时，因负载不均或通信瓶颈导致的计算资源浪费不仅会延长训练周期，亦会显著增加算力成本。由此可见，针对异构集群设计高效的 MLLMs 并行训练方案，既是系统层面的技术挑战，也是落地部署中的关键环节。

1.1.2 异构 GPU 集群的并行训练策略

多模态大语言模型的训练效率与成本高度依赖底层硬件平台。目前，工业界与学术界普遍采用 NVIDIA GPU 作为大模型与 MLLMs 训练的主要加速器，并通过多卡、多机集群进行分布式训练。然而，NVIDIA 约每 1-2 年迭代一代计算架构并推出多款不同定位的 GPU，导致显存容量、算力与互联方式持续分化，实际部署中的集群往往由多代、多型号 GPU 混合组成，形成显存异构、算力异构与通信异构并存的局面 [21]。对单层计算与显存相对均匀的传统 LLMs，尚可通过“按

层数或算力比例”划分在一定程度上缓解异构；而对编码器、投影层与 LLMs 在结构与参数量上差异显著的 MLLMs，模块间负载差异与设备能力差异叠加，使得简单比例划分难以同时兼顾负载均衡与显存安全。

图1.2 概括了近年来 NVIDIA GPU 的架构演进。2016–2017 年的 Pascal（如 P100）与 Volta（V100）奠定了数据中心 GPU 与 Tensor Core 的基础；2018 年 Turing（RTX 20 系列）引入消费级光追与 INT8 推理；2020 年 Ampere 架构推出 A100（40GB/80GB HBM2e）与消费级 RTX 30 系列（如 RTX 3090 24GB），支持 PCIe 4.0 与 NVLink 3.0，成为当前许多实验室与云平台的主力[?]。2022 年 Hopper 架构的 H100（80GB/96GB HBM3）针对 Transformer 与 LLM 训练做了专门优化[?]，并广泛配备 NVLink 4.0 与 NVSwitch，单机多卡带宽可达数百 GB/s；同年 Ada Lovelace 架构的 RTX 40 系列（如 RTX 4090 24GB）在消费级市场提供高性价比算力。2024 年起，Blackwell 架构的 B100/B200 等数据中心 GPU 逐步量产，采用 HBM3e、更高带宽的 NVLink5 与 PCIe 6.0，进一步拉大与旧代设备的性能与互联差距[?]。按 NVIDIA 已披露的路线图，后续还将推出 Rubin（约 2026 年）、Rubin Ultra（约 2027 年），以及面向推理与能效深度优化的费曼（*Feynman*）架构（约 2028 年），后者将采用下一代 HBM 与 3D 堆叠内存等技术，进一步凸显代际间显存与互联的差异。与此同时，不同代际与型号在 PCIe 版本（3.0/4.0/5.0/6.0）、是否配备 NVLink/NVSwitch、以及 InfiniBand 与 RoCE 等节点间网络上的差异，使得通信带宽与延迟在集群内分布极不均匀。




图 1.2 NVIDIA GPU 架构与代表性产品演进

在大多数高校、研究所与中小企业的实际环境中，受预算与采购周期限制，集群常同时包含多代 GPU（例如部分 A100 或 H100 与大量 RTX 3090/4090、甚至更早的 V100/RTX 2080），单机内也可能混用不同显存与互联配置，难以做到“全集群同构”。而主流并行训练框架（如 Megatron-LM、DeepSpeed）在设计时多假设同构设备与统一拓扑 [22]，在异构集群上直接使用往往导致：负载无法按算力与显存合理分配、通信成为瓶颈或部分高端卡空闲、以及因“木桶效应”整体效率下降 [22]。因此，在显存、算力与通信三重异构的 GPU 集群上高效训练 MLLMs，是学术界和工业界共同面临且亟待解决的问题。

从系统层面看，异构带来的问题不仅在于单卡能力差异，还在于拓扑与调度：节点内 NVLink 与节点间 InfiniBand 的带宽可相差一个数量级以上，若流水线或张量并行的划分未考虑链路差异，跨节点通信极易成为瓶颈；同时，MLLMs 各阶段对编码器、投影层与 LLMs 的冻结策略不同，导致同一模型在不同训练阶段下各层的计算与显存占比发生明显变化，若沿用固定划分与调度，难以在整轮训练中保持负载均衡。因此，面向异构集群的 MLLMs 训练需要同时考虑硬件拓扑、模型结构与多训练阶段，通过自适应的划分与高效的调度使各设备利用率最大化。

除了硬件设施固有的算力、显存和通信异构，模型异构也是现有并行训练框架无法高效训练多模态大语言模型的原因之一。负责将不同模态的输入数据编码为模型可理解的 Modality Encoder 一般是视觉模型（如 CLIP、ViT 等），核心模块 LLMs 是常见的基座大语言模型（如 GPT-3、Llama-3 [23]），具有庞大的参数量，大约占据整个多模态大语言模型 80%–90% 的参数量。Modality Generator 一般是一个 Diffusion 生成模型（如 Stable Diffusion [24]），根据 LLMs 的输出产生图像、视频、音频等其它模态的数据。其中，LLMs 是由参数量很大的 Transformer 层堆叠而成，Encoder 可能由小的 Transformer 层或卷积层等其它神经网络组成，Generator 也可能是 U-Net [25] 等其他网络结构。前后两个 Projector 可能是 Transformer 层、Linear 层，也可能是 Q-Former [26] 等其它网络结构。多模态大语言模型的这种网络结构和传统的大模型结构不同，传统的大模型只有一种参数量固定的 Transformer 层，每一层在特定 GPU 上运行所需的时间和显存都是固定的；而对于多模态大语言模型，模型的某一层变化多样，在不同的 GPU 上运行的时间开销和显存开销都不同，在异构 GPU 集群的环境下，这种模型异构对于异构集群上训练效率带来的影响被进一步放大。

得益于深度学习的持续演进，在计算机视觉、大语言模型、内容生成等领域涌现出众多性能优异的预训练模型，为当前多模态大语言模型的训练范式奠定了基础。Blip-2 [27] 率先提出复用已有的 SOTA 模型，在训练过程中冻结大部分网络模块，仅更新新增的轻量连接层，从而实现跨模态对齐。此后，这种基于冻结与

局部更新的策略被广泛应用于各类多模态大语言模型中，如近期的 NextGPT[?]、DreamLLM[?] 等工作。此外，多模态大语言模型的训练通常被划分为多个阶段（如模态对齐、指令微调等），不同阶段针对特定能力解冻不同模块。当某一模块被冻结时，其反向传播的计算量会大幅下降；且优化器亦无需为冻结参数维护一阶与二阶矩等状态变量（如使用 Adam[?] 优化器时），这显著降低了训练过程中的显存压力。但在异构 GPU 集群中，这种由模块冻结带来的算力、显存与通信需求的时变性，反而放大了各设备间的负载不均。此外，云上与混合部署中的弹性训练与按需资源供给，使得集群内设备型号与拓扑更加多样，对异构感知的划分与调度、以及训练成本与性能的联合优化提出了进一步要求 [??]。

硬件层面的设备异构与模型层面的模块异构、分阶段冻结交织，构成了当前有限资源下高效训练的核心难点。为此，本课题拟结合现有并行策略，深入分析实际 GPU 集群中的异构场景，基于 Megatron 等主流并行训练框架，针对 MLLMs 的结构特点以及集群内显存、算力与带宽的非均匀性，研究细粒度的混合同步并行技术和重计算技术，旨在提出一套面向异构复杂环境的自适应并行训练方案，以期缓解异构集群下训练 MLLMs 效率低、显存利用不充分等问题。

1.2 国内外研究现状

1.2.1 多模态大语言模型并行训练策略研究现状

近年来，基座语言模型、视觉模型与多模态大语言模型持续向更大参数规模与更大数据规模演进。Kaplan 等 [?] 通过大量实验归纳出扩展定律（Scaling Law）：模型性能随模型参数量与训练数据量的幂律关系持续提升，这为“做大模型、用大数据”提供了理论依据；Chinchilla[?] 进一步表明，在计算最优意义下，模型规模与训练 token 数应同比例扩展，后续研究 [?] 从推理成本角度拓展了最优缩放策略。提升大模型性能的两条主要途径是增大模型参数与扩大数据规模 [?]：通过提升参数量可增强对复杂场景的拟合与泛化能力；通过扩大数据规模可使模型学习到更充分的特征表示 [?]，更好地适应复杂应用场景；参数高效微调（如 LoRA[?]、QLoRA[?]）则在资源受限下广泛用于 MLLM 的适配与部署 [?]

自 Transformer[?] 提出以来，语言模型规模迅猛增长：从 BERT[?] 的亿级参数，到 GPT-2[?]、T5[?] 的十亿级，再到 GPT-3[?] 的千亿级与 GPT-4[?] 等闭源模型，以及 DeepSeek-V3[?]、Qwen2.5[?] 等开源千亿级模型。多模态大语言模型在此基础上融合视觉编码器与语言模型，代表性工作包括 BLIP-2[?]（Q-Former 连接视觉与语言）、InstructBLIP[?]（指令感知视觉特征）、LLaVA/LLaVA-1.5[??]（线性投影对齐）、Flamingo[?]（交错图文与 gated 交叉注意力）、Qwen-VL[?]、InternVL[?]、MiniGPT-4[?] 等，其参数量从数十亿到数百亿不等，且训练数据从

数百万图文对到数十亿级样本（如 LAION-5B[?]）；相关综述从架构、对齐策略、数据与效率等角度对 MLLMs 进行了系统梳理[?]。单卡或单机在显存与算力上已无法容纳完整模型与训练流程[?]，并行与分布式训练成为训练大模型与 MLLM 的必由之路[?]。

训练数据规模同样持续扩大：图像方面，Open Images[?]、COCO[?] 等需 TB 级存储；LAION-5B 等开放图文对达数十亿样本；文本方面，Common Crawl、The Pile[?] 等为 LLM 预训练提供数百 GB 至数万亿 token 量级语料；视频方面，YouTube-8M[?]、WebVid[?] 等基准需 PB 级存储与高吞吐数据管线；多模态理解与推理则依赖 VQAv2[?]、TextVQA[?] 等数据集与长上下文基准[?]。在单机无法存储完整数据集与模型的前提下，并行训练（数据并行、模型并行及其组合）成为必然选择。

在并行策略方面，工业界与学术界已形成以数据并行、张量并行、流水线并行及 ZeRO 等为核心的技术栈，并被 Megatron-LM、DeepSpeed 等框架广泛应用于千亿级参数模型训练[?]。Galvatron[?] 针对 Transformer 在多 GPU 上的自动并行进行了系统探索，将策略搜索与编译优化结合；Colossal-Auto[?] 等将自动并行策略搜索与激活检查点统一自动化，为大规模与异构环境下的联合优化提供了参考。然而，上述框架在设计时多假设同构 GPU 集群与单一形态的 Transformer 模型，对 MLLMs 的模块异构（编码器、投影层、LLM、生成器结构各异）与分阶段冻结考虑不足；在实际部署中，集群往往由多代、多型号 GPU 混合组成，存在显存、算力与通信的异构[?]，直接使用传统并行策略易出现负载不均、通信瓶颈与“木桶效应”。因此，面向异构 GPU 环境设计多模态大模型并行训练方法，实现自感知、自适应、细粒度的划分与调度，对提高算力利用率、充分利用存储与缓解通信瓶颈十分必要；相关综述可参见[?]。而要支撑上述目标，需依托现有并行训练的主体形态，并在此基础上针对异构集群与 MLLM 做专门适配。

1.2.2 异构 GPU 集群并行训练策略研究现状

并行训练是当前工业界与学术界训练多模态大语言模型的主要手段，主流做法可概括为两类：以计算与张量切分为核心的多维混合并行，以及以显存分片为核心的零冗余优化器（ZeRO）系列。

多维混合并行通过在不同维度上划分模型或数据以降低单机负载。数据并行[?]在各设备上复制完整模型、按批次划分样本，通信集中在梯度 AllReduce，实现简单且扩展性好。张量并行[?]（如 Megatron-LM）将单层内矩阵按行或列切分到多卡，降低单卡显存，是千亿级稠密模型的主流选择。流水线并行将模型按层划分为若干阶段并分配到不同设备：GPipe[?]通过微批次与多阶段调度减

少流水线气泡；PipeDream[?] 提出 1F1B 等调度进一步压缩空闲时间。此外，序列并行 [?]、专家并行 [?] 等与张量、流水线并行组合后可进一步扩展模型规模。NVIDIA 的 Megatron-LM[?] 联合使用张量、流水线与数据并行，已支撑在数千张 GPU 上训练千亿至万亿级参数的大语言模型；Korthikanti 等 [?] 针对超大 Transformer 提出序列并行与选择性重计算，与张量并行协同以降低激活显存。零冗余优化器 ZeRO[?] 在数据并行基础上将优化器状态、梯度与参数分片存于各卡、按需聚合，显著降低单卡显存；ZeRO-Infinity[?] 将部分状态卸载至 CPU/NVMe；ZeRO++[?] 通过量化与通信重算减少跨节点通信量。

然而，上述策略多假设同构设备与统一拓扑。Megatron-LM 在设计时未考虑设备异构与模型异构；在实际异构环境下训练 MLLMs 时，往往将不同型号、显存与带宽的 GPU 当作同构设备统一配置，其典型并行策略如图1.3所示。对于 MLLM 中结构各异的 Modality Encoder、LLM Backbone、Projector 与 Modality Generator，Megatron 缺乏针对性的细粒度划分与映射，编码器与生成器的并行方式通常被动跟随 LLM 主干划分，难以根据各子模块的算力与显存需求及不同 GPU 能力做自适应分配，导致显存小、算力弱或通信慢的 GPU 成为瓶颈，整体利用率与训练效率下降 [? ?]。




图 1.3 使用 Megatron 训练多模态大语言模型

针对异构 GPU 集群的并行训练，已有不少研究。HetPipe[?] 较早将流水线并行与数据并行结合，通过虚拟工作节点（VW）在异构设备间分配负载，但未显式建模设备排列与通信拓扑，也未考虑 MLLM 的模块异构与冻结策略。Whale[?] 针对显存与算力异构提出基于硬件感知的负载均衡方法，按比例对各设备分配不同大小的模型分片与批次，但未考虑网络异构，划分粒度相对粗糙。AMP[?] 在

异构环境下为大模型自动搜索并行策略，同时考虑模型异构与设备异构，通过开销模型与动态规划求解近似最优配置，但划分粒度为全局粗粒度，对通信与显存估计的准确性有限。近年来，面向异构集群的分布式训练系统与调度方法受到持续关注。hethub2024[?]支持 AMD、NVIDIA 等多厂商异构 GPU 集群，通过统一通信器、性能预测器与自动并行规划，在 768 张异构卡上训练 Llama-140B 达到理论性能上界的 97.49%；HexiScale[?]将数据、流水线与张量并行的非对称划分形式化，采用层次图划分算法在异构环境下分配计算，在 7B–30B LLM 上取得与同构系统接近的 MFU（平均差距约 3.5%）；Espresso[?]面向成本效益的异构 GPU 资源供给与阶段放置，集成 Profiler、GPU Allocator、Stage Placer 与 Performance Estimator；Zorse[?]直接针对异构集群上的 LLM 训练效率优化，支持非对称流水线阶段与异构数据并行组；Cephalo[?]通过解耦计算分布与训练状态分配在异构集群上为 Transformer 训练分配算力与显存。上述工作多为通用 LLM 或同构扩展设计，对 MLLM 的模块异构、分阶段冻结与显存—算力—通信三重异构的联合优化仍不足。

ZeRO[?]的梯度 / 参数 All-Gather 等通信在跨节点异构网络中易成为瓶颈；MiCS[?]对异构网络下的高带宽链路利用仍有不足；ZeRO++[?]的量化与通信重算可能引入精度与通用性代价；AMSP[?]等侧重跨节点通信削减，对集群内存储、算力与带宽的细粒度异构利用仍有限。因此，在异构 GPU 集群上高效训练 MLLMs，仍需在 DeepSpeed 与 Megatron 等现有框架基础上，引入对设备能力与模型结构的感知与自适应优化；本文后续第三章给出的 MMoH 框架即针对上述问题，在异构集群上为 MLLM 提供需求驱动的拓扑识别、复合粒度划分与冻结感知调度 [? ?]。

1.3 研究内容与贡献

1.3.1 MMoH: 多模态大语言模型在异构 GPU 集群上的混合并行

针对现有并行策略在异构集群适配上的局限性，本课题以实际 GPU 集群中普遍存在的显存、算力和网络异构为切入点，研究细粒度的混合自动并行优化技术。提出适用于异构 GPU 环境的 MLLMs 自适应并行训练方案，以期在复杂集群下缓解负载不均与通信瓶颈，提升整体训练效率。

针对异构 GPU 设备环境下显存空间利用不均衡、通信异构带来的通信瓶颈问题、算力异构带来的 GPU 利用率不高的问题、模型异构带来的算力分配问题、冻结对于显存和计算需求的变化问题，本课题提出一种综合的、面向异构设备和异构模型的多模态大语言模型计算图的层级划分方法，通过为不同属性的计算设备分配不同大小的部分模型，实现计算资源、存储空间、通信带宽的充分利用，争

取最大限度提高训练速度。

MLLMs 训练与常见的大语言模型的训练过程不同，通常需要分为不同的阶段进行训练，在不同的阶段中对不同模块进行冻结，冻结部分的反向计算量远小于未冻结部分，进一步加剧阶段间执行时间的不均衡，使得气泡率在异构流水线中居高不下，而且可能存在冗余的计算和通信。

本课题针对上述问题，提出一种面向多模态大语言模型的提前终止流水线调度策略。该策略可以感知模型在不同阶段的冻结情况，根据各阶段的冻结情况，调整模型的划分策略；同时结合冻结特性，检测冗余的计算和通信操作并且直接丢弃，提高多卡流水线的有效算力利用率与训练吞吐。

1.3.2 HR-MMoH: 多模态大语言模型在异构 GPU 集群上的重计算

激活检查点（重计算）通过在前向时丢弃部分中间激活、在反向时按需重算，以计算换显存，是支撑大模型与 MLLMs 在有限显存下训练的重要手段。然而，现有重计算策略多采用全局统一的配置（如对全部层或按固定间隔插入检查点），未考虑异构集群中设备间显存与算力的差异：显存紧张、算力相对充裕的设备适合更激进的检查点以释放显存；显存宽裕、算力紧张或通信繁忙的设备则不宜过度重算，否则会加重计算或通信瓶颈。此外，MLLMs 各子模块（Encoder、LLM、Projector、Generator）的层数、每层激活体积与计算量各不相同，在同一设备上对不同模块采用相同检查点策略也难以达到最优。

本课题针对上述不足，提出一种面向异构设备与异构模型的重计算优化方法。该方法在给定层级划分与设备映射的基础上，以各设备的显存上限、算力及通信负载为约束，为不同设备上的不同模型阶段分别搜索或配置差异化的检查点策略（如检查点插入的粒度与密度），在满足显存不溢出的前提下，最小化因重计算带来的额外时间开销，并兼顾流水线不同流水级的负载均衡。通过将重计算与前述的复合粒度划分、流水线调度相结合，实现计算、存储与通信在异构环境下的联合优化，进一步提升 MLLMs 在异构 GPU 集群上的训练效率。

1.4 论文组织结构

本论文共分为五章，具体结构如下：

第一章为绪论。主要阐述面向异构 GPU 集群的 MLLMs 并行训练的背景与意义，剖析当前面临的技术挑战，并概述本文的研究内容与核心贡献。

第二章为相关工作。从 MLLMs 架构特点、分布式训练基础、异构 GPU 并行策略以及重计算优化等方面梳理现有研究的发展脉络与局限性。

第三章介绍本文提出的 MMoH 框架，重点阐述需求驱动的设备拓扑识别、复合粒度模型抽象、冻结感知划分及提前终止流水线调度方法，并给出实验评估。

第四章介绍 HR-MMoH 异构重计算优化，详细说明如何在异构计算资源与不同模型模块间实现检查点策略的细粒度自适应配置。

第五章为总结与展望。对全文工作进行回顾，并探讨后续可能的研究方向。

第二章 相关工作

本章从多模态大语言模型架构与训练、并行与分布式训练基础、异构 GPU 集群并行训练策略以及重计算优化等方面对国内外相关研究进行综述。本章内容旨在论证如下观点：模型的模块化设计与分阶段训练深刻改变了其计算图与显存分布；尽管混合并行与重计算等显存优化技术已被广泛应用，但在面临集群硬件异构性与 MLLMs 独有的模块异构时，现有同构导向的策略仍暴露出明显的局限。

基于 Transformer 的大语言模型在自然语言处理 [??]、图像识别 [??]、多模态理解与生成 [??] 等众多领域取得了显著进展；多模态大语言模型（MLLMs）在此基础上融合视觉、语言与生成模块，成为当前研究的热点之一。性能提升与规模扩展紧密绑定：扩展定律（Scaling Law）[?] 表明模型性能随参数规模与数据规模提升而持续改善，工业界与学术界因此不断推动模型参数量与训练数据量的增长，单设备在显存与算力上已无法容纳完整模型与训练流程 [?]，并行与分布式训练成为训练大模型与 MLLMs 的必由之路。目前，以数据并行、张量并行、流水线并行及零冗余优化器（ZeRO）等为代表的并行策略已被广泛应用于千亿级参数模型的训练 [???]，但上述框架在设计时多假设同构 GPU 集群与统一的设备拓扑，对实际环境中普遍存在的设备与网络异构考虑不足。

由于硬件迭代与采购周期等因素，实际部署的计算集群往往混用多代、多型号的 GPU，导致显存容量、算力与互联带宽呈现高度异构性 [??]。在此类异构环境下，若直接套用基于同构假设设计的并行策略，极易造成负载失衡与通信拥塞，不仅拉低了整体训练效率，也制约了可用资源的规模扩展；而 MLLMs 内部各模块（Encoder、LLM、Projector、Generator）在结构与参数量上的悬殊差异，及其分阶段冻结的训练设定，进一步加剧了系统级优化的难度。

因此，本章首先介绍 MLLMs 的架构组成、训练数据特点与多阶段训练范式；随后梳理数据并行、张量并行、流水线并行等并行策略及 ZeRO 系列优化等分布式训练基础；进而探讨现有异构 GPU 集群并行训练方法的研究进展及其适用边界；最后评述重计算等显存换计算技术的当前状态。通过上述梳理，揭示现有工作在应对异构 MLLMs 训练时的不足，从而为后文 MMoH 与 HR-MMoH 的提出奠定基础。

需要说明的是，并行与分布式训练领域文献浩繁，本章重点聚焦与本文工作直接相关的几个切入点：多模态大语言模型的组件差异与其特有的多阶段训练范式，共同决定了其动态且高度不均衡的计算资源需求；数据并行、张量并行、流水线并行及 ZeRO 构成了解决大规模训练的基石；面对实际生产中普遍存在的集群异构性，如何通过智能化的负载均衡与任务调度来突破单点瓶颈，逐渐成为学

术界与工业界关注的焦点；同时，以重计算为代表的显存优化技术在异构场景下具备与其他调度策略深度融合的潜力。上述各维度的探讨，旨在为后续章节提出的优化算法提供理论与实践层面的依据。

2.1 多模态大语言模型

2.1.1 多模态大语言模型的异构架构

多模态大语言模型（MLLMs）将视觉、语言与（可选）生成能力统一到以大规模语言模型为核心的异构架构中，其典型组成如图1.1所示，主要包括以下几类模块。

Modality Encoder 负责将图像、视频、音频等非文本输入编码为高维特征表示，以便与语言模型的词嵌入空间对接。实践中多采用在大规模图文或视频等多模态数据上预训练好的视觉模型作为编码器：CLIP[?] 通过对比学习实现开放词汇的视觉表征，被 LLaVA[?]、MiniGPT-4[?] 等广泛采用；ViT[?] 及规模化变体 [?] 则将图像切分为 patch 后经 Transformer 编码，在 Flamingo[?]、InternVL[?] 等工作中用作视觉 backbone。InternVL[?] 将视觉基础模型规模扩展至 60 亿参数，并在多图、长文本与文档理解上取得领先；Qwen-VL[?] 支持百万像素级高分辨率与多轮对话，在 DocVQA、ChartQA 等基准上表现突出。编码器输出通常为序列形式的特征，再经后续模块映射到 LLM 空间；从而完成视觉等其它模态数据与语言模型的对齐的第一步 [?]。

Input Projector 将编码器输出的多模态特征映射到与 LLMs 词嵌入维度与语义空间对齐的表示，使 LLMs 能够将视觉等信息与文本统一处理。常见实现包括线性层、轻量 Transformer 层等，以及 BLIP-2[?] 提出的 Q-Former（通过可学习的 query 从编码器特征中抽取与任务相关的表示）；InstructBLIP[?] 在此基础上引入指令感知的 Q-Former，根据用户指令从图像中抽取与任务更相关的特征，在 ScienceQA 等零样本任务上显著优于 BLIP-2。该模块参数量远小于 LLM，常与编码器一起在预训练或对齐阶段更新。

LLM Backbone 即大规模语言模型主体，承担主要的语言理解与生成计算，参数量通常占整个 MLLM 的 80%–90%[? ?]。基座模型多选用已在海量文本上预训练好的 Transformer 模型，如 GPT 系列 [? ?]、LLaMA[?]、T5[?] 等；在资源受限或强调高效微调时，常对 LLMs 进行冻结或仅微调部分层。

Output Projector 与 **Modality Generator** 用于多模态生成任务（如图生图、文生图、文生视频、文生音频等）：前者将 LLMs 的输出映射到生成器可接受的表示空间，后者根据该表示生成图像、视频或音频。生成器多采用扩散模型，如 Stable Diffusion[?] 中基于 U-Net[?] 的潜在扩散结构；Next-GPT[?]、DreamLLM[?] 等

工作在此基础上实现了任意模态到任意模态的生成与转换。

BLIP-2[?] 率先系统性地采用“冻结 Encoder + 冻结 LLM + 仅训练轻量 Projector”的范式，在显著降低训练成本的同时达到与全参数微调可比的效果，后续多数 MLLMs 均沿用或发展此类设计。这种模块异构（编码器、投影层、LLM、生成器在结构、参数量与计算特性上差异显著）与分阶段冻结策略，使得在异构 GPU 集群上为各模块分配合适的算力与显存、并设计均衡的并行与调度策略变得尤为困难。

从实现角度看，编码器多为卷积或 ViT 类结构，单层计算与显存占用与 Transformer 解码层不同；投影层参数量小、计算密集度高，在流水线中若与 LLMs 层混合划分，易造成流水级间负载不均；LLMs 主体层数多、激活体积大，常需配合激活检查点与张量并行以控制单卡显存。生成器（若存在）多为 U-Net 或扩散结构，其前向与反向计算模式与语言模型差异较大。因此，在设计面向 MLLMs 的并行与调度方案时，需要针对各子模块的特性分别建模计算、显存与通信，并考虑不同训练阶段下冻结比例变化带来的动态负载差异，而不能简单套用单一 Transformer 的划分假设；这也为本文第三、四章中针对各模块与冻结状态的细粒度划分与调度提供了直接动机。

2.1.2 多模态大语言模型训练数据

扩展定律（Scaling Law）[?] 表明，模型性能随训练数据规模与模型参数规模的提升而持续改善；Chinchilla[?] 进一步指出，在计算最优意义下，模型参数量与训练 token 数应近似同比例扩展，后续工作 [?] 从推理成本角度拓展了最优数据—模型比例。由此可推知，在给定算力预算下，若要逼近 Pareto 前沿的性能，就必须同时扩大数据规模与模型规模；因此工业界与学术界在预训练与微调阶段均倾向于使用尽可能大的数据与模型。大语言模型通常在海量文本语料（如 Common Crawl、The Pile[?]、书籍与代码）上预训练，规模可达数万亿 token。多模态大语言模型在此基础上还需大规模图文对、视频—文本对等多模态数据，用于模态对齐、指令微调与多模态生成等阶段；由于上述各阶段均依赖大规模监督或多模态配对数据，数据量与存储需求在文本预训练的基础上进一步放大。多模态理解与推理的评估常采用 MMMU[?] 等跨学科基准 [?]，其题目与数据形态的多样性也反过来推动训练数据在模态与任务类型上的扩展。

表2.1列举了若干代表性数据集的规模与用途。图像方面，Open Images[?] 包含约 900 万张图像及框注，存储需求约 18TB；JFT、LAION 等内部或开放图文对数据集规模可达数亿至数十亿样本，用于视觉—语言预训练。视频方面，YouTube-8M[?] 等基准包含数百万视频与标签，用于视频理解与生成的数据集往

往需要 PB 级存储与高吞吐的数据管线。文本方面，Common Crawl、The Pile 等为 LLM 预训练提供数万亿 token 的语料。综合上述规模可知，单机显存既难以容纳完整模型与优化器状态，单机存储与 I/O 带宽也难以在训练周期内高效供给全量数据；在这一双重约束下，并行训练（数据并行、模型并行及其组合）成为必然选择。与此同时，数据规模与模型规模的持续增长，对并行策略的 I/O 效率、通信拓扑与异构集群下的数据供给能力提出了更高要求 [?]。

表 2.1 多模态大语言模型训练中常用的部分数据集规模示意

类型	规模量级	存储量级	典型用途
图像文本对	数百万 – 数十亿	TB–PB	图文预训练、对齐（如 Open Images[?]）
视频	数百万 – 数亿	百 TB–PB	视频理解、生成（如 YouTube-8M[?]）
文本 / 语料	数百亿 – 数万亿 token	PB 级	LLM 预训练、指令数据

2.1.3 多模态大语言模型训练过程

多模态大语言模型的训练通常采用多阶段、分模块的策略，在不同阶段设定不同的训练目标与可训练参数集合，以兼顾效果与成本 [?]。各阶段的先后顺序遵循从粗粒度对齐到细粒度能力塑造的递进关系：典型阶段包括（1）模态对齐（或预训练），在大规模图文对或视频—文本对上训练 Input Projector（及可选的部分 Encoder/LLM），使视觉等特征与 LLM 语义空间对齐；（2）指令微调（Instruction Tuning），在高质量指令—回答数据上微调，以提升遵循指令与对话能力，此时常冻结 Encoder、仅微调 Projector 与 LLM 部分层；（3）多模态生成微调（若需文生图等），在生成数据上训练 Output Projector 与 Modality Generator，LLM 可冻结或低秩微调。各阶段对“谁冻结、谁更新”的设定不同，因而在同一模型上，不同阶段对应不同的有效计算图与显存、算力需求分布；换言之，模块异构在时间维度上表现为阶段依赖的、动态变化的负载形态。实践中，各阶段采用的典型超参与数据规模因模型与任务而异：LLaVA[?] 在约 60 万图文对上做视觉—语言对齐与指令微调；InstructBLIP[?] 在 13 个指令化数据集上微调；Qwen-VL[?]、LLaVA-NeXT[?] 等则进一步扩大指令数据与上下文长度；闭源多模态模型如 Gemini[?]、PaLM[?] 系列则在更大规模数据与算力下完成预训练与对齐，其具体数据配比与阶段划分多未完全公开。

冻结会显著改变各模块的反向计算量与显存占用。其原因是：冻结参数不参与梯度计算与更新，因而无需为其保存梯度或中间激活用于反向；优化器状态（如

Adam 的动量与方差) 仅需为可训练参数维护, 故冻结比例越高, 单步显存与计算量通常越低, 但可调表达能力也越受限 [2]。在流水线并行或层级划分下, 若某流水级被冻结, 其对应设备上的反向计算远少于未冻结阶段, 容易造成流水级间负载不均与流水线气泡。在异构 GPU 集群下, 设备间本就存在显存、算力与带宽差异; 训练阶段与冻结策略带来的动态模型异构 (即同一模型在不同阶段呈现不同的有效计算与显存分布) 与设备异构叠加, 使得静态的、一次性确定的划分与调度难以在各阶段均接近最优, 进一步增加了并行策略设计调优的难度。因此, 一种能够随训练阶段与冻结状态自适应调整划分与调度的方案具有明确价值, 也是本文 MMoH 设计的目标之一。

图2.1概括了上述多阶段训练中常见的模块冻结与更新关系, 便于理解不同阶段对算力与显存的需求差异。

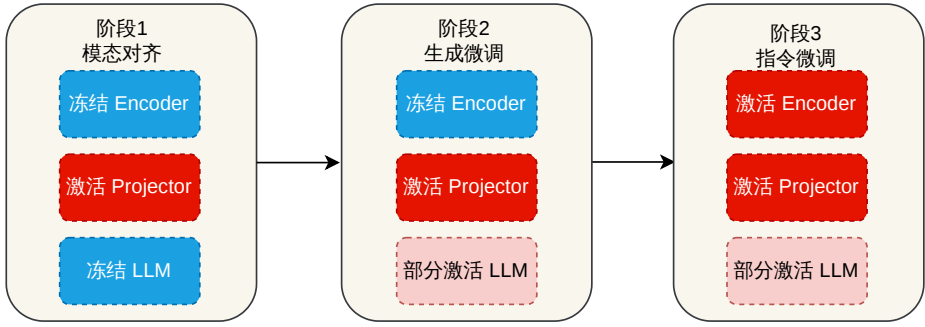


图 2.1 MLLM 多阶段训练中典型模块冻结与更新关系示意

2.2 并行与分布式训练基础

2.2.1 数据并行与模型并行

数据并行 (DP)。 数据并行将训练数据在各计算设备间划分, 每个设备持有一份完整模型副本, 本地前向传播与反向传播后通过梯度 All-Reduce 等通信同步参数 [22]。如图2.2所示, 各设备独立计算所分配 mini-batch 的梯度, 再在迭代末聚合梯度并更新一致参数。DP 实现简单、扩展性好, 是 PyTorch DDP[23]、Horovod[24] 等框架的默认方式; PyTorch 的 FSDP[25] 在数据并行基础上对参数、梯度与优化器状态进行分片, 与 ZeRO-3 思路相近, 可在单卡显存受限时支撑千亿级稠密模型训练; Parallax[26] 针对稀疏与异构场景对参数服务器与 All-Reduce 做了灵活选择。其局限在于单卡需容纳完整模型与优化器状态 (DP) 或需额外通信聚合分片 (FSDP), 无法单独支撑超大参数规模, 常与张量 / 流水线并行或 ZeRO 组合使用。




图 2.2 数据并行示意

张量并行（TP）与序列并行（SP）。张量并行在层内划分权重与计算，使多设备协同完成单层的前向与反向，组合后等价于完整层 [? ?]。如图2.3所示，每设备仅持有部分参数与激活，层间通过 All-Gather/Reduce-Scatter 等通信传递激活与梯度。Megatron-LM[?] 针对 Transformer 提出按行 / 列交替划分 FFN 与注意力权重，在减少同步次数的同时控制通信量；GShard[?] 在 MoE 中结合张量并行与专家划分。TP 通信密集且对带宽敏感，实践中多限于单节点或高带宽拓扑内，并与流水线、数据并行组合 [?]。序列并行（SP）针对长序列场景，将输入沿序列维划分到多卡，每卡仅处理一段子序列，通过通信在注意力等层交换信息以保持语义一致 [? ?]。DeepSpeed-Ulysses[?] 将序列均匀分片，在注意力处采用两阶段 All-to-All 重分布，使通信量随序列长度与设备数成比例缩放，支持百万级 token 训练；Megatron 中的实现常与张量并行共用进程组，与 TP、PP、DP 组合构成多维混合并行 [?]。




图 2.3 张量并行示意

流水线并行（PP）。 流水线并行在层间划分模型，每设备持有若干连续层构成一个流水级，如图2.4所示。GPipe 使用多个 micro-batch 依次流过各流水级以重叠计算、降低空闲（bubble）[?]。PipeDream[?] 提出 1F1B（1 Forward 1 Backward）等异步调度进一步压缩空闲；TeraPipe[?] 在序列内做 token 级流水线，实现更细粒度的层间并行。Chimera[?] 采用双向流水线减少气泡；Hanayo[?] 等波式调度进一步优化多流水级下的计算重叠。近年来，ZeroBubble[?] 在同步语义下将反向拆分为“对输入的梯度”与“对参数的梯度”两阶段，结合 1F1B1W 等调度与参数更新重叠，实现了近似零 bubble，在相同显存下相较 1F1B 提升吞吐约 23%–31%；DualPipe[?] 采用双向 micro-batch 流动与前后向重叠，在 DeepSeek 等超大规模训练中用于降低 bubble 与通信压力。PP 通信量相对较小，适合跨节点扩展，常与节点内 TP、全局 DP 组合 [?]。上述并行方式降低了单机负载与通信压力，但单机显存仍可能成为瓶颈；下文介绍的零冗余优化器（ZeRO）系列正是针对显存分片与优化器状态而提出，与 DP/TP/PP 组合后构成当前大模型训练的主流栈。长序列场景下，Ring Attention[?] 等通过块状 Transformer 与环形通信在有限显存内支持近无限上下文，与 PP、SP 形成互补。




图 2.4 流水线并行示意

上下文并行（CP）与专家并行（EP）。 上下文并行（CP）在如今模型输入越来越长的场景下得到了广泛应用：单卡显存难以容纳全长序列的激活时，将输入沿序列维划分到多卡，在注意力等层通过通信交换信息以保持语义一致，与张量并行共用进程组的序列并行（Sequence Parallelism）不同，上下文并行把模型输入在序列维度做切分，不同的序列块使用不同的 GPU 进行计算，称为 Context Parallelism（CP）[?]。CP 在 8K+ token 场景下显存收益显著，但会引入额外通信与拓扑约束，需与 Flash Attention、激活检查点等配合使用。专家并行（EP）针对混合专家模型（MoE）：不同 token 由不同子网络（专家）处理，EP 将完整专家分布到不同设备，每设备仅持有部分专家权重，前向时根据路由将激活发送至对应专家所在设备，再汇总结果 [?]。与张量并行（每设备持所有专家的部分权重）不同，EP 下每设备只存部分专家的全量权重，通信模式为 All-to-All 的 token 重分布，适合专家数

多、单专家规模适中的 MoE。GShard[?] 将 MoE 与张量并行结合并做自动分片；DeepSeek-MoE[?] 等在有限资源下通过 MoE 扩展语言模型规模；DualPipe[?] 等也在流水线中结合专家并行以支撑超大规模 MoE 训练。EP 的主要挑战是专家负载不均与路由带来的通信开销，需高带宽互联与负载均衡设计。图2.5展示了专家并行中的典型路由过程：门控网络先为 token 选择 Top- k 专家，再通过 All-to-All 将 token 分发到对应 GPU 上的专家执行计算，最后汇聚结果返回主干网络。




图 2.5 专家并行（EP）中门控路由与专家分布示意

2.2.2 零冗余优化器（ZeRO）

ZeRO[?] 在数据并行基础上，将优化器状态、梯度与参数分片存于各卡，前向与反向时按需聚合，在保持 DP 通信量的前提下显著降低单卡显存，使千亿级训练可行。如图2.6所示，ZeRO 三阶段分别分片优化器状态、梯度与参数；ZeRO-Infinity[?] 进一步将部分状态卸载至 CPU/NVMe 以突破 GPU 显存墙。ZeRO++[?] 通过量化与通信重算减少跨节点通信量；MiCS[?]、AMSP[?] 等在云环境与统一划分空间上做了扩展。ZeRO-3 与张量并行、流水线并行的组合在工程上存在约束（如 DeepSpeed 与 Megatron 的 3D 并行通常采用 ZeRO-1/2 与 TP+PP），需根据框架与集群拓扑谨慎配置 [?]，在实际部署中需在显存节省、通信开销与实现复杂度之间权衡。在注意力与激活显存方面，Flash Attention[?] 通过分块计算与 IO 感知将注意力显存从序列长度平方降为线性，FlashAttention-3[?] 在 H100 上进一步通过异步计算与低精度达到更高利用率。ZeRO 与 TP、PP、SP 等组合构成当前大模型与 MLLM 训练的主流基础设施。




图 2.6 零冗余优化器 ZeRO 示意

2.3 异构 GPU 集群并行训练策略

实际部署中，高校、企业与云平台往往无法配备全同构的 GPU 集群：设备多代共存（如 A100 与 V100、H100 混用）、显存容量从数十 GB 到 80 GB 不等、算力与互联带宽差异显著。在此类异构环境下，直接套用面向同构集群设计的并行训练框架，通常会引发三个层面的系统性问题。存储异构方面，传统策略多假设各卡显存一致，按均匀方式划分模型与激活，导致大显存设备利用率不足而小显存设备易发生 OOM，制约扩展性。算力异构方面，同步式并行要求各设备步调一致，最慢设备成为瓶颈，产生“木桶效应”，整体算力利用率与训练吞吐下降。网络异构方面，集群常存在多级互联（节点内 NVLink、节点间 InfiniBand 或以太），不同链路带宽与延迟差异大，跨节点通信易成为瓶颈。针对异构 GPU 集群并行训练的方法逐步成为近年来的研究热点，下文将梳理代表性工作及其应用局限。这些工作从不同角度缓解了异构带来的负载不均与 OOM 风险，但多数仍以通用 LLMs 或粗粒度划分为前提，对 MLLMs 的模块异构与分阶段冻结的适配仍显不足。

HetPipe[?] 较早将流水线并行与数据并行结合以利用异构集群。其将多个 GPU 组织为虚拟工作节点（VW），在 VW 内采用流水线模型并行（PMP）处理小批量，在 VW 间采用数据并行提升可扩展性。通过将“弱”设备与“强”设备搭配成 VW，在一定程度上缓解了单机算力不足的问题。然而，HetPipe 未显式建模 VW 内部的异构设备排列与通信拓扑，对通信与显存开销的估计较为直观，且未考虑模型异构（如 MLLM 中 Encoder、Projector、LLM 模块结构各异、冻结策略不同），在当今多模态大语言模型与分阶段训练场景下适用性有限。

Whale[?] 针对显存与算力异构，提出基于硬件感知的负载均衡方法。通过刻画各 GPU 的存储与算力差异，**Whale** 按比例对各设备分配不同大小的批次与模型分片，在数据并行与张量并行下实现计算与显存负载的均衡。其思路对“大卡多算、小卡少算”的配置有参考价值。但 **Whale** 未考虑网络异构，且存储 / 算力均衡策略相对直观，划分与编译粒度停留在子图级别，未与 **ZeRO** 等显存优化结合，在超大规模与多维度异构并存时仍有优化空间。

AMP[?] 在异构环境下为大模型自动寻找并行策略。**AMP** 同时考虑模型异构（不同层结构、参数量与计算量）与设备异构（GPU 显存、算力、网络），对层间差异进行抽象与建模，对集群内存储与网络异构进行近似量化，在此基础上基于 3D 并行（DP+TP+PP）设计开销模型（Cost Model），并用动态规划求解近似最优的并行配置。实验表明其在异构场景下相较基线有明显提升。不足在于：划分粒度为全局粗粒度，开销模型对通信与显存估计的准确性有限，且未显式约束显存上界，实际部署中易出现 OOM，仍需与显存预算和重计算等联合考虑。

近年来，面向大模型在云上与异构集群中训练的资源调度与配置规划工作受到关注。**Espresso**[?] 是一种面向成本效益的异构 GPU 资源供给与阶段放置框架，面向大规模模型训练场景。**Espresso** 集成四大模块：*Profiler* 分析不同层在异构 GPU 上的迭代时间与显存占用；*GPU Allocator* 负责异构 GPU 的分配；*Stage Placer* 确定流水线等并行策略下的阶段放置；*Performance Estimator* 预测给定配置下的训练性能。用户可指定模型、数据集、训练轮数与 SLO（服务等级目标），由系统自动给出资源分配与 stage 放置方案，从而在异构环境中兼顾成本与效率。**Espresso** 为异构集群上的大模型训练提供了从分析到配置的一体化思路，其与 **ZeRO**、流水线气泡优化及 **MLLM** 模块异构的结合仍可进一步探索。

HetHub[?] 面向多厂商异构 GPU 集群（如华为昇腾、AMD 与 NVIDIA 的计算卡混合），引入分布式统一通信器、性能预测器与自动并行规划，在 768 张异构卡（128 张 AMD + 640 张 A 系列）上训练 Llama-140B 达到理论性能上界的 97.49%，验证了异构集群训练大模型的可行性。**HexiScale**[?] 将数据、流水线与张量并行的非对称划分形式化为约束优化问题，采用层次图划分算法为异构 GPU 分配计算，在 7B–30B LLM 上取得与同构系统相当的 MFU（平均差距约 3.5%），为“按设备能力非对称划分”提供了系统化方法。

Zorse[?] 则直接针对异构 GPU 集群上的 LLM 训练效率优化。其指出，在异构集群上高效训练需要：（1）将流水线并行与数据并行以通信与显存高效的方式结合；（2）支持更灵活的配置，包括将 GPU 灵活划分为非对称的流水线阶段、在同一数据并行组内容纳异构 GPU。**Zorse** 实现了上述能力的统一，并配备自动规划器，根据工作负载自动生成训练配置。实验表明在异构场景下相较现有系统有

显著提升。Zorse 与 Espresso 等工作的出现，反映了社区对异构环境下大模型训练系统化方法的需求，二者在 MLLMs 多模块、分阶段冻结训练等场景下的适配问题仍亟待解决。

此外，与 ZeRO 系列相关的工作在异构场景下也存在局限。ZeRO[?] 的梯度 / 参数 All-Gather 等通信在跨节点异构网络中易成为瓶颈；MiCS[?] 对模型规模与异构网络下的高带宽链路利用仍有不足；ZeRO++[?] 的量化与通信重算在带来收益的同时可能引入精度与通用性代价；AMSP[?] 等侧重跨节点通信削减，对集群内存储、算力与带宽的细粒度异构利用仍有限。综合来看，现有异构并行与 ZeRO 类方法多针对通用 LLM 或同构假设下的扩展，对多模态大语言模型的模块异构、分阶段冻结与显存—算力—通信三重异构的联合优化仍不足，为本文面向异构集群的 MLLMs 高效训练与调度研究留下了空间。

从系统实现角度，将上述思路落地还需解决若干工程问题：异构设备上的性能预测与开销建模、与 Megatron/DeepSpeed 等现有框架的集成方式、以及多阶段训练下划分与调度策略的自动或半自动生成。Frenzy[?] 等面向内存感知的 serverless 调度在异构环境下可辅助资源与阶段放置；部分工作[?] 已开始提供从分析到配置的一体化工具，但在 MLLM 的模块级划分、冻结感知调度与重计算的联合优化方面仍缺少系统化方案，这也是本文 MMoH 与 HR-MMoH 设计所要弥补的不足。

2.4 重计算显存优化技术

大规模模型与长序列训练中，前向传播产生的中间激活（activation）需在反向传播时用于梯度计算，若全部保存则显存占用随层数与序列长度线性甚至平方增长，成为训练瓶颈。重计算（Recomputation，又称激活检查点（Activation Checkpointing））通过“以计算换显存”的思想，即前向传播时仅保存部分激活或仅保存检查点处的输入，反向时对未保存的区域重新执行前向传播以得到所需激活值，如图2.7所示，从而在显存与计算之间进行权衡，是缓解显存压力的常用手段[?]。根据检查点放置的粒度和策略，可大致分为全部重计算、选择重计算与细粒度重计算三类；以下分别简述其思路与适用场景。

全部重计算。 全部重计算（full recomputation）策略在前向阶段不保存任何中间激活，仅在若干“检查点”层保存该层的输入（或仅保存网络输入），反向传播需要某段中间激活时，从最近的检查点重新执行前向至该位置再计算梯度。极端情况下仅保存网络输入，则显存占用可降至与深度无关的常数级别，但反向传播需对整网做一次完整前向重算，计算开销约增加前向传播的一倍。Chen 等[?] 针对链式计算图证明了在仅增加一次额外前向的前提下，通过动态规划可求得检查点




图 2.7 重计算（激活检查点）示意

的最优放置，使显存从 $O(n)$ 降为 $O(\sqrt{n})$ (n 为层数)，并在千层残差网络等实验中实现了显存的大幅下降（如 48 GB $\rightarrow$ 7 GB）与约 30% 的训练时间增加。全部重计算实现简单、显存收益最大，适合显存极度紧张、算力相对充裕的场景，但计算冗余较高。

选择重计算。 选择重计算（selective recomputation）不是对整个 Transformer 层统一做 checkpoint，而是只对显存占用大但重算代价相对较低的部分子模块执行重算，未选部分仍正常保存激活。Korthikanti 等 [?] 在大规模 Transformer 中提出的 selective activation recomputation 即属于此类：其核心思想是优先重算注意力中的 QK^T 、softmax、dropout 以及与 V 的乘法等中间激活，因为这些张量随序列长度和注意力头数增长较快，但额外 FLOPs 开销相对有限。相较整层重计算，该策略的显存收益略小，但能显著降低重算开销；论文报告其总时间开销约为 7%，明显低于整层重算的 39%[?]。在工程实现上，Megatron-LM 与 NeMo 将其落地为 selective 粒度，默认仅重算 core_attn，也可扩展到 mlp、moe、layernorm 等指定子模块 [??]。

细粒度重计算。 细粒度重计算（fine-grained recomputation）在算子或更小粒度上决定哪些激活保存、哪些重算，从而更精细地利用不同算子的计算—显存特性。与上一段“选择重计算”主要回答“哪些模块需要重算”不同，细粒度重计算更关注“如何在模块内部重算”。例如，Transformer 中可不把整个注意力或 MLP 作为单一单位处理，而是进一步细化到 LayerNorm、dropout、MoE 激活函数、或某些投影输出等中间张量：前向时仅保留最少输入或元数据，反向时再局部恢复需要的结果。Megatron-LM/NeMo 中的 output-discarding checkpoint 就体现了这种思路：它并非简单地把整段前向再执行一遍，而是在前向后主动丢弃部分输出张量的存储，在反向阶段借助 hook 触发局部重算，从而进一步压缩激活占用 [??]。这类方法比“按层”或“按子模块”的重计算更贴近实现细节，能够利用不同算子的显存占用、通信需求与 FLOPs 差异做更细致的权衡。Lynx[?] 进一步将激活重算与通信重叠调度，在 1.3B–23B GPT 模型上相较现有方法取得最高约 $1.37\times$ 的加

速，表明细粒度重算若与通信、并行调度协同设计，还可以同时改善显存效率与训练吞吐。细粒度策略可结合模型结构（如 MLLMs 中 Encoder、Projector、LLM 各模块的算子组成）与异构设备的显存、算力差异，在不同设备或不同 stage 上采用不同的检查点粒度，是面向异构集群与 MLLM 的潜在优化方向。

在 Megatron-LM 与 NeMo 等框架中，重计算被实现为可配置的多级粒度。全部重计算（full）以整个 Transformer 层为粒度：检查点保存每层输入，反向时重算整层前向，显存下降显著但单层计算约增加 30%。框架进一步提供两种全层模式：*block* 模式通过参数指定每个流水线 stage 内参与重计算的层数，可仅对部分层做检查点以在显存与计算间折中；*uniform* 模式以连续多层的“块”为重计算单位，块内仅存块首输入，适用于层数很多或层间激活相对较小的模型，可节省激活显存但会增加重算缓冲。选择性重计算（selective）则仅在子模块级别重算：例如仅对自注意力块做检查点与重算（保存注意力块输入，重算 softmax、dropout、QKV 等中间激活），而 MLP 等不重算。自注意力激活随序列长度平方增长、占显存大头，但其重算成本相对线性投影层较低，因此选择性重算能以较小计算代价获得较高显存收益；用户还可指定 `core_attn`、`mlp`、`moe` 等模块是否参与重算。在使用 Flash Attention 时，框架通常强制对注意力做选择性重算以配合其显存布局。上述多级粒度（全层 *block/uniform*、子模块 *selective*）为实际训练中按显存预算与算力调节检查点策略提供了细粒度控制，与 Korthikanti 等 [?] 的序列并行与选择性激活重算相结合，已广泛应用于大规模 Transformer 与 LLM 训练。然而，现有检查点策略多面向同构设备设计：重计算层数、块大小、参与重算的子模块等均需用户或策略脚本手动指定，且通常假设各设备显存与算力一致，无法根据异构集群中不同设备的显存余量与算力差异自动调节（例如在显存紧张设备上加大重算比例、在算力瓶颈设备上减少重算）。

将重计算与流水线并行、stage 划分及异构分配结合，可进一步缓解显存瓶颈并提升整体吞吐：例如在流水线各 stage 内独立设置检查点策略，或在显存紧张的设备上采用更激进的重计算、在算力紧张处适当多存以减少重算，但上述调节目前仍依赖人工或离线调参。Megatron-LM、NeMo 等支持按层或子模块（如 `core_attn`、`mlp`）配置选择性重算 [??]；Colossal-Auto[??] 等将自动并行策略搜索与激活检查点统一自动化，为大规模模型与异构环境下的联合优化提供了参考；在异构 GPU 集群上，针对 MLLM 的模块异构与分阶段冻结，设计能自动适应设备异构的细粒度检查点策略仍是开放问题，也是本文后续工作方向之一。

2.5 本章小结

本章从多模态大语言模型、并行与分布式训练基础、异构 GPU 集群并行训练策略以及重计算优化四个方面对相关工作进行了综述。大模型训练系统的综述 [?] 也从不同角度归纳了并行、显存与异构优化的发展脉络。首先介绍了 MLLM 的典型架构（编码器、投影层、LLM 骨干及可选生成器）、训练数据规模与训练目标，以及模块异构与分阶段冻结带来的计算—显存需求差异。随后综述了数据并行、张量并行、流水线并行、序列并行与专家并行等多维混合同构并行方式，以及 ZeRO 系列显存分片优化，指出其在同构假设下的广泛应用与在异构、模块异构场景下的局限。接着讨论了异构 GPU 集群上显存、算力与通信的异构性，以及 Whale、HetPipe、Espresso、Cephalo 等异构感知并行与调度工作的思路与不足，并指出 MLLM 的混合模块结构与冻结策略进一步增加了高效划分与调度的难度。最后介绍了重计算的基本原理与全层、选择重计算及细粒度重计算等实现方式，以及 Megatron-LM 等框架中的多级粒度配置，并指出现有检查点策略多面向同构设备、难以根据异构集群与 MLLM 各阶段需求自动调节。综合来看，MLLM 的模块异构与分阶段冻结、以及异构集群的显存—算力—通信差异，共同构成了现有同构导向并行与统一检查点策略难以直接应对的挑战。上述分析为本文第三章的 MMoH 框架（需求驱动拓扑、复合粒度划分、冻结感知划分与提前终止调度）与第四章的 HR-MMoH 异构重计算提供了问题背景与动机。

致 谢

作者在学期间取得的学术成果

发表的学术论文

[1] 满足毕业条件

附录 A 本文中英文对照表

表 A.1 给出正文常用术语的中英文对照；第二列在必要时附缩写或原文记号。

表 A.1 本文主要术语中英文对照表

中文	英文
自注意力机制	Self-Attention
Transformer 架构	Transformer
深度神经网络	Deep Neural Network (DNN)
卷积神经网络	Convolutional Neural Network (CNN)
循环神经网络	Recurrent Neural Network (RNN)
计算机视觉	Computer Vision (CV)
自然语言处理	Natural Language Processing (NLP)
语音识别	Speech Recognition (SR)
大语言模型	Large Language Model (LLM)
多模态大语言模型	Multimodal Large Language Model (MLLM)
通用人工智能	Artificial General Intelligence (AGI)
自回归（建模）	Autoregressive
编码器—解码器（结构）	Encoder-Decoder
迁移学习	Transfer Learning
少样本学习	Few-Shot Learning
零样本学习	Zero-Shot Learning
扩展定律	Scaling Laws
图文对比学习	Contrastive Language-Image Pre-Training (CLIP)
词嵌入	word embedding
图像描述	Image Captioning
视觉问答	Visual Question Answering (VQA)
图文对话	Visual-Text Dialog
文档理解	Document Understanding
具身智能	Embodied Intelligence
医疗影像理解	Medical Image Understanding

续下页

续表 A.1

中文	英文
最优先进水平	state-of-the-art (SOTA)
模态编码器	Modality Encoder
输入投影层	Input Projector
LLM 骨干 / 主体	LLM Backbone
输出投影层	Output Projector
模态生成器	Modality Generator
扩散模型	diffusion model
模块异构	module heterogeneity
模态对齐	modality alignment
指令微调	instruction tuning
多模态生成微调	multimodal generative fine-tuning
数据并行	data parallelism (DP)
分布式数据并行	Distributed Data Parallel (DDP)
张量并行	tensor parallelism (TP)
流水线并行	pipeline parallelism (PP)
序列并行	sequence parallelism (SP)
上下文并行	context parallelism (CP)
专家并行	expert parallelism (EP)
混合专家	Mixture of Experts (MoE)
三维混合并行	3D parallelism (DP+TP+PP)
微批次	micro-batch
小批量	mini-batch
一前向一反向调度	One-Forward-One-Backward (1F1B)
全归约	AllReduce
全收集	All-Gather
归约分散	Reduce-Scatter
全对全通信	All-to-All
点对点通信	Peer-to-Peer (P2P)
参数服务器	parameter server
主流水级	master pipeline stage

续下页

续表 A.1

中文	英文
流水级 / 流水线阶段	pipeline stage
流水线气泡	pipeline bubble
混合并行	hybrid parallelism
混合精度训练	mixed-precision training
Flash Attention / FlashAttention-3	Flash Attention / FlashAttention-3
全分片数据并行	Fully Sharded Data Parallel (FSDP)
零冗余优化器	Zero Redundancy Optimizer (ZeRO)
ZeRO-Infinity / ZeRO++	ZeRO-Infinity / ZeRO++
环形注意力	Ring Attention
激活 / 激活值	activation
显存溢出	Out Of Memory (OOM)
负载均衡	load balancing
剖析 / 性能剖析	profiling
设备拓扑	device topology
整数规划	integer programming
复合粒度（模型抽象）	multi-granularity model abstraction
成本模型	cost model
服务等级目标	Service Level Objective (SLO)
模型算力利用率	Model FLOPs Utilization (MFU)
虚拟工作节点	Virtual Worker (VW)
剖析器 / 性能估计器	Profiler / Performance Estimator
GPU 分配器	GPU Allocator
阶段放置器	Stage Placer
全部重计算	full recomputation
选择重计算	selective recomputation
细粒度重计算	fine-grained recomputation
Top- k （专家路由）	Top- k (expert routing)